

SVEUČILIŠTE U ZAGREBU  
**FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA**

DIPLOMSKI RAD br. 872

# **VARIJACIJSKO UČENJE NA ZAŠUMLJENIM OZNAKAMA**

Dominik Jambrović

Zagreb, lipanj, 2025.

Zagreb, 3. ožujka 2025.

## DIPLOMSKI ZADATAK br. 872

Pristupnik: **Dominik Jambrović (0036534818)**

Studij: Računarstvo

Profil: Računarska znanost

Mentor: prof. dr. sc. Siniša Šegvić

Zadatak: **Varijacijsko učenje na zašumljenim oznakama**

Opis zadatka:

Raspoznavanje slika važan je problem računalnog vida s mnogim zanimljivim primjenama. U posljednje vrijeme stanje tehnike postižu duboki modeli zasnovani na konvolucijama i slojevima pažnje. Međutim, standardni postupci teško se nose sa zašumljenim oznakama. U okviru rada, potrebno je odabrati okvir za automatsku diferencijaciju te upoznati biblioteke za rukovanje tenzorima i slikama. Proučiti i ukratko opisati postojeće duboke arhitekture za raspoznavanje slika s posebnim naglaskom na prednaučene samonadzirane modele. Odabrati slobodno dostupne skupove slika te oblikovati podskupove za učenje, validaciju i testiranje. Formulirati optimizacijski cilj s latentnim predikcijama čistih razreda te predložiti rješenje utemeljeno na varijacijskoj aproksimaciji te maksimiziranju očekivanja. Komentirati učinkovitost učenja i zaključivanja. Predložiti pravce za budući rad. Radu priložiti izvorni i izvršni kod razvijenih postupaka, ispitne slijedove i rezultate, uz potrebna objašnjenja i dokumentaciju. Citirati korištenu literaturu i navesti dobivenu pomoć.

Rok za predaju rada: 4. srpnja 2025.

*Prof. dr. sc. Siniši Šegviću i univ. mag. ing. Ivanu Saboliću, hvala na brojnim savjetima i  
pomoći tijekom izrade diplomskog rada.*

*Mojim roditeljima, hvala na beskrajnoj podršci tijekom cijelog studija.*

*Mojim ljubimcima, hvala na društvu i sreći tijekom učenja i rada.*

# Sadržaj

|                                            |           |
|--------------------------------------------|-----------|
| <b>1. Uvod</b>                             | <b>4</b>  |
| <b>2. Napadi umetanjem stražnjih vrata</b> | <b>6</b>  |
| 2.1. Implementacije napada                 | 7         |
| 2.1.1. BadNets                             | 7         |
| 2.1.2. Blend                               | 8         |
| 2.1.3. WaNet                               | 8         |
| 2.2. Obrane od napada                      | 9         |
| 2.2.1. ABL                                 | 9         |
| 2.2.2. DBD                                 | 10        |
| 2.2.3. ASD                                 | 12        |
| <b>3. Zašumljene oznake</b>                | <b>14</b> |
| 3.1. Metode zašumljivanja                  | 15        |
| 3.1.1. Simetrično zašumljivanje            | 15        |
| 3.1.2. Asimetrično zašumljivanje           | 16        |
| 3.2. Učenje na zašumljenim oznakama        | 17        |
| 3.2.1. SOP                                 | 17        |
| 3.2.2. ILL                                 | 19        |
| <b>4. Samonadzirano učenje</b>             | <b>21</b> |
| 4.1. Kontrastno samonadzirano učenje       | 22        |
| 4.2. All4One                               | 23        |
| 4.2.1. Kontrastiranje najbližih susjeda    | 24        |
| 4.2.2. Kontrastiranje centroida            | 25        |
| 4.2.3. Kontrastiranje značajki             | 26        |

|                                                        |           |
|--------------------------------------------------------|-----------|
| 4.2.4. Kombinirano kontrastiranje . . . . .            | 27        |
| <b>5. Algoritam maksimizacije očekivanja . . . . .</b> | <b>28</b> |
| 5.1. Osnovna ideja . . . . .                           | 29        |
| 5.2. Izvod algoritma . . . . .                         | 29        |
| <b>6. Problem optimalnog transporta . . . . .</b>      | <b>33</b> |
| 6.1. Općenita formulacija . . . . .                    | 34        |
| 6.2. Algoritam Sinkhorn-Knopp . . . . .                | 35        |
| <b>7. VIBE . . . . .</b>                               | <b>38</b> |
| 7.1. Parametrizacija distribucija . . . . .            | 39        |
| 7.2. Optimizacija varijacijskog cilja . . . . .        | 40        |
| 7.2.1. E korak . . . . .                               | 42        |
| 7.2.2. M korak . . . . .                               | 44        |
| 7.3. Konzistencijski gubitak . . . . .                 | 45        |
| 7.4. Pretprocesiranje . . . . .                        | 47        |
| <b>8. Duboki konvolucijski modeli . . . . .</b>        | <b>49</b> |
| 8.1. Konvolucijski sloj . . . . .                      | 49        |
| 8.2. Sloj normalizacije nad grupom . . . . .           | 51        |
| 8.3. Rezidualni modeli . . . . .                       | 53        |
| <b>9. Skupovi podataka . . . . .</b>                   | <b>55</b> |
| 9.1. CIFAR-10 . . . . .                                | 55        |
| <b>10. Eksperimenti . . . . .</b>                      | <b>56</b> |
| 10.1. Zašumljene oznake . . . . .                      | 56        |
| 10.1.1. Usporedba sa stanjem tehnike . . . . .         | 58        |
| 10.1.2. Validacija hiperparametara . . . . .           | 62        |
| 10.1.3. Validacija gubitka stanja tehnike . . . . .    | 68        |
| 10.1.4. Validacija gubitka nadziranog učenja . . . . . | 70        |
| 10.2. Napadi umetanjem stražnjih vrata . . . . .       | 72        |
| 10.2.1. Usporedba sa stanjem tehnike . . . . .         | 73        |
| 10.2.2. Primjena algoritma ILL . . . . .               | 75        |

|                                                      |           |
|------------------------------------------------------|-----------|
| 10.2.3. Hibrid okvira VIBE i algoritma ILL . . . . . | 76        |
| <b>11. Zaključak . . . . .</b>                       | <b>80</b> |
| <b>Literatura . . . . .</b>                          | <b>82</b> |
| <b>Sažetak . . . . .</b>                             | <b>90</b> |
| <b>Abstract . . . . .</b>                            | <b>91</b> |

# 1. Uvod

Duboki modeli koriste se u brojnim aspektima naše svakodnevice. Pri razvoju i učenju modela, pažnju prije svega posvećujemo performansama na neviđenim podacima - želimo naučiti modele koji dobro generaliziraju. Drugim riječima, želimo da modeli daju ispravna predviđanja za viđene, ali i za neviđene podatke. Ovime osiguravamo da naša rješenja imaju primjenu i van laboratorijskih uvjeta u kojima se uče.

U procesu razvoja modela za određeni zadatak strojnog učenja, osim odabira arhitekture, algoritma učenja i hiperparametara, veliku ulogu igraju podatci na kojima učimo. Općenito govoreći, prikupljanje i označavanje podataka jedan je od najskupljih dijelova procesa razvoja rješenja za nekih problem. Važno je da prikupljeni podatci što realističnije predstavljaju stvarne situacije s kojima će se naš model susretati tj. da distribucija podataka odgovara stvarnoj distribuciji situacija koje prikazuju. Dodatno, pokazuje se da duboki modeli uz dovoljan kapacitet mogu naučiti ispravno predviđati oznake čak i za nasumično označene podatke [1], tako da je veoma važno da su prikupljeni podatci što točnije označeni.

Područje računalnog vida [2] bavi se razvojem algoritama i modela za brojne zadatke raspoznavanja i razumijevanja slika. Najčešći zadatak je klasifikacija slika - model na ulazu dobiva sliku, a na izlazu treba predvidjeti razred koji odgovara ulaznom primjeru. Iako postoje brojni skupovi slikovnih podataka koji se mogu koristiti za učenje i evaluaciju modela, za konkretne zadatke u većini slučajeva trebamo prikupiti i označiti vlastite slike. Pritom postoji nekoliko čestih opasnosti: napadi umetanjem stražnjih vrata [3] i prisutnost zašumljenih oznaka [4].

Kada govorimo o napadima umetanjem stražnjih vrata (engl. *backdoor attack*), maliciozni agent u skup podataka dodaje zatrovane podatke s ciljem manipulacije izlaza naučenog modela za određene ulaze. S druge strane, anotator podataka bez zlih namjera određenim podacima može pridijeliti netočne oznake, time dodajući podatke sa zašumljenim oznakama u skup. Kroz vrijeme, razvili su se brojni algoritmi za obranu modela od napada umetanjem stražnjih vrata [5, 6, 7], kao i za učenje na zašumljenim oznakama [8, 9]. Ipak, većina radova se fokusira na samo jedan od ovih problema, a ne na razvoj algoritma koji se može nositi s oba problema.

Cilj ovog rada je reproducirati i poboljšati rezultate okvira za obranu od napada umetanjem stražnjih vrata imena VIBE (engl. *Variational inference for backdoor elimination*) [10]. Osim ovoga, cilj je i primijeniti VIBE na problem zašumljenih oznaka. Pritom VIBE evaluiramo na nekoliko čestih vrsta napada odnosno metoda zašumljivanja oznaka kako bi se osigurala robusnost okvira. Dodatno, cilj je usporediti VIBE sa stanjem tehnike (engl. *state of the art* - *SotA*) za problem zašumljenih oznaka.



## 2. Napadi umetanjem stražnjih vrata

Cilj napada umetanjem stražnjih vrata [3] je dodavanjem zatrovanih podataka ugraditi stražnja vrata u naučeni model. Ako napad uspije, napadač može kontrolirati izlaz modela koristeći suptilne izmjene ulaznog primjera. Općenito govoreći, napad umetanjem stražnjih vrata podrazumijeva dodavanje vizualnog okidača na ulazni primjer, kao i prikladnu izmjenu oznaka. Pritom napadač radi izmjenu određenog udjela podataka, dok preostali podatci ostaju neizmjenjeni. Hiperparametar koji opisuje udio zatrovanih podataka zvat ćemo stopom trovanja (engl. *poisoning rate*). Pojedini napadi razlikuju se po načinu dodavanja okidača tj. načinu izmjene ulaznih primjera, kao i po načinu izmjene oznaka.

Kada govorimo o načinu izmjene ulaznih primjera, možemo napraviti podjelu na lokalne i globalne izmjene primjera. Kod lokalnih izmjena, mijenja se samo određeno područje slike, najčešće dodavanjem zadanog okidača na to područje [11]. S druge strane, kod globalnih izmjena se mijenja cijela slika koristeći različite tehnike poput miješanja slike s okidačem [12] ili transformiranja slike na temelju zadanog deformacijskog polja [13]. Osim korištenja jednog okidača za sve zatrovane podatke, određeni napadi koriste okidače specifične za pojedini uzorak [14].

Većinu napada možemo svrstati u jedan od dva načina izmjena oznaka: *all-to-one* i *all-to-all* izmjena oznaka [15]. Kod *all-to-one* metode, primjeri dobivaju zatrovanu oznaku jednog proizvoljno odabranog razreda neovisno o originalnim oznakama pojedinih primjera. S druge strane, kod *all-to-all* metode, primjeri dobivaju zasebne zatrovane oznake ovisno o originalnim oznakama. Određeni napadi uopće ne mijenjaju oznake zatrovanih primjera, već se oslanjaju isključivo na jače izmjene ulaznih primjera. Ovakve napade zovemo napadi s čistim oznakama (engl. *clean-label attacks*) [16].


Uspješnost pojedinog napada mjerimo metrikom imena stopa uspješnosti napada (engl. *attack success rate* - ASR). Ovu mjeru definiramo kao točnost modela mjerenu isključivo na zatrovanim primjerima. Cilj algoritama za obranu od napada umetanjem stražnjih vrata je naučiti čisti model na zatrovanom skupu. Drugim riječima, glavni cilj obrane je naučiti model koji ima izvrsne performanse na čistim podacima, ali i što nižu stopu uspješnosti napada.

## 2.1. Implementacije napada

U ovome radu, fokusiramo se na tri napada umetanjem stražnjih vrata: napade BadNets [11], Blend [12] te WaNet [13].

### 2.1.1. BadNets

Napad BadNets uobičajeno dodaje jedan zadani okidač na svaki odabrani ulazni primjer. Okidač možemo shvatiti kao uzorak piksela koji se dodaje na specifično mjesto na slici. Na primjer, okidač može biti bijeli pravokutnik pozicioniran u donjem lijevom kutu slike. Naravno, korišteni uzorak može biti proizvoljne kompleksnosti i veličine. Kod napada BadNets, izmjene oznaka su najčešće tipa *all-to-one*, ali česte su i izmjene tipa *all-to-all*.



**Slika 2.1.** Primjer primjene napada BadNets. Izvornoj slici (lijevo) dodaje se okidač kako bi nastala zatrovana slika (desno).

### 2.1.2. Blend

Napad Blend provodi miješanje zadanog okidača sa svakim odabranim ulaznim primjerom. Pritom je jačina napada određena hiperparametrom  $\alpha$  koji nazivamo jačina miješanja (engl. *blending strength*). Primjenu napada Blend možemo prikazati jednadžbom:

$$\tilde{x} = (1 - \alpha) \cdot x + \alpha \cdot t \quad (2.1)$$

Pri čemu  $x$  označava ulazni primjer,  $t$  okidač, a  $\tilde{x}$  zatrovani primjer. Kod napada Blend, izmjene oznaka su uobičajeno tipa *all-to-one*.



**Slika 2.2.** Primjer primjene napada Blend. Izvorna slika (lijevo) miješa se s okidačem uz  $\alpha = 0.2$  kako bi nastala zatrovana slika (desno).

### 2.1.3. WaNet

Napad WaNet provodi geometrijsku transformaciju svakog odabranog ulaznog primjera koristeći nasumično generirano deformacijsko polje. Deformacijsko polje svakom pikselu određene slike dodjeljuje vektor pomaka prema pikselu izvorne slike. Pritom hiperparametar  $k$  određuje veličinu nasumično generiranog polja šuma na temelju kojeg se skaliranjem i interpolacijom dobiva konačno deformacijsko polje, a hiperparametar  $s$  određuje jačinu deformacije. Primjenu napada WaNet možemo definirati jednadžbom:

$$\tilde{x} = \mathcal{W}(x, \mathbf{M}(k, s)) \quad (2.2)$$

Pri čemu  $\mathbf{x}$  označava ulazni primjer,  $\mathbf{M}$  deformacijsko polje generirano uz hiperparametre  $k$  i  $s$ ,  $\mathcal{W}$  primjenu deformacijskog polja na ulazni primjer, a  $\tilde{\mathbf{x}}$  zatrovani primjer. Kao i kod napada Blend, kod napada WaNet su izmjene oznaka uobičajeno tipa *all-to-one*.



**Slika 2.3.** Primjer primjene napada WaNet. Izvorna slika (lijevo) transformira se koristeći deformacijsko polje uz  $k = 8$  i  $s = 4$  kako bi nastala zatrovana slika (desno). Hiperparametri  $k$  i  $s$  su uvećani kako bi učinak napada bio uočljiviji.

## 2.2. Obrane od napada

U ovome radu, rezultate okvira VIBE uspoređujemo s rezultatima triju obrana od napada umetanjem stražnjih vrata: *Anti-backdoor learning* (ABL) [5], *Decoupling based defense* (DBD) [6] te *Adaptively splitting dataset-based defense* (ASD) [7].

### 2.2.1. ABL

Algoritam *Anti-backdoor learning* (ABL) sastoji se od dva glavna koraka: izoliranje stražnjih vrata (engl. *backdoor isolation*) i odučavanje stražnjih vrata (engl. *backdoor unlearning*). Osnovna ideja ove obrane je da se nakon određenog broja epoha učenja uz posebno definiran gubitak izolira određeni broj primjera za koje se smatra da su zatrovani. Nakon prvog koraka, ti se primjeri koriste za odučavanje stražnjih vrata, dok se preostali primjeri koriste za standardno učenje.

Konkretno, cilj prvog koraka je zadržati vrijednost gubitka svakog pojedinog primjera oko praga  $\gamma$ . Kako bi ovo postigli, autori predlažu korištenje gradijentnog uspona [17] u slučaju da gubitak primjera padne ispod praga, dok se inače koristi gradijentni spust [18]. Gubitak u prvom koraku možemo prikazati jednadžbom:

$$\mathcal{L}_1 = \mathbb{E}_{(\mathbf{x}, y) \sim \mathcal{D}} [\text{sign}(\ell(f_\theta(\mathbf{x}), y) - \gamma) \cdot \ell(f_\theta(\mathbf{x}), y)] \quad (2.3)$$

Pritom  $(\mathbf{x}, y) \sim \mathcal{D}$  označava primjer  $\mathbf{x}$  s pripadnom oznakom  $y$  iz skupa podataka  $\mathcal{D}$ ,  $f_\theta(\mathbf{x})$  izlaz modela s parametrima  $\theta$ ,  $\ell(f_\theta(\mathbf{x}), y)$  gubitak za izlaz modela i stvarnu oznaku  $y$ , a  $\text{sign}$  operaciju signum.

Ideja je da će gubitak za zatrovane primjere veoma brzo pasti ispod praga te će se za njih često aktivirati gradijentni uspon, dok će gubitak čistih primjera sporije padati i stabilizirati se oko praga. Nakon zadanog broja epoha, izolira se udio  $p$  primjera s najnižim gubitkom i proglašava potencijalnim zatrovanim skupom. Važno je napomenuti da bismo prvi korak ABL-a mogli zamijeniti proizvoljnim algoritmom detekcije zatrovanih primjera.


U drugom koraku, učenje se u svakoj epohi provodi zasebno za procijenjeni čisti odnosno zatrovani skup. Dok se učenje na čistom skupu provodi uz standardni gradijentni spust, učenje na zatrovanom skupu provodi se uz gradijentni uspon kako bi model odučili od stražnjih vrata. Ovo je moguće zato što je napad najčešće realiziran uz samo jedan ciljani razred tj. uz *all-to-one* način izmjene oznaka. Gubitak u drugom koraku možemo prikazati jednadžbom:

$$\mathcal{L}_2 = \mathbb{E}_{(\mathbf{x}, y) \sim \hat{\mathcal{D}}_c} [\ell(f_\theta(\mathbf{x}), y)] - \mathbb{E}_{(\mathbf{x}, y) \sim \hat{\mathcal{D}}_b} [\ell(f_\theta(\mathbf{x}), y)] \quad (2.4)$$

Pritom  $\hat{\mathcal{D}}_c$  označava procijenjeni čisti skup, a  $\hat{\mathcal{D}}_b$  procijenjeni zatrovani skup.

### 2.2.2. DBD

Algoritam *Decoupling based defense* (DBD) obranu od napada umetanjem stražnjih vrata razdvaja na tri koraka. Pritom DBD model tretira kao dvije povezane cjeline: ekstraktor značajki (engl. *feature extractor*) te klasifikator (najčešće nekoliko potpuno-povezanih slojeva). Ekstraktor značajki za ulazni primjer na izlazu daje vektor značajki tj. ugrađivanje (engl. *embedding*) u latentnom metričkom prostoru. S druge strane, klasifikator za ugrađivanje na ulazu predviđa jednu od mogućih oznaka.



**Slika 2.4.** Prikaz glavnih koraka obrane DBD. Preuzeto iz [6].


U prvom koraku, DBD uči ekstraktor značajki koristeći proizvoljan algoritam samonadziranog učenja [19] na slikama bez oznaka. Budući da algoritmi samonadziranog učenja uobičajeno uključuju korištenje jakih augmentacija ulaznih primjera, kvaliteta okidača kod zatrovanih primjera bit će narušena. Dodatno, jer se model u ovoj fazi uči bez oznaka, u prvom koraku nije moguće ugraditi stražnja vrata u ekstraktor značajki. Drugim riječima, na kraju prvog koraka imat ćemo naučen čisti ekstraktor značajki.

U drugom koraku, parametri ekstraktora značajki su zamrznuti, a klasifikator učimo koristeći klasično nadzirano učenje na podacima s oznakama. Pritom kao funkciju gubitka koristimo simetričnu unakrsnu entropiju - pokazano je da korištenje iste rezultira višim gubitkom kod zatrovanih primjera [20]. Ipak, ako bismo koristili samo ova dva koraka, dobiveni model ne bi imao performanse jednake stanju tehnike jer smo ekstraktor značajki učili bez oznaka. Zbog toga, važno je napraviti podjelu skupa podataka na čisti i zatrovani skup te nakon toga ugoditi (engl. *fine-tune*) cijeli model. Kod algoritma DBD, ova podjela se radi na temelju iznosa gubitka: udio  $\alpha$  primjera s najnižim iznosom gubitka smatrat ćemo vjerodostojnim tj. čistim skupom, dok ćemo preostale primjere smatrati zatrovanima.

Treći korak koristi podjelu na čisti i zatrovani skup kako bi dodatno ugodio parametre cijelog modela. Konkretno, zatrovanom skupu uklanjamo oznake te potom model učimo koristeći proizvoljni algoritam polunadziranog učenja [21]. Na kraju ovog koraka, imat ćemo naučen cjelokupni model otporan na napade umetanjem stražnjih vrata.

### 2.2.3. ASD

Algoritam *Adaptively splitting dataset-based defense* (ASD) obranu od napada umetanjem stražnjih vrata razdvaja na tri koraka. Tijekom sva tri koraka, održavaju se dva skupa podataka: čisti i zagađeni skup. Pritom se u čistom skupu nalaze podatci za koje je velika vjerojatnost da su čisti, dok se u zagađenom skupu nalaze zatrovani podatci, kao i preostali čisti podatci. Kroz učenje, čisti skup se povećava dodavanjem primjera iz zagađenog skupa. Konačno, na kraju učenja bi zagađeni skup trebao sadržavati isključivo zatrovane podatke. Parametri modela uvijek se ažuriraju na temelju proizvoljnog polunadziranog gubitka, pri čemu se zagađeni skup koristi za učenje bez oznaka.



**Slika 2.5.** Prikaz glavnih koraka obrane ASD.  $D_C$  predstavlja čisti skup, a  $D_P$  zagađeni skup.  $L_1$  odgovara gubitku  $\mathcal{L}_{SCE}$ , a  $L_2$  gubitku  $\mathcal{L}_{CE}$ . Preuzeto iz [7].

U prvom koraku, čisti skup se inicijalizira na mali broj provjereno čistih primjera (na primjer, po 10 primjera za svaki razred), dok se zagađeni skup inicijalizira na cijeli skup podataka. Svakih  $t$  epoha učenja, u čisti skup se iz zagađenog skupa dodaje  $n$  primjera iz svakog pojedinog razreda koji imaju najniži gubitak  $\mathcal{L}_{SCE}$ . Pritom kao funkciju gubitka  $\mathcal{L}_{SCE}$  koristimo simetričnu unakrsnu entropiju kako bi zatrovani primjeri imali što viši gubitak. Ovu podjelu zovemo razredno-svjesna podjela vođena gubitkom (engl. *class-aware loss-guided split*).

Tijekom drugog koraka, čisti skup značajno proširujemo dodavanjem udjela  $\alpha$  zagađenog skupa. Pritom se dodaju primjeri iz cijelog skupa (neovisno o razredu) koji imaju najniži gubitak  $\mathcal{L}_{SCE}$ . Ovu podjelu zovemo razredno-nesvjesna podjela vođena gubitkom (engl. *class-agnostic loss-guided split*).

Nakon prva dva koraka ASD-a, u zagađenom skupu preostaju zatrovani primjeri, ali i neki teški primjeri specifični za model. Zbog toga što model nismo učili na teškim primjerima s oznakama, performanse modela trenutno su niže od stanja tehnike. Kako bismo dodali i teške primjere u čisti skup, svaku epohu trećeg koraka konstruiramo virtualni model. Virtualni model inicijaliziramo parametrima glavnog modela te potom provodimo jednu epohu nadziranog učenja na zagađenom skupu uz korištenje gubitka  $\mathcal{L}_{CE}$ . Kao funkciju gubitka  $\mathcal{L}_{CE}$  koristimo standardnu unakrsnu entropiju. Nakon učenja virtualnog modela, mjerimo smanjenje gubitka definirano jednadžbom:

$$\Delta\mathcal{L}_{SCE} = \mathcal{L}_{SCE}(f_{\theta}) - \mathcal{L}_{SCE}(f_{\theta'}) \quad (2.5)$$

Pritom  $f_{\theta}$  označava glavni model s parametrima  $\theta$ , a  $f_{\theta'}$  predstavlja virtualni model s parametrima  $\theta'$  dobivenim nakon jedne epohe nadziranog učenja na zagađenom skupu. Konačno, udio  $\gamma$  primjera s najmanjim smanjenjem gubitka dodajemo u čisti skup. Intuicija iza ove podjele je da su zatrovani podatci lagani za naučiti, tako da već nakon jedne epohe nadziranog učenja isti imaju veoma nizak gubitak, dok teški čisti primjeri i dalje imaju visok gubitak. Važno je napomenuti da se virtualni model koristi isključivo za provođenje podjele na temelju smanjenja gubitka. Ovu podjelu zovemo meta-podjela (engl. *meta-split*) jer je pristup s učenjem virtualnog modela inspiriran područjem meta-učenja (engl. *meta-learning*) [22]. Na kraju trećeg koraka, u čistom skupu će se nalaziti gotovo svi čisti primjeri, a dobiveni model će imati izvrsne performanse uz otpornost na napade umetanjem stražnjih vrata.



### 3. Zašumljene oznake

Proces stvaranja skupa vizualnih podataka otprilike možemo podijeliti u tri koraka. U prvom koraku, potrebno je definirati skup razreda tj. oznaka koje mogu biti dodijeljene svakom primjeru. Tijekom drugog koraka, cilj nam je prikupiti što veći skup slika, pri tom pazeći na to da slike precizno prikazuju situacije s kojima će se naš model susretati. Dodatno, veoma je važno da je prikupljeni skup što raznovrsniji kako bi model mogao naučiti dobro generalizirati. Konačno, u trećem koraku anotatori označavaju slike na temelju definiranog skupa oznaka. Drugi i treći korak ovog procesa mogu se provoditi jedan za drugim, ali i paralelno - nakon što se prikupi određen broj slika, taj skup se šalje na označavanje, a istovremeno je moguće prikupiti još slika.

Iako anotatori podataka prolaze kroz brojne edukacije kako bi se što bolje upoznali s pravilima na temelju kojih će označavati podatke, određeni podatci su prirodom teži od drugih pa može doći do pogrešnog označavanja. Prisutnost zašumljenih oznaka slična je napadima umetanjem stražnjih vrata po tome što se kod oba problema model mora nositi s pogrešnim oznakama. Ipak, kod problema zašumljenih oznaka podrazumijevamo da su ulazne slike netaknute tj. da ne postoji nikakva izmjena ulaza. Dodatno, kod problema zašumljenih oznaka ne postoji konkretan cilj - podatci sa zašumljenim oznakama nastaju slučajno, bez ikakvih loših namjera.

Dok je kod napada umetanjem stražnjih vrata problem prelako učenje poveznice između prisutnosti okidača i određenog ciljnog razreda, kod podataka sa zašumljenim oznakama je problem činjenica da model uz dovoljan kapacitet može naučiti oznake čak i ako su one nasumično generirane [1]. Drugim riječima, ako nismo oprezni, lako je doći do prenaučenosti (engl. *overfitting*) modela. Naravno, ovakav model će loše generalizirati na ispravno označenim podacima.

Kako bismo mogli usporediti performanse različitih algoritama za učenje na zašumljenim oznakama, najčešće određenom udjelu čistog skupa podataka dodajemo sintetičke zašumljene oznake. Hiperparametar koji opisuje udio podataka sa zašumljenim oznakama zvat ćemo stopa šuma (engl. *noise rate*). Nakon učenja na zašumljenim podacima, performanse modela evaluiramo na čistom, ali i na u potpunosti zašumljenom skupu. Cilj algoritama za učenje na zašumljenim oznakama tada je zadržati performanse modela učenog na zašumljenim podacima što bližima performansama modela učenog na čistim podacima.


### 3.1. Metode zašumljivanja

U ovome radu, fokusiramo se na dvije metode zašumljivanja oznaka: simetrično (engl. *symmetric*) i asimetrično (engl. *asymmetric*) zašumljivanje [23].

#### 3.1.1. Simetrično zašumljivanje

Kod simetričnog zašumljivanja, nasumično biramo zadani udio primjera iz čistog skupa podataka te istima dodjeljujemo nasumično generirane nove oznake. Ovu metodu zašumljivanja također zovemo i uniformno zašumljivanje jer svaki razred ima jednaku vjerojatnost postati nova oznaka za neki zadani primjer.

Pritom razlikujemo dvije vrste simetričnog zašumljivanja: inkluzivnu (engl. *symm-inc*) i ekskluzivnu (engl. *symm-exc*) vrstu [23]. Ako govorimo o inkluzivnom simetričnom zašumljivanju, stvarna oznaka za neki zadani primjer može biti odabrana i kao zašumljena oznaka. S druge strane, kod ekskluzivnog simetričnog zašumljivanja ignoriramo stvarnu oznaku tj. zašumljena oznaka se uvijek razlikuje od stvarne oznake primjera. U našem radu, fokusirat ćemo se na inkluzivno simetrično zašumljivanje.




**Slika 3.1.** Prikaz inkluzivnog (gore) odnosno ekskluzivnog (dolje) simetričnog zašumljivanja za tri odabrana primjera iz skupa CIFAR-10 [24]. Čiste oznake (lijevo) preslikavaju se na jednu od mogućih oznaka (sredina) i nastaju zašumljene oznake (desno). Vidimo da primjeri s istim čistim oznakama nemaju nužno i iste zašumljene oznake.

### 3.1.2. Asimetrično zašumljivanje

Kod asimetričnog zašumljivanja, prvo nasumično biramo zadani udio primjera zasebno za svaki razred. Drugim riječima, ako je u pitanju skup CIFAR-10 [24], za svaki od 10 razreda nasumično ćemo odabrati zadani udio primjera kojima ćemo potencijalno dodijeliti zašumljene oznake.

Nakon početnog odabira, svakom primjeru dodjeljujemo novu oznaku na temelju predodređenog preslikavanja. Pritom je moguće da određeni razredi nemaju definirano preslikavanje u neki drugi razred, tako da odabranim primjerima iz tih razreda neće biti dodijeljene zašumljene oznake. Preslikavanje na temelju kojeg se pojedinim primjerima dodjeljuje nova oznaka unaprijed je definirano za pojedine skupove podataka poput skupova MNIST [25], CIFAR-10 i CIFAR-100 [24]. Kod skupova s hijerarhijskim odnosom razreda poput skupa CIFAR-100, preslikavanja su definirana nasumično unutar pojedinih grupa razreda.



**Slika 3.2.** Prikaz preslikavanja razreda za skup CIFAR-10. Odabranim primjerima se na temelju čistih oznaka (lijevo) dodjeljuju zašumljene oznake (desno). Pritom odabrani primjeri s istim čistim oznakama uvijek imaju i iste zašumljene oznake.

## 3.2. Učenje na zašumljenim oznakama

U ovome radu, rezultate prilagođenog okvira VIBE uspoređujemo s rezultatima dvaju algoritama za učenje na podacima sa zašumljenim oznakama: *Sparse over-parameterization* (SOP) [8] te *Imprecise label learning* (ILL) [9].

### 3.2.1. SOP

Osnovna ideja algoritma *Sparse over-parameterization* (SOP) bazira se na činjenici da su primjeri sa zašumljenim oznakama u većini slučajeva rijetki. Jedan od mogućih načina za učenje modela na zašumljenim oznakama tada je modeliranje šuma za pojedine primjere koristeći rijetke vektore.

Konkretno, za svaki primjer  $(\mathbf{x}_i, y_i)$  iz skupa podataka  $\mathcal{D}$  definiramo rijetki vektor  $\mathbf{s}_i$  koji služi kao odstupanje između uočene (potencijalno zašumljene) oznake  $\mathbf{y}_i^{OH}$  i čiste (skrivenne) oznake  $\mathbf{l}_i^{OH}$ . Pritom  $\mathbf{y}_i^{OH}$  označava jednojedinu kodiranu (engl. *one-hot encoding*) oznaku  $y$ . Uobičajeno, učenje modela se svodi na potragu za parametrima  $\theta$  koji minimiziraju gubitak definiran jednadžbom:

$$\mathcal{L} = \mathbb{E}_{(\mathbf{x}, y) \sim \mathcal{D}} [\ell(f_{\theta}(\mathbf{x}), y)] \quad (3.1)$$

Pritom  $f_{\theta}$  predstavlja model s parametrima  $\theta$ , a  $\ell(f_{\theta}(\mathbf{x}), y)$  funkciju gubitka između izlaza modela  $f_{\theta}(\mathbf{x})$  i dane oznake  $y$ . Uz uvođenje rijetkog vektora  $\mathbf{s}_i$  za svaki primjer, učenje se svodi na potragu za parametrima  $(\theta, \{\mathbf{s}_i\}_{i=1}^N)$  koji minimiziraju gubitak:

$$\mathcal{L}_{SOP} = \mathbb{E}_{(\mathbf{x}, y) \sim \mathcal{D}} [\ell(f_{\theta}(\mathbf{x}) + \mathbf{s}, y)] \quad (3.2)$$

Dodatno, kako bi se osigurala rijetkost vektora  $\mathbf{s}_i$ , isti definiramo pomoću vektora  $\mathbf{u}_i$  i vektora  $\mathbf{v}_i$  kao:

$$\mathbf{s}_i = \mathbf{u}_i \odot \mathbf{u}_i - \mathbf{v}_i \odot \mathbf{v}_i \quad (3.3)$$

Drugim riječima, za svaki podatak  $(\mathbf{x}_i, y_i)$  definiramo dva vektora parametara:  $\mathbf{u}_i$  i  $\mathbf{v}_i$ .

Ove vektore učimo zajedno s parametrima modela  $\theta$  koristeći gradijentni spust. Pritom je stopa učenja za parametre  $\{\mathbf{u}_i, \mathbf{v}_i\}_{i=1}^N$  skalirana hiperparametrom  $\alpha$  kako bi se izbjeglo trivijalno rješenje optimizacijskog problema kod kojeg vrijedi  $\mathbf{u}_i \equiv \mathbf{v}_i \equiv \mathbf{0}$ ,  $\forall i \in N$ .

Uočimo da vektor  $\mathbf{s}_i$  za primjer  $(\mathbf{x}_i, y_i)$  dodatno mora poštovati nekoliko uvjeta: u vektoru  $\mathbf{s}_i$  se pozitivna vrijednost može nalaziti isključivo na mjestu koje odgovara ne-negativnoj vrijednosti u  $\mathbf{y}_i^{OH}$ , dok se negativne vrijednosti mogu nalaziti isključivo na mjestima koje odgovaraju vrijednosti 0 u  $\mathbf{y}_i^{OH}$ . Dodatno, svaki element vektora  $\mathbf{s}_i$  mora biti u rasponu  $[-1, 1]$ . Kako bismo ovo osigurali, uvodimo konačnu definiciju vektora  $\mathbf{s}_i$ :

$$\mathbf{s}_i = \mathbf{u}_i \odot \mathbf{u}_i \odot \mathbf{y}_i^{OH} - \mathbf{v}_i \odot \mathbf{v}_i \odot (\mathbf{1} - \mathbf{y}_i^{OH}) \quad (3.4)$$

Pritom su vektori parametara  $\mathbf{u}_i$  i  $\mathbf{v}_i$  definirani kao:

$$\mathbf{u}_i \in [-1, 1]^K, \mathbf{v}_i \in [-1, 1]^K \quad (3.5)$$

U algoritmu SOP, za učenje parametara  $(\theta, \{\mathbf{u}_i\}_{i=1}^N)$  se kao funkcija gubitka koristi standardna unakrsna entropija. Nažalost, unakrsna entropija se ne može koristiti za ispravno učenje parametara  $\{\mathbf{v}_i\}_{i=1}^N$ . Umjesto toga, za učenje tih parametara kao funkciju gubitka koristimo srednju kvadratnu pogrešku.

Kako bi poboljšali performanse osnovnog algoritma SOP, autori predlažu dodavanje dvije nove komponente gubitka: konzistencijski gubitak (engl. *consistency loss*) [26] te gubitak ravnoteže razreda (engl. *class-balance loss*) [27]. Inačicu algoritma koja dodatno koristi ove dvije komponente gubitka zovemo SOP+, a ista općenito postiže bolje performanse od osnovne inačice algoritma.

### 3.2.2. ILL

Algoritam *Imprecise label learning* (ILL) obuhvaća i pokušava riješiti nekoliko problema vezanih uz nesavršenosti oznaka: učenje na djelomičnim oznakama (engl. *partial label learning*) [28], polunadzirano učenje te učenje na zašumljenim oznakama. Konkretno, ILL sve ove probleme smatra vrstama problema nepreciznih oznaka (engl. *imprecise labels*). Skup podataka tada sadrži ulazne slike  $X$  i neprecizne oznake  $I$ , dok su čiste oznake  $Y$  skrivene (latentne). Pritom su neprecizne oznake apstraktne - u stvarnosti to može biti skup oznaka (u problemu učenja na djelomičnim oznakama), ali i zašumljena oznaka (u problemu učenja na zašumljenim oznakama). Cilj učenja modela tada je pronaći parametre  $\theta$  koji maksimiziraju zajedničku vjerojatnost definiranu kao:

$$p(X, I | \theta) = \sum_Y p(X, I, Y | \theta) \quad (3.6)$$

Kako bismo maksimizirali logaritam očekivanja uz prisutnost latentne varijable, koristimo algoritam maksimizacije očekivanja (algoritam EM) [29]. Pritom u E koraku algoritma maksimizacije očekivanja računamo očekivanje zajedničke vjerojatnosti  $p(X, I, Y | \theta)$  uz zadanu uvjetnu vjerojatnost  $p(Y | X, I, \theta^t)$  u vremenskom koraku  $t$ . S druge strane, u M koraku tražimo parametre  $\theta$  koji maksimiziraju donju varijacijsku granicu (engl. *evidence lower bound* - ELBO) vjerojatnosti  $p(X, I | \theta)$ . Budući da se različite vrste problema razlikuju primarno po prirodi nepreciznosti oznaka, algoritmi za pojedine probleme najviše će se razlikovati u načinu izračuna vjerojatnosti  $p(Y | X, I, \theta^t)$ . Ovime algoritam ILL pruža unificirani okvir koji podržava različite vrste nepreciznosti oznaka, kao i kombinacije istih.

Dakle, glavni cilj algoritma ILL je pronaći parametre  $\theta$  koji maksimiziraju zajedničku vjerojatnost  $p(X, I | \theta)$  odnosno logaritam iste. Prema algoritmu EM, ovaj problem možemo riješiti maksimizacijom očekivanja:

$$\mathbb{E}_{Y|X,I,\theta^t} [\log p(X, Y, I | \theta)] = \mathbb{E}_{Y|X,I,\theta^t} [\log p(Y | X, \theta) + \log p(I | X, Y, \theta)] \quad (3.7)$$

Pritom ignoriramo član  $p(X)$  jer isti ne ovisi o parametrima  $\theta$ . Iz dobivenog izraza vidimo da izračunom očekivanja razmatramo sve moguće oznake  $Y$  na temelju danih nepreciznih oznaka  $I$ , umjesto da se fokusiramo na samo jednu prepravljenu oznaku. Na temelju ove formulacije dalje možemo izvesti cilj za pojedini problem. U našem radu, fokusirat ćemo se na izvod za problem učenja na zašumljenim oznakama.

Kod problema učenja na zašumljenim oznakama, neprecizne oznake  $I$  se manifestiraju kao zašumljene oznake  $\hat{Y}$ . Vjerojatnost  $p(\hat{Y}|Y, X, \theta)$  tada predstavlja model šuma ovisan o pojedinom uzorku  $X$ . Ovaj problem pojednostavit ćemo razmatranjem modela šuma neovisnog o uzorku  $\mathcal{T}(\hat{Y}|Y, \omega)$  s parametrima  $\omega$ . Cilj koji želimo maksimizirati tada dobivamo kao:

$$\begin{aligned}
\mathbb{E}_{Y|X,I,\theta^t} [\log p(X, Y, I|\theta)] &= \mathbb{E}_{Y|X,I,\theta^t} [\log p(Y, I|X, \theta)] \\
&= \mathbb{E}_{Y|X,\hat{Y},\theta^t} [\log p(Y, \hat{Y}|X, \theta)] \\
&= \mathbb{E}_{Y|X,\hat{Y},\theta^t} [\log p(Y|\hat{Y}, X, \theta) + \log p(\hat{Y}|X, \theta)] \\
&= \sum_Y p(Y|\hat{Y}, X, \theta^t) \log p(Y|\hat{Y}, X, \theta) + \log p(\hat{Y}|X, \theta)
\end{aligned} \tag{3.8}$$

Funkcija gubitka koju želimo minimizirati tada postaje:

$$\mathcal{L}_{ILL} = \mathcal{L}_{CE}(p(y|\mathbf{x}, \hat{y}, \theta, \omega^t), p(y|\mathbf{x}, \hat{y}, \theta^t, \omega^t)) + \mathcal{L}_{CE}(p(\hat{y}|\mathbf{x}, \theta, \omega), \hat{y}) \tag{3.9}$$

Pritom  $\mathcal{L}_{CE}$  označava unakrsnu entropiju. Prva komponenta dobivenog gubitka odgovara konzistencijskom gubitku čistih oznaka uvjetovanih zašumljenim oznakama, dok druga komponenta odgovara nadziranom gubitku na zašumljenim oznakama. Pritom se za izračun obje komponente koristi model šuma uz zadanu zašumljenu oznaku  $\hat{y}$ :

$$\begin{aligned}
p(y|\mathbf{x}, \hat{y}, \theta, \omega^t) &\propto p(y|\mathbf{x}, \theta) \mathcal{T}(\mathbf{y}|y, \omega^t) \\
p(\hat{y}|\mathbf{x}, \theta, \omega) &= \sum_y p(y|\mathbf{x}, \theta) \mathcal{T}(\mathbf{y}|y, \omega)
\end{aligned} \tag{3.10}$$

## 4. Samonadzirano učenje

Samonadzirano učenje [19] paradigma je strojnog učenja kod koje model uči izlučivati korisne reprezentacije tj. značajke ulaznih podataka na temelju posebno osmišljenih zadataka bez oznaka (engl. *pretext tasks*). Ovim pristupom pokušava se adresirati problem cijene i vremena potrebnog za označavanje velikih skupova podataka. Model učen proizvoljnim algoritmom samonadziranog učenja dalje se može koristiti kao okosnica (engl. *backbone*) za model koji rješava neki nizvodni (engl. *downstream*) zadatak poput klasifikacije ili detekcije objekata. Pritom se okosnici dodaje klasifikacijska glava (najčešće nekoliko potpuno-povezanih slojeva), a cijeli model se dodatno ugađa nadziranim učenjem na manjem skupu podataka prilagođenom konkretnom problemu.

Ključno pitanje kod samonadziranog učenja je formiranje zadatka učenja bez oznaka tj. odlučivanje o tome na temelju čega će model dobivati signal za učenje. Tipični zadatci uključuju rekonstrukciju ulaznih podataka na temelju izlučenih reprezentacija, grupiranje reprezentacija tj. ugrađivanja (engl. *embedding*) semantički sličnih podataka u prostoru ugrađivanja ili predviđanje maskiranih piksela ulaznih slika (engl. *masked image modeling* - MIM) [30]. Rješavanjem jednog od zadataka učenja, model posredno uči izlučivati korisne reprezentacije ulaznih podataka ili uočavati korisne odnose između podataka.


Područje samonadziranog učenja možemo podijeliti na temelju korištenog tipa zadatka učenja, a neka od najpoznatijih područja su autoasocijativno samonadzirano učenje [31] i kontrastno samonadzirano učenje [19]. Kod autoasocijativnog samonadziranog učenja, osnovni zadatak je rekonstruirati ulazni podatak na temelju izlučene reprezentacije. Pritom je model koji učimo odgovoran za izlučivanje reprezentacije, dok za rekonstrukciju uobičajeno koristimo drugi model koji nakon učenja odbacujemo. U našem radu, fokusirat ćemo se na kontrastno samonadzirano učenje.



## 4.1. Kontrastno samonadzirano učenje

Kontrastno učenje jedno je od područja samonadziranog učenja. Ono podrazumijeva učenje izlučivanja korisnih reprezentacija tj. ugrađivanja ulaznih podataka na temelju parova podataka. Ako su dobivena ugrađivanja normirana, a sličnost dvaju ugrađivanja možemo izračunati koristeći neku od standardnih metrika (na primjer, kosinusnu sličnost), tada govorimo o metričkim ugrađivanjima tj. ugrađivanjima u metrički prostor [32]. Možemo reći da naučeni model preslikava ulazne slike na  $(d-1)$ -dimenzionalnu hipersferu  $S^{d-1}$ , pri čemu sličnost ugrađivanja odgovara semantičkoj sličnosti ulaza.

Kod kontrastnog učenja razlikujemo sidro, pozitivne i negativne primjere. Trenutno promatrani podatak iz minigrupe nazivamo sidro, podatak sličan sidru nazivamo pozitivan primjer, a podatak različit od sidra nazivamo negativan primjer. Budući da primjeri nisu označeni, pozitivne primjere najčešće dobivamo perturbacijom sidra, dok negativnim primjerima smatramo sve ostale podatke iz minigrupe.



**Slika 4.1.** Prikaz osnovne ideje kontrastnog samonadziranog učenja. Cilj učenja je približiti sidro (gore lijevo) i pozitivan primjer (dolje lijevo), ali i međusobno udaljiti sidro i negativne primjere (desno). Preuzeto iz [33].

Glavni cilj kontrastnog učenja je približiti ugrađivanja pozitivnih parova (sidra i pozitivnog primjera), ali i istovremeno udaljiti ugrađivanja negativnih parova (sidra i negativnih primjera). Kako bismo ovo postigli, veoma je važno prikladno definirati funkciju gubitka, a neke od mogućih su trojni gubitak [34] te gubitak N parova. Gubitak N parova također je poznat i kao infoNCE gubitak [35], a možemo ga definirati jednadžbom:


$$\mathcal{L}_{infoNCE} = -\log \frac{\exp(\langle \mathbf{z}_a, \mathbf{z}_p \rangle / \tau)}{\sum_{i=1}^N \exp(\langle \mathbf{z}_a, \mathbf{z}_{ni} \rangle / \tau)} \quad (4.1)$$

Pritom  $\mathbf{z}_a$  označava ugrađivanje sidra  $\mathbf{x}_a$ ,  $\mathbf{z}_p$  ugrađivanje pozitivnog primjera  $\mathbf{x}_p$ ,  $\mathbf{z}_{ni}$  ugrađivanje i-tog negativnog primjera  $\mathbf{x}_{ni}$  iz minigrupe, a  $\tau$  hiperparametar temperature. Oznaka  $\langle \dots \rangle$  označava skalarni produkt vektora unutar zagrada.

U okviru za obranu od napada umetanjem stražnjih vrata VIBE, samonadzirana inicijalizacija parametara modela veoma je važan korak koji osigurava uspješnost obrane. Pritom za inicijalizaciju koristimo okvir All4One [36] koji se bazira na kontrastnom samonadziranom učenju.

## 4.2. All4One

Okvir All4One kombinira tri zasebna pristupa kontrastiranju kako bi naučeni modeli postizali što bolje rezultate. Konkretno, optimizacijski cilj okvira All4One sadrži komponentu kontrastiranja najbližih susjeda (engl. *nearest neighbour contrast*) [37], komponentu kontrastiranja centroida (engl. *centroid contrast*) te komponentu kontrastiranja značajki (engl. *feature contrast*) [38].



**Slika 4.2.** Prikaz arhitekture okvira All4One. Komponenta kontrastiranja najbližih susjeda označena je zelenom bojom, komponenta kontrastiranja centroida ljubičastom bojom, a komponenta kontrastiranja značajki crvenom bojom. Preuzeto iz [36].

U okviru All4One, glavni model  $f_\theta$  služi kao koder značajki. Ovaj model učimo gradientnim spustom, a kasnije ćemo ga koristiti za rješavanje proizvoljnih nizvodnih zadataka. Osim glavnog koder, tijekom učenja se dodatno održava i koder s momentom  $f_\xi$  [39] čiji parametri odgovaraju eksponencijalnom pomičnom prosjeku (engl. *exponential moving average* - EMA) parametara glavnog koder. Dodatno, osim para koder, učimo i par projektora  $g_\theta$  i  $g_\xi$ . Za svaku sliku  $\mathbf{x}$  na ulazu, generiraju se dvije augmentirane slike  $\mathbf{x}^1$  te  $\mathbf{x}^2$ . Jedna od dobivenih augmentiranih slika tada prolazi kroz koder s momentom i pripadni projektor te dobivamo ugrađivanje  $\mathbf{z}^1 = g_\xi(f_\xi(\mathbf{x}^1))$ , dok druga augmentirana slika prolazi kroz glavni koder i pripadni projektor te dobivamo ugrađivanje  $\mathbf{z}^2 = g_\theta(f_\theta(\mathbf{x}^2))$ . Dobivena ugrađivanja dalje se mogu koristiti za izračun pojedinih komponenti optimizacijskog cilja. Osim para koder i para projektora, dodatno se održavaju i dva prediktora  $q_\theta^{nn}$  te  $q_\theta^c$  koji služe za prilagodbu ugrađivanja za zadatak kontrastiranja najbližih susjeda odnosno zadatak kontrastiranja centroida.

#### 4.2.1. Kontrastiranje najbližih susjeda


Kontrastiranje najbližih susjeda često je korišten pristup kontrastnog samonadziranog učenja kod kojega se ugrađivanje jedne od perturbiranih slika zamijeni sa svojim najbližim susjedom. Konkretno, tijekom učenja održavamo skup prethodnih ugrađivanja (engl. *support set*)  $Q$  koji možemo koristiti za pronalazak najbližih susjeda za neko zadano ugrađivanje. Ovu operaciju označit ćemo operatorom  $KNN$ . Gubitak za  $i$ -ti primjer  $\mathbf{x}_i$  u minigrupi tada možemo definirati jednadžbom:

$$\mathcal{L}_{NNCLR} = -\log \frac{\exp(\langle \mathbf{nn}_i^1, \mathbf{p}_i^{nn,2} \rangle / \tau)}{\sum_{k=1}^N \exp(\langle \mathbf{nn}_i^1, \mathbf{p}_k^{nn,2} \rangle / \tau)} \quad (4.2)$$

Pritom  $\mathbf{nn}_i^1$  označava najbližeg susjeda ugrađivanja prve perturbacije primjera  $\mathbf{x}_i$ ,  $\mathbf{p}_i^{nn,2}$  izlaz prediktora  $q_\theta^{nn}$  za ugrađivanje druge perturbacije primjera  $\mathbf{x}_i$ , a  $\tau$  hiperparametar temperature. Naspram osnovne inačice kontrastnog učenja, kontrastiranje najbližih susjeda povećava raznolikost primjera koje model vidi tijekom učenja, a time i generalizacijsku moć naučenog modela.

### 4.2.2. Kontrastiranje centroida

Ipak, pokazano je da modeli ućeni kontrastiranjem najbliŹih susjeda mogu postići još bolje performanse ako se pritom koristi više od jednog najbliŹeg susjeda [40]. NaŹalost, ućenje s više od jednog najbliŹeg susjeda znaćajno povećava trajanje ućenja jer se funkcija cilja treba evaluirati za svakog susjeda pojedinaćno. Autori okvira All4One ovome problemu doskaću uvoćenjem kontrastiranja centroida.



**Slika 4.3.** Prikaz kontrastiranja najbliŹih susjeda (lijevo) i kontrastiranja centroida (desno). Kod kontrastiranja najbliŹih susjeda, kontrastiraju se najbliŹi susjed jedne perturbacije i druga perturbacija. S druge strane, kod kontrastiranja centroida, kontrastiraju se centriodi pojedinih perturbacija. Preuzeto iz [36].

Konkretno, nakon Źto smo za zadani primjer  $x$  generirali ugraćivanja  $z^1$  te  $z^2$ , za ista prvo pronalazimo skupove najbliŹih susjeda  $NN^1$  odnosno  $NN^2$ . Ugraćivanje  $z^2$  tada prolazi kroz prediktor  $q_\theta^c$  te dobivamo ugraćivanje  $p^{c,2}$ . Ovim ugraćivanjem zamijenit ćemo posljednjeg najbliŹeg susjeda u skupu  $NN^2$  te potom provesti operaciju kruŹnog posmaka (engl. *shift*) kojim će ugraćivanje  $p^{c,2}$  doći na prvo mjesto u skupu.

Kada imamo pripremljene skupove najbliŹih susjeda  $NN^1$  te  $NN^2$ , iz istih Źelimo dobiti po jedno ugraćivanje koje sadrŹi informacije o svim najbliŹim susjedima iz pripadnog skupa. Kako bismo ovo postigli, koristimo mehanizam samopaŹnje (engl. *self-attention*) [41]. Konkretno, koristimo koder transformera  $\psi$  kojemu na ulaz dovodimo niz ugraćivanja  $Seq$  iz skupa  $NN$  obogaćen sinusoidalnim pozicijskim kodiranjem [41]. Na izlazu koderu  $\psi$  tada dobivamo niz ugraćivanja  $Seq^c$  obogaćenih kontekstualnim informacijama o preostalim susjedima iz skupa. Kako bismo za svaki skup imali samo jedno ugraćivanje, kao centroid  $c$  proglašavamo prvo ugraćivanje s izlaza koderu transformera  $Seq_1^c$ .

Ovaj postupak provodimo zasebno za skup  $NN^1$  odnosno skup  $NN^2$  kako bismo dobili centroeide  $\mathbf{c}^1$  odnosno  $\mathbf{c}^2$ . Konačno, gubitak za  $i$ -ti primjer  $\mathbf{x}_i$  u minigrupi možemo definirati jednadžbom:

$$\mathcal{L}_{centroid} = -\log \frac{\exp(\langle \mathbf{c}_i^1, \mathbf{c}_i^2 \rangle / \tau)}{\sum_{k=1}^N \exp(\langle \mathbf{c}_i^1, \mathbf{c}_k^2 \rangle / \tau)} \quad (4.3)$$

### 4.2.3. Kontrastiranje značajki

Kontrastiranje značajki veoma se razlikuje od uobičajenih pristupa kontrastnom učenju. Kod ovog pristupa, ideja je direktno kontrastirati značajke ugrađivanja. Kako bismo ovo postigli, potrebno je izračunati korelacijsku matricu značajki za svaku minigrupu. Tada je cilj naučiti parametre modela koji korelacijsku matricu značajki što više približavaju prema jediničnoj matrici.

Konkretno, prvo za svaku minigrupu konstruiramo matrice  $\mathbf{Z}^1$  odnosno  $\mathbf{Z}^2$  u kojima reci označavaju ugrađivanja prve odnosno druge perturbacije pripadnih primjera iz minigrupe. Nakon provođenja  $L_2$  normalizacije matrice po stupcima, korelacijsku matricu  $\mathbf{C}\mathbf{C}^1$  dobivamo računanjem kosinusne sličnosti između transponirane matrice  $\mathbf{Z}^1$  te matrice  $\mathbf{Z}^2$ . Dodatno, korelacijsku matricu  $\mathbf{C}\mathbf{C}^2$  dobivamo uz zamjenu grana tj. zamjenu glavnog kodera i kodera s momentom te ponovan izračun sličnosti. Kada smo izračunali obje korelacijske matrice, gubitak za zadanu minigrupu možemo definirati jednadžbom:

$$\begin{aligned} \mathcal{L}_{feature} = & \frac{1}{2} \sqrt{\frac{1}{2D} \sum_{i=1}^D ((1 - \mathbf{C}\mathbf{C}_{i,i}^1)^2 + (1 - \mathbf{C}\mathbf{C}_{i,i}^2)^2)} \\ & + \frac{1}{2} \sqrt{\frac{1}{2D(D-1)} \sum_{i=1}^D \sum_{j \neq i}^D ((\mathbf{C}\mathbf{C}_{i,j}^1)^2 + (\mathbf{C}\mathbf{C}_{i,j}^2)^2)} \end{aligned} \quad (4.4)$$

Pritom  $D$  označava broj značajki tj. dimenzionalnost vektora ugrađivanja. Vidimo da će gubitak biti to manji što su korelacijske matrice bliže jediničnoj matrici. Prvi član gubitka pokušava povećati invarijantnost pojedinih značajki na augmentacije ulaznih slika, dok drugi član pokušava smanjiti međusobnu redundantnost značajki.

#### 4.2.4. Kombinirano kontrastiranje

Dok prethodni algoritmi samonadziranog učenja većinom koriste samo jednu vrstu kontrastiranja (na primjer, samo kontrastiranje najbližih susjeda), okvir All4One kombinira sva tri navedena pristupa. Konkretno, gubitak koji želimo minimizirati možemo definirati jednadžbom:

$$\mathcal{L}_{All4One} = \sigma \mathcal{L}_{NNCLR} + \kappa \mathcal{L}_{centroid} + \eta \mathcal{L}_{feature} \quad (4.5)$$

Pritom su  $\sigma$ ,  $\kappa$  i  $\eta$  hiperparametri koji određuju jačinu utjecaja pojedine vrste kontrastiranja. Kombiniranjem više pristupa kontrastnog učenja, okvir All4One poboljšava učenje korisnih reprezentacija ulaznih podataka.

## 5. Algoritam maksimizacije očekivanja

Zamislamo da imamo skup opaženih varijabli  $X$  te želimo pronaći parametre  $\theta$  pretpostavljenog modela za koje je log-izglednost  $\log p(X|\theta)$  maksimalna. Drugim riječima, zanima nas MLE (engl. *maximum likelihood estimation*) procjena [42] parametara  $\theta$ . Osim što ovaj zadatak ponekad ima rješenje u zatvorenoj formi (engl. *closed-form solution*), općenito ga možemo riješiti gradijentnim postupcima poput stohastičkog gradijentnog spusta [43]. Ako uz opažene varijable  $X$  postoje i skrivene (latentne) varijable  $Z$ , problem pronalaska MLE procjene parametara  $\theta$  postaje kompliciraniji. Konkretno, nepotpunu log-izglednost parametara tada možemo definirati kao:

$$\log p(X|\theta) = \log \int p(X, Z|\theta) dZ = \log \int p(X|Z, \theta) p(Z|\theta) dZ \quad (5.1)$$

Gledajući da optimizacijski cilj sada sadrži varijable  $Z$  čije vrijednosti ne znamo, više ga nije moguće direktno maksimizirati. Jedan od mogućih algoritama koji se nosi s postojanjem skrivenih varijabli je algoritam maksimizacije očekivanja (engl. *expectation maximization algorithm* - algoritam EM) [29]. Kao i gradijentni spust, i algoritam EM je iterativne prirode, ali se pritom svaka iteracija sastoji od dva zasebna koraka: E koraka i M koraka.

Pokazuje se da algoritam EM osigurava monotoni rast nepotpune log-izglednosti parametara  $\log p(X|\theta)$ , ali pritom ne postoji garancija da će algoritam konvergirati u globalni maksimum [44]. Drugim riječima, moguće je da dobiveni parametri  $\theta$  odgovaraju lokalnom maksimumu nepotpune log-izglednosti, tako da se preporučuje koristiti heurističke pristupe poput ponovnog pokretanja algoritma s nasumično odabranim početnim vrijednostima parametara  $\theta$  [44].

## 5.1. Osnovna ideja

Osnovna ideja algoritma EM je jednostavna. Tijekom učenja, u svakoj iteraciji uobičajeno prvo provodimo E korak, a nakon njega provodimo M korak. Naravno, moguće je provoditi i više M koraka zaredom. Gledajući da ne znamo vrijednosti skrivenih varijabli  $Z$ , kao ni vrijednosti optimalnih parametara  $\theta$ , učenje možemo započeti uz nasumično odabrane vrijednosti parametara  $\theta^{(0)}$ .

Na početku E koraka fiksiramo trenutne vrijednosti parametara  $\theta^{(t)}$ . Tada računamo očekivanje potpune log-izglednosti  $\log p(X, Z|\theta)$  uz uvjetnu distribuciju skrivenih varijabli  $p(Z|X, \theta^{(t)})$ . Izračunato očekivanje možemo definirati jednadžbom:

$$Q(\theta|\theta^{(t)}) = \mathbb{E}_{Z \sim p(\cdot|X, \theta^{(t)})} [\log p(X, Z|\theta)] \quad (5.2)$$

U M koraku, cilj nam je pronaći parametre  $\theta$  koji maksimiziraju izračunato očekivanje  $Q(\theta|\theta^{(t)})$ . Nakon što smo izračunali nove parametre  $\theta^{(t+1)}$ , možemo ih iskoristiti za provođenje E koraka sljedeće iteracije. Općenito, jednu iteraciju algoritma EM sažeto možemo prikazati kao:

$$\theta^{(t+1)} = \arg \max_{\theta} \mathbb{E}_{Z \sim p(\cdot|X, \theta^{(t)})} [\log p(X, Z|\theta)] \quad (5.3)$$

Pokažimo sada detaljniji izvod algoritma maksimizacije očekivanja.

## 5.2. Izvod algoritma

Glavni cilj algoritma EM je pronalazak parametara  $\theta$  koji maksimiziraju log-izglednost  $\log p(X|\theta)$  uz postojanje skrivenih varijabli  $Z$ . Koristeći Bayesovu formulu, vjerojatnost  $p(X|\theta)$  možemo prikazati kao:

$$p(X|\theta) = \frac{p(X|Z, \theta)p(Z|\theta)}{p(Z|X, \theta)} \quad (5.4)$$




Definirajmo sada zamjensku distribuciju  $q(Z)$  kao proizvoljnu distribuciju skrivenih varijabli  $Z$ . Ako izraz za vjerojatnost  $p(X|\theta)$  pomnožimo i podijelimo s  $q(Z)$  te potom primijenimo operaciju logaritmiranja, dobivamo:

$$\log p(X|\theta) = \log \frac{p(X|Z, \theta)p(Z|\theta)}{q(Z)} + \log \frac{q(Z)}{p(Z|X, \theta)} \quad (5.5)$$

Izračunajmo sada očekivanje dobivenog izraza s obzirom na distribuciju  $q(Z)$ . Budući da se na lijevoj strani jednadžbe ne pojavljuju skrivene varijable  $Z$ , nepotpunu log-izglednost  $\log p(X|\theta)$  konačno možemo definirati jednadžbom:

$$\begin{aligned} \log p(X|\theta) &= \int q(Z) \log \frac{p(X|Z, \theta)p(Z|\theta)}{q(Z)} dZ + \int q(Z) \log \frac{q(Z)}{p(Z|X, \theta)} dZ \\ &= F(q(Z), \theta) + KL(q(Z)||p(Z|X, \theta)) \end{aligned} \quad (5.6)$$

Pritom  $F(q(Z), \theta)$  predstavlja donju varijacijsku granicu (engl. *evidence lower bound* - ELBO) log-izglednosti  $\log p(X|\theta)$ , a  $KL(q(Z)||p(Z|X, \theta))$  predstavlja Kullback-Leibler (KL) divergenciju [45] između distribucija  $q(Z)$  te  $p(Z|X, \theta)$ . Algoritam maksimizacije očekivanja sada možemo interpretirati kao koordinatni uspon (engl. *coordinate ascent*) [46] s ciljem maksimizacije donje varijacijske granice  $F(q(Z), \theta)$ .



**Slika 5.1.** Prikaz rada algoritma EM.  $l(\theta)$  odgovara nepotpunoj log-izglednosti  $\log p(X|\theta)$ . E korak algoritma maksimizira donju varijacijsku granicu  $F(q(Z), \theta^{(t)})$  s obzirom na distribuciju  $q(Z)$ , a M korak algoritma maksimizira istu s obzirom na parametre  $\theta$ . Preuzeto iz [47].

E korak algoritma maksimizacije očekivanja sada maksimizira donju varijacijsku granicu  $F(q(Z), \theta^{(t)})$  s obzirom na distribuciju  $q(Z)$  uz fiksirane vrijednosti parametara  $\theta^{(t)}$ . Budući da lijeva strana jednadžbe 5.6 ne ovisi o distribuciji  $q(Z)$ , vidimo da je problem maksimizacije funkcije  $F(q(Z), \theta^{(t)})$  s obzirom na distribuciju  $q(Z)$  ekvivalentan problemu minimizacije izraza  $KL(q(Z)||p(Z|X, \theta^{(t)}))$ . Iznos KL divergencije jednak je 0 jedino kada vrijedi:

$$q(Z) = p(Z|X, \theta^{(t)}) \quad (5.7)$$

Ovime dobivamo rješenje E koraka, a uz dobivenu distribuciju  $q^{(t+1)}(Z)$  dodatno vrijedi da je donja varijacijska granica  $F(q^{(t+1)}(Z), \theta^{(t)})$  jednaka nepotpunoj log-izglednosti  $\log p(X|\theta^{(t)})$ . Uz uvrštavanje izraza za distribuciju  $q^{(t+1)}(Z)$ , donju varijacijsku granicu možemo zapisati kao:

$$\begin{aligned} F(p(Z|X, \theta^{(t)}), \theta) &= \int p(Z|X, \theta^{(t)}) \log \frac{p(X, Z|\theta)}{p(Z|X, \theta^{(t)})} dZ \\ &= \int [p(Z|X, \theta^{(t)}) \log p(X, Z|\theta) - p(Z|X, \theta^{(t)}) \log p(Z|X, \theta^{(t)})] dZ \\ &= \mathbb{E}_{Z \sim p(\cdot|X, \theta^{(t)})} [\log p(X, Z|\theta)] - \mathbb{E}_{Z \sim p(\cdot|X, \theta^{(t)})} [\log p(Z|X, \theta^{(t)})] \\ &= Q(\theta|\theta^{(t)}) + H(p(Z|X, \theta^{(t)})) \end{aligned} \quad (5.8)$$

Pri čemu  $H(p(Z|X, \theta^{(t)}))$  označava entropiju [48] distribucije  $p(Z|X, \theta^{(t)})$ . Uočimo da je dobiveni izraz za donju varijacijsku granicu jednak izrazu  $Q(\theta|\theta^{(t)})$ , ali uvećan za iznos entropije  $H(p(Z|X, \theta^{(t)}))$ . Kada smo odredili distribuciju  $q^{(t+1)}(Z)$  koja maksimizira donju varijacijsku granicu, možemo prijeći na M korak.

M korak algoritma maksimizacije očekivanja sada maksimizira donju varijacijsku granicu  $F(q^{(t+1)}(Z), \theta)$  s obzirom na parametre  $\theta$  uz fiksiranu distribuciju  $q^{(t+1)}(Z)$  dobivenu u E koraku. Dakle, cilj je pronaći parametre  $\theta^{(t+1)}$  koji maksimiziraju izraz:

$$\begin{aligned}
F(p(Z|X, \theta^{(t)}), \theta) &= Q(\theta|\theta^{(t)}) + H(p(Z|X, \theta^{(t)})) \\
&= Q(\theta|\theta^{(t)}) + \text{const.}
\end{aligned} \tag{5.9}$$

Pritom je član  $H(p(Z|X, \theta^{(t)}))$  konstantan s obzirom na trenutne parametre  $\theta$ , tako da on ne utječe na tijek optimizacije. Vidimo da je izvedeni M korak identičan M koraku osnovne ideje - jedina razlika je prisutnost konstantnog člana u izrazu koji maksimiziramo. Dobivene parametre  $\theta^{(t+1)}$  dalje možemo iskoristiti za provođenje E koraka sljedeće iteracije.

Pokažimo još da provođenjem algoritma maksimizacije očekivanja postizemo monotoni rast nepotpune log-izglednosti  $\log p(X|\theta)$ . Na kraju E koraka raspoložemo distribucijom  $q^{(t+1)}(Z)$  uz koju vrijedi:

$$\log p(X|\theta^{(t)}) = F(q^{(t+1)}(Z), \theta^{(t)}) \tag{5.10}$$

Provođenjem M koraka dobivamo parametre  $\theta^{(t+1)}$  uz koje vrijedi:

$$F(q^{(t+1)}(Z), \theta^{(t)}) \leq F(q^{(t+1)}(Z), \theta^{(t+1)}) \tag{5.11}$$

Gledajući da je funkcija  $F(q(Z), \theta)$  donja granica log-izglednosti  $\log p(X|\theta)$ , vrijedi i:


$$F(q^{(t+1)}(Z), \theta^{(t+1)}) \leq \log p(X|\theta^{t+1}) \tag{5.12}$$

Konačno, dobivamo početnu tvrdnju:

$$\log p(X|\theta^{(t)}) \leq \log p(X|\theta^{t+1}) \tag{5.13}$$

## 6. Problem optimalnog transporta

Problem optimalnog transporta (engl. *optimal transport problem*) [49] bavi se pitanjem premještanja jedne raspodjele (distribucije) mase u drugu, pritom nastojeći minimizirati ukupnu cijenu transporta. Drugim riječima, cilj je pronaći optimalni plan transporta za koji je ukupna cijena premještanja jedne distribucije u drugu minimalna.



**Slika 6.1.** Prikaz problema optimalnog transporta. Plan transporta  $T$  opisuje kako preoblikovati distribuciju  $\mu_0$  u distribuciju  $\mu_1$ . Preuzeto iz [50].

Općenito govoreći, dvije najpoznatije formulacije problema su Mongeova formulacija te Kantorovičeva formulacija, a po istima se problem optimalnog transporta često naziva i Monge-Kantorovičev problem [51]. Kod Mongeove formulacije problema, optimalni plan transporta je bijekcija - jedna vrijednost iz prve distribucije može se preslikati u samo jednu vrijednost iz druge distribucije. Ova formulacija ekvivalentna je problemu uparivanja bipartitnog grafa (engl. *bipartite graph matching*) [52].

S druge strane, kod Kantorovičeve formulacije problema, optimalni plan transporta možemo prikazati matricom zajedničke vjerojatnosti uz nekoliko dodatnih ograničenja. U okviru našeg rada, fokusirat ćemo se na Kantorovičevu formulaciju problema optimalnog transporta, kao i jedno moguće rješenje istoga.

## 6.1. Općenita formulacija

Neka su  $\mu$  i  $\nu$  vektori distribucija vjerojatnosti nad prostorima  $X$  odnosno  $Y$ . Vektor  $\mu$  neka je duljine  $M$ , a vektor  $\nu$  neka je duljine  $N$ . Cilj problema je pronaći optimalni plan transporta koji distribuciju  $\mu$  preslikava u distribuciju  $\nu$  uz što nižu ukupnu cijenu. Cijenu transporta između točke  $x \in X$  i točke  $y \in Y$  označit ćemo s  $C_{x,y}$ , pri čemu je  $C$  matrica cijena transporta. Neki zadani plan transporta definirat ćemo matricom  $Q$ . Važno je napomenuti da su matrice  $C$  i  $Q$  definirane nad prostorom  $X \times Y$  odnosno dimenzija su  $M \times N$ . Dodatno, svaki plan transporta mora zadovoljavati sljedeće uvjete:

$$\begin{aligned} Q\mathbf{1}_N &= \mu \\ Q^T\mathbf{1}_M &= \nu \end{aligned} \tag{6.1}$$

Drugim riječima, plan transporta  $Q$  mora se marginalizirati po stupcima u vektor  $\mu$  odnosno po redcima u vektor  $\nu$ . Gledajući da je u pitanju matrica vjerojatnosti, svaki element  $q_{ij}$  mora biti nenegativan. Ovim skupom linearnih ograničenja definiran je politop [53]:

$$Q[\mu, \nu] = \{Q \in \mathbb{R}_+^{M \times N} \mid Q\mathbf{1}_N = \mu, Q^T\mathbf{1}_M = \nu\} \tag{6.2}$$

Svako rješenje problema mora se nalaziti na zadanom politopu  $Q[\mu, \nu]$ . Problem optimalnog transporta tada možemo definirati kao potragu za matricom  $Q$  koja zadovoljava:

$$\min_Q \text{tr}(C^T Q) \tag{6.3}$$

Pritom  $\text{tr}$  označava operaciju traga matrice, a  $C^T$  označava transponiranu matricu  $C$ . Ovako formuliran problem možemo riješiti proizvoljnim algoritmom linearnog programiranja [54]. Matrica  $Q$  dobivena kao rješenje zadanog problema optimalnog transporta često će biti rijetka (engl. *sparse*). Ako želimo osigurati da rješenje  $Q$  što manje odgovara rijetkoj matrici, u problem možemo dodati komponentu entropijske regularizacije. Problem optimalnog transporta s entropijskom regularizacijom [55] možemo definirati jednadžbom:

$$\min_{\mathbf{Q}} \left[ \text{tr}(\mathbf{C}^T \mathbf{Q}) - \frac{1}{\lambda} H(\mathbf{Q}) \right] \quad (6.4)$$

Pri čemu je  $\lambda$  regularizacijski hiperparametar, a  $H(\mathbf{Q})$  entropija matrice vjerojatnosti dana kao:

$$H(\mathbf{Q}) = - \sum_{i=1}^M \sum_{j=1}^N \mathbf{Q}_{i,j} \log \mathbf{Q}_{i,j} \quad (6.5)$$

Ovisno o iznosu hiperparametra  $\lambda$ , član  $-\frac{1}{\lambda} H(\mathbf{Q})$  može potaknuti gustoću matrice plana transporta  $\mathbf{Q}$  te time spriječiti degeneraciju rješenja. Jedan od algoritama kojim možemo riješiti problem optimalnog transporta s entropijskom regularizacijom je algoritam Sinkhorn-Knopp (algoritam SK) [56].

## 6.2. Algoritam Sinkhorn-Knopp

Sinkhornov teorem [57] govori da za svaku matricu s pozitivnim vrijednostima  $\mathbf{A}$  dimenzija  $N \times N$  postoje dijagonalne matrice  $\mathbf{U}$  i  $\mathbf{V}$  s pozitivnim vrijednostima takve da je matrica  $\mathbf{UAV}$  dvostruko stohastička tj. da se svaki redak i stupac dobivene matrice sumiraju u 1. Pritom matrice možemo definirati kao  $\mathbf{U} = \text{diag}(\mathbf{u})$  odnosno  $\mathbf{V} = \text{diag}(\mathbf{v})$ , pri čemu je  $\text{diag}(\mathbf{u})$  dijagonalna matrica s vrijednostima vektora  $\mathbf{u}$ . Originalna namjena algoritma Sinkhorn-Knopp bila je proizvesti dvostruko stohastičku matricu  $\mathbf{UAV}$  na temelju dane matrice  $\mathbf{A}$ .

Uočimo da matrice  $\mathbf{U}$  i  $\mathbf{V}$  zapravo skaliraju retke odnosno stupce matrice  $\mathbf{A}$ . Zadatak algoritma tada postaje pronaći pripadne vektore  $\mathbf{u}$  i  $\mathbf{v}$  koji ispravno skaliraju zadanu matricu. Kako bismo ovo postigli, kod algoritma SK alterniramo između ažuriranja vektora  $\mathbf{u}$  na temelju suma pojedinih redaka odnosno vektora  $\mathbf{v}$  na temelju suma pojedinih stupaca. Konkretno, nakon inicijalizacije vektora na proizvoljne vrijednosti (na primjer, na vektore jedinica  $\mathbf{1}_N$ ), u svakoj iteraciji ih ažuriramo koristeći sljedeće jednadžbe:

$$\begin{aligned} \mathbf{u}^{(t+1)} &= \frac{\mathbf{1}_N}{\mathbf{A}\mathbf{v}^{(t)}} \\ \mathbf{v}^{(t+1)} &= \frac{\mathbf{1}_N}{\mathbf{A}^T\mathbf{u}^{(t)}} \end{aligned} \quad (6.6)$$

Nakon dovoljnog broja iteracija, vektori  $\mathbf{u}$  i  $\mathbf{v}$  će konvergirati u očekivane vrijednosti, a konačnu dvostruko stohastičku matricu dobivamo kao  $\mathbf{UAV}$ . Osim za postizanje dvostruke stohastičnosti dane matrice, pokazano je da se algoritam Sinkhorn-Knopp može koristiti i za rješavanje problema optimalnog transporta s entropijskom regularizacijom [58].

Prisjetimo se danog problema. Uz vektore distribucija vjerojatnosti  $\boldsymbol{\mu}$  i  $\boldsymbol{\nu}$  definiranih nad prostorima  $X$  odnosno  $Y$  te matricu cijena transporta  $\mathbf{C}$  dimenzija  $M \times N$ , cilj je pronaći matricu plana transporta  $\mathbf{Q}$  koja se nalazi na politopu  $\mathcal{Q}[\boldsymbol{\mu}, \boldsymbol{\nu}]$  te za koju vrijedi:

$$\min_{\mathbf{Q}} \left[ \text{tr}(\mathbf{C}^T \mathbf{Q}) - \frac{1}{\lambda} H(\mathbf{Q}) \right] \quad (6.7)$$

Pritom je  $\lambda$  regularizacijski hiperparametar, a  $H(\mathbf{Q})$  entropija matrice vjerojatnosti. Kako bismo izveli pravila za ažuriranje temeljena na algoritmu SK, definirajmo prvo Lagrangeovu funkciju [59]:

$$\mathcal{L}(\mathbf{Q}, \boldsymbol{\alpha}, \boldsymbol{\beta}) = \text{tr}(\mathbf{C}^T \mathbf{Q}) - \frac{1}{\lambda} H(\mathbf{Q}) + \boldsymbol{\alpha}^T (\mathbf{Q} \mathbf{1}_N - \boldsymbol{\mu}) + \boldsymbol{\beta}^T (\mathbf{Q}^T \mathbf{1}_M - \boldsymbol{\nu}) \quad (6.8)$$

Vektori  $\boldsymbol{\alpha}$  i  $\boldsymbol{\beta}$  odgovaraju Lagrangeovim multiplikatorima uz linearne uvjete jednakosti. Pogledajmo sada kako izgleda derivacija dobivene Lagrangeove funkcije  $\mathcal{L}(\mathbf{Q}, \boldsymbol{\alpha}, \boldsymbol{\beta})$  po proizvoljnom elementu matrice plana transporta  $\mathbf{Q}_{i,j}$ :

$$\frac{\partial \mathcal{L}}{\partial \mathbf{Q}_{i,j}} = \mathbf{C}_{i,j} + \frac{1}{\lambda} (1 + \log \mathbf{Q}_{i,j}) + \alpha_i + \beta_j \quad (6.9)$$

Izjednačavanjem dobivene parcijalne derivacije s 0, dobivamo izraz za element matrice plana transporta  $\mathbf{Q}_{i,j}$ :

$$\mathbf{Q}_{i,j} = \exp(-1) \exp(-\lambda \mathbf{C}_{i,j}) \exp(-\lambda \alpha_i) \exp(-\lambda \beta_j) \quad (6.10)$$

Pritom član  $\exp(-1)$  možemo ignorirati jer je on konstantan  $\forall i, j$ . Uvođenjem:

$$\begin{aligned}
\mathbf{A}_{i,j} &= \exp(-\lambda \mathbf{C}_{i,j}) \\
u_i &= \exp(-\lambda \alpha_i) \\
v_j &= \exp(-\lambda \beta_j)
\end{aligned} \tag{6.11}$$

Dolazimo do formulacije iz Sinkhornovog teorema:

$$\mathbf{Q} = \text{diag}(\mathbf{u}) \mathbf{A} \text{diag}(\mathbf{v}) \tag{6.12}$$

Gledajući da se svako rješenje  $\mathbf{Q}$  mora nalaziti na politopu  $\mathbf{Q} [\boldsymbol{\mu}, \boldsymbol{\nu}]$ , mora vrijediti:

$$\begin{aligned}
\text{diag}(\mathbf{u}) \mathbf{A} \text{diag}(\mathbf{v}) \mathbf{1}_N &= \boldsymbol{\mu} \\
\text{diag}(\mathbf{v}) \mathbf{A}^T \text{diag}(\mathbf{u}) \mathbf{1}_M &= \boldsymbol{\nu}
\end{aligned} \tag{6.13}$$

Ove izraze možemo dodatno pojednostaviti:

$$\begin{aligned}
\mathbf{u} \odot (\mathbf{A} \mathbf{v}) &= \boldsymbol{\mu} \\
\mathbf{v} \odot (\mathbf{A}^T \mathbf{u}) &= \boldsymbol{\nu}
\end{aligned} \tag{6.14}$$

Pronalaskom vektora  $\mathbf{u}$  i  $\mathbf{v}$  koji zadovoljavaju dana ograničenja, pronašli smo i rješenje  $\mathbf{Q}$ . Konačno, slijedeći algoritam Sinkhorn-Knopp, na temelju dobivenih ograničenja izvodimo izraze za iterativno ažuriranje vektora  $\mathbf{u}$  i  $\mathbf{v}$ :

$$\begin{aligned}
\mathbf{u}^{(t+1)} &= \frac{\boldsymbol{\mu}}{\mathbf{A} \mathbf{v}^{(t)}} \\
\mathbf{v}^{(t+1)} &= \frac{\boldsymbol{\nu}}{\mathbf{A}^T \mathbf{u}^{(t)}}
\end{aligned} \tag{6.15}$$



## 7. VIBE

Okvir VIBE (engl. *Variational inference for backdoor elimination*) [10] zasniva se na ideji da su podatci i zatrovane oznake realizacije uočenih slučajnih varijabli, dok su čiste oznake skrivene varijable. Cilj okvira tada je naučiti model koji na izlazu daje vjerojatnost čistih oznaka, bez obzira na mogućnost da je skup podataka zatrovan. Kako bismo ovo postigli, model učimo koristeći algoritam EM. Pritom u E koraku procjenjujemo čiste pseudooznake rješavajući problem optimalnog transporta s entropijskom regularizacijom, a u M koraku ažuriramo parametre modela koristeći gradijentni spust.

Neka je  $\mathcal{D}_{clean} = \{(\tilde{\mathbf{x}}^i, l^i)\}_{i=1}^N$  čisti skup podataka, pri čemu je  $\tilde{\mathbf{x}}^i \in X$  ulazni primjer, a  $l^i \in Y$  čista oznaka. Napadač modificira udio  $\gamma$  čistog skupa podataka te time nastaje zatrovani skup  $\mathcal{D} = \{(\mathbf{x}^i, y^i)\}_{i=1}^N$ . Pritom ulazni primjer  $\mathbf{x}^i \in X$  može sadržavati okidač, a oznaka  $y^i \in Y$  može biti zatrovana. Cilj okvira VIBE je naučiti model  $f$  koji potencijalno zatrovanom ulaznom primjeru  $\mathbf{x}^i$  dodjeljuje čistu oznaku  $l^i$ . Naravno, čiste oznake  $\mathbf{l}$  su skrivene, a dostupne su nam samo zatrovane oznake  $\mathbf{y}$ .

Uobičajeni napadi umetanjem stražnjih vrata modificiraju mali udio  $\gamma$  čistog skupa jer žele izbjeći detekciju. Drugim riječima, za većinu podataka će zatrovane i čiste oznake biti identične. Zbog ovoga, prirodan optimizacijski cilj za okvir VIBE je maksimizacija log-izglednosti skupa  $\mathcal{D}$  uz pretpostavku o nezavisno i identično distribuiranim primjerima (IID pretpostavku):

$$\ell_{VD}(\cdot|\mathcal{D}) = \log \prod_{i=1}^N p(y^i|\mathbf{x}^i) = \sum_{i=1}^N \log \sum_{l=1}^K p(y^i|l, \mathbf{x}^i) p(l|\mathbf{x}^i) \quad (7.1)$$

Zbog jednostavnosti, distribuciju  $p(y|l, \mathbf{x})$  možemo aproksimirati distribucijom  $p(y|l)$ . Drugim riječima, uvodimo model šuma koji ne ovisi o konkretnom primjeru. Kako bismo mogli optimirati zadani cilj, potrebno je definirati distribuciju  $p(l|\mathbf{x})$  odnosno distribuciju  $p(y|l, \mathbf{x})$ .

## 7.1. Parametrizacija distribucija

Model  $f$  podijelit ćemo na okosnicu tj. ekstraktor značajki  $g_\theta$  te klasifikacijsku glavu. Pritom ekstraktor značajki na ulazu dobiva primjer  $\mathbf{x}^i$ , a na izlazu daje ugrađivanje  $\mathbf{v}^i = g_\theta(\mathbf{x}^i)$  definirano na  $(d - 1)$ -dimenzionalnoj jediničnoj hipersferi  $S^{d-1}$ . Uvjetnu vjerojatnost ugrađivanja  $\mathbf{v}^i$  s obzirom na čistu oznaku  $l^i$  definirat ćemo kao von Mises-Fisherovu distribuciju (distribuciju vMF) [60]:

$$p_\phi(\mathbf{v}^i | l^i) = C_d(\kappa) \exp(\kappa \boldsymbol{\mu}_{l^i}^T \mathbf{v}^i) \quad (7.2)$$

Pri čemu vektor  $\boldsymbol{\mu}_{l^i} \in S^{d-1}$  određuje smjer središta distribucije na hipersferi, hiperparametar  $\kappa$  određuje raspršenost distribucije, a  $C_d(\kappa)$  je normalizacijska konstanta. Primjer  $\mathbf{x}^i$  jednoznačno određuje ugrađivanje  $\mathbf{v}^i$ , tako da vrijedi:

$$p_{\theta, \phi, \pi}(l^i | \mathbf{x}^i) = p_{\phi, \pi}(l^i | \mathbf{v}^i) \quad (7.3)$$

Koristeći Bayesovu formulu, vjerojatnost  $p_{\theta, \phi, \pi}(l|\mathbf{x})$  sada možemo definirati kao mješavinu distribucija vMF:

$$p_{\theta, \phi, \pi}(l^i | \mathbf{x}^i) = \frac{p_\phi(\mathbf{v}^i | l^i) p_\pi(l^i)}{\sum_{l'} p_\phi(\mathbf{v}^i | l') p_\pi(l')} = \frac{p_\phi(\mathbf{v}^i | l^i) \pi_{l^i}}{\sum_{l'} p_\phi(\mathbf{v}^i | l') \pi_{l'}} = \frac{\exp(\kappa \boldsymbol{\mu}_{l^i}^T \mathbf{v}^i + \log \pi_{l^i})}{\sum_{l'} \exp(\kappa \boldsymbol{\mu}_{l'}^T \mathbf{v}^i + \log \pi_{l'})} \quad (7.4)$$

Pritom koeficijenti miješanja  $\boldsymbol{\pi}$  odgovaraju apriornoj distribuciji čistih oznaka  $\mathbf{l}$ . Kako bismo osigurali da distribuciju  $\boldsymbol{\pi}$  možemo učiti, definiramo ju kao  $\boldsymbol{\pi} = \sigma(c \cdot \hat{\boldsymbol{\pi}})$ , pri čemu je  $\sigma$  funkcija softmax,  $c$  hiperparametar temperature, a  $\hat{\boldsymbol{\pi}}$  vektor parametara koje učimo. Ovom formulacijom osiguravamo da se vektor  $\boldsymbol{\pi}$  sumira u 1.

Uočimo da dobivena uvjetna vjerojatnost  $p_{\theta, \phi, \pi}(l|\mathbf{x})$  odgovara dubokom modelu s funkcijom softmax,  $L_2$  normalizacijom pred-logita te skupom razrednih prototipova  $\phi$ . Parametri definiranog modela tada su: skup razrednih tj. čistih prototipova  $\phi = \{\mu_1, \dots, \mu_K\}$ , koeficijenti miješanja  $\pi$  te parametri  $\theta$  ekstraktora značajki  $g_\theta$ . Uz ovu parametrizaciju, model  $f$  koji na ulazu prima primjer  $\mathbf{x}^i$  te na izlazu daje čistu oznaku  $l^i$  možemo prikazati kao kompoziciju nekoliko funkcija:

$$f = \arg \max \circ \cos\text{-sim}_{\phi, \pi} \circ g_\theta \quad (7.5)$$

Pritom funkcija  $\cos\text{-sim}_{\phi, \pi}$  računa kosinusnu sličnost između prototipova iz skupa  $\phi$  i ugrađivanja  $\mathbf{v}^i$  otežanu parametrima  $\pi$ .

Sada trebamo definirati distribuciju  $p(y|l, \mathbf{x})$ . Kako bismo to postigli, uvedimo još i skup zatrovanih prototipova  $\psi = \{\eta_1, \dots, \eta_K\}$  na istoj hipersferi  $S^{d-1}$ . Distribuciju  $p(y|l, \mathbf{x})$  definirat ćemo kao normaliziranu kosinusnu sličnost između zatrovanih prototipova i izlaza funkcije  $h$  koja kao ulaz dobiva čisti prototip  $\mu_{l^i}$  te ugrađivanje  $\mathbf{v}^i$ :

$$p_{\phi, \psi}(y^i | l^i, \mathbf{x}^i) = \frac{\exp(\nu \eta_{y^i}^T h(\mu_{l^i}, \mathbf{v}^i))}{\sum_{y'} \exp(\nu \eta_{y'}^T h(\mu_{l^i}, \mathbf{v}^i))} \quad (7.6)$$

Pri čemu je  $\nu$  hiperparametar temperature, a funkcija  $h$  je proizvoljno zadana. Definiranjem iste kao  $h(\mu, \mathbf{v}) = \mu$ , distribuciju  $p_{\phi, \psi}(y|l, \mathbf{x})$  aproksimiramo distribucijom  $p_{\phi, \psi}(y|l)$  koja ne ovisi o konkretnom primjeru. U našem radu, koristit ćemo upravo navedenu aproksimacijsku distribuciju. Uočimo da pomoću naučene distribucije  $p_{\phi, \psi}(y|l)$  možemo rekonstruirati pravila trovanja korištena za stvaranje zatrovanog skupa podataka  $\mathcal{D}$ . Skup svih parametara modela označit ćemo s  $\Omega = \theta \cup \pi \cup \phi \cup \psi$ . Nakon što smo parametrizirali obje potrebne distribucije, vrijeme je za definiranje algoritma učenja.

## 7.2. Optimizacija varijacijskog cilja


Nažalost, pokazuje se da direktna optimizacija cilja  $\ell_{VD}$  ne osigurava ispravno učenje distribucije  $p_{\theta, \phi, \pi}(l|\mathbf{x})$  [61]. Kako bismo doskočili ovom problemu, uvodimo zamjensku distribuciju  $q(l|\mathbf{x}, y)$ . Cilj  $\ell_{VD}$  sada možemo zapisati kao:

$$\begin{aligned}
\ell_{VD}(\mathbf{\Omega}|\mathcal{D}) &= \sum_{i=1}^N \log \sum_{l=1}^K p_{\phi,\psi}(y^i|l, \mathbf{x}^i) p_{\theta,\phi,\pi}(l|\mathbf{x}^i) \frac{q(l|\mathbf{x}^i, y^i)}{q(l|\mathbf{x}^i, y^i)} \\
&= \sum_{i=1}^N \log \mathbb{E}_{l^i \sim q(\cdot|\mathbf{x}^i, y^i)} \left[ \frac{p_{\phi,\psi}(y^i|l^i, \mathbf{x}^i) p_{\theta,\phi,\pi}(l^i|\mathbf{x}^i)}{q(l^i|\mathbf{x}^i, y^i)} \right]
\end{aligned} \tag{7.7}$$

Prisjetimo se da je logaritam konkavna funkcija. Primjenom Jensenove nejednakosti [62] dalje dobivamo:

$$\begin{aligned}
\ell_{VD}(\mathbf{\Omega}|\mathcal{D}) &= \sum_{i=1}^N \log \mathbb{E}_{l^i \sim q(\cdot|\mathbf{x}^i, y^i)} \left[ \frac{p_{\phi,\psi}(y^i|l^i, \mathbf{x}^i) p_{\theta,\phi,\pi}(l^i|\mathbf{x}^i)}{q(l^i|\mathbf{x}^i, y^i)} \right] \\
&\geq \sum_{i=1}^N \mathbb{E}_{l^i \sim q(\cdot|\mathbf{x}^i, y^i)} \left[ \log \frac{p_{\phi,\psi}(y^i|l^i, \mathbf{x}^i) p_{\theta,\phi,\pi}(l^i|\mathbf{x}^i)}{q(l^i|\mathbf{x}^i, y^i)} \right] \\
&= \sum_{i=1}^N \mathbb{E}_{l^i \sim q(\cdot|\mathbf{x}^i, y^i)} [\log p_{\phi,\psi}(y^i|l^i, \mathbf{x}^i) + \log p_{\theta,\phi,\pi}(l^i|\mathbf{x}^i) - \log q(l^i|\mathbf{x}^i, y^i)] \\
&= \mathcal{L}_{VD}(\mathbf{\Omega}, q|\mathcal{D})
\end{aligned} \tag{7.8}$$

Dobivena funkcija  $\mathcal{L}_{VD}(\mathbf{\Omega}, q|\mathcal{D})$  predstavlja donju varijacijsku granicu (ELBO) log-izglednosti  $\ell_{VD}(\mathbf{\Omega}|\mathcal{D})$ , a istu možemo optimirati algoritmom maksimizacije očekivanja. Konkretno, u E koraku ćemo uz fiksirane vrijednosti parametara  $\mathbf{\Omega}$  procijeniti distribuciju  $q(l|\mathbf{x}, y)$  za skup podataka  $\mathcal{D}$  rješavajući problem optimalnog transporta s entropijskom regularizacijom. Nakon toga, u M koraku ćemo uz fiksiranu distribuciju  $q(l|\mathbf{x}, y)$  ažurirati parametre modela  $\mathbf{\Omega}$  koristeći gradijentni spust.



**Slika 7.1.** Prikaz učenja okvirom VIBE. U E koraku (desno) procjenjujemo pseudooznake tj. distribuciju  $q(l|\mathbf{x}, y)$ , a u M koraku (lijevo) ažuriramo parametre modela  $\mathbf{\Omega}$ . Preuzeto iz [10].

Kako bismo osigurali da učenje algoritmom maksimizacije očekivanja konvergira k parametrima  $\mathbf{\Omega}$  koji imaju dobru generalizacijsku moć, važno je prikladno inicijalizirati model. Nasumična inicijalizacija parametara ne nudi nikakvu garanciju uspješnosti algoritma EM, tako da umjesto nje koristimo samonadziranu inicijalizaciju okvirom All4One. Pokazuje se da korištenje samonadzirane inicijalizacije parametara ubrzava konvergenciju učenja, a i rezultira modelom koji bolje generalizira [10].

### 7.2.1. E korak

Cilj E koraka algoritma maksimizacije očekivanja je pronaći distribuciju  $q(l|\mathbf{x}, y)$  koja maksimizira donju varijacijsku granicu  $\mathcal{L}_{VD}(\mathbf{\Omega}, q|\mathcal{D})$  uz fiksirane vrijednosti parametara  $\mathbf{\Omega}$ . Donju varijacijsku granicu uprosječenu preko  $N$  primjera možemo zapisati kao:

$$\begin{aligned}
\frac{1}{N}\mathcal{L}_{VD}(\mathbf{\Omega}, q|\mathcal{D}) &= \frac{1}{N} \sum_{i=1}^N \mathbb{E}_{l^i \sim q(\cdot|\mathbf{x}^i, y^i)} [\log p_{\phi, \psi}(y^i|l^i, \mathbf{x}^i) + \log p_{\theta, \phi, \pi}(l^i|\mathbf{x}^i) - \log q(l^i|\mathbf{x}^i, y^i)] \\
&= \sum_{i=1}^N \sum_{l=1}^K \frac{1}{N} q(l|\mathbf{x}^i, y^i) [\log p_{\phi, \psi}(y^i|l, \mathbf{x}^i) + \log p_{\theta, \phi, \pi}(l|\mathbf{x}^i) - \log q(l|\mathbf{x}^i, y^i)] \\
&= \sum_{i=1}^N \sum_{l=1}^K \frac{1}{N} q(l|\mathbf{x}^i, y^i) \log [p_{\phi, \psi}(y^i|l, \mathbf{x}^i) p_{\theta, \phi, \pi}(l|\mathbf{x}^i)] \\
&\quad - \sum_{i=1}^N \sum_{l=1}^K \frac{1}{N} q(l|\mathbf{x}^i, y^i) \log \left[ N \frac{1}{N} q(l|\mathbf{x}^i, y^i) \right]
\end{aligned} \tag{7.9}$$

Uvedimo sada matrice  $\mathbf{P}$  i  $\mathbf{Q}$  za koje vrijedi:

$$\begin{aligned}
\mathbf{P}_{i,l} &= p_{\phi, \psi}(y^i|l, \mathbf{x}^i) p_{\theta, \phi, \pi}(l|\mathbf{x}^i) \\
\mathbf{Q}_{i,l} &= \frac{1}{N} q(l|\mathbf{x}^i, y^i)
\end{aligned} \tag{7.10}$$

Pritom član  $\frac{1}{N}$  osigurava da je matrica  $\mathbf{Q}$  ispravna matrica zajedničke vjerojatnosti. Cilj  $\frac{1}{N}\mathcal{L}_{VD}(\mathbf{\Omega}, q|\mathcal{D})$  sada možemo prikazati matričnim operacijama:

$$\begin{aligned}
\frac{1}{N} \mathcal{L}_{VD}(\mathbf{Q}, q|\mathcal{D}) &= \sum_{i=1}^N \sum_{l=1}^K \frac{1}{N} q(l|\mathbf{x}^i, y^i) \log [p_{\phi, \psi}(y^i|l, \mathbf{x}^i) p_{\theta, \phi, \pi}(l|\mathbf{x}^i)] \\
&\quad - \sum_{i=1}^N \sum_{l=1}^K \frac{1}{N} q(l|\mathbf{x}^i, y^i) \log \left[ N \frac{1}{N} q(l|\mathbf{x}^i, y^i) \right] \\
&= \sum_{i=1}^N \sum_{l=1}^K \mathbf{Q}_{i,l} \log \mathbf{P}_{i,l} - \sum_{i=1}^N \sum_{l=1}^K \mathbf{Q}_{i,l} \log [N \mathbf{Q}_{i,l}] \\
&= \sum_{i=1}^N \sum_{l=1}^K \mathbf{Q}_{i,l} \log \mathbf{P}_{i,l} - \sum_{i=1}^N \sum_{l=1}^K \mathbf{Q}_{i,l} \log \mathbf{Q}_{i,l} - \sum_{i=1}^N \sum_{l=1}^K \mathbf{Q}_{i,l} \log N \\
&= \text{tr}(\mathbf{Q}^T \log \mathbf{P}) + \text{H}(\mathbf{Q}) - \log N
\end{aligned} \tag{7.11}$$

Pri čemu  $\text{tr}$  označava operaciju traga matrice, a  $\text{H}(\mathbf{Q})$  entropiju matrice  $\mathbf{Q}$  danu jednadžbom 6.4 Član  $-\log N$  pritom možemo ignorirati jer je konstanta. Uz uvođenje regularizacijskog hiperparametra  $\lambda$  za koji vrijedi  $\lambda > 1$ , dobivamo:

$$\begin{aligned}
\frac{1}{N} \mathcal{L}_{VD}(\mathbf{Q}, q|\mathcal{D}) &= \text{tr}(\mathbf{Q}^T \log \mathbf{P}) + \text{H}(\mathbf{Q}) - \log N \\
&\geq \text{tr}(\mathbf{Q}^T \log \mathbf{P}) + \frac{1}{\lambda} \text{H}(\mathbf{Q})
\end{aligned} \tag{7.12}$$

Maksimizacija dobivenog cilja ekvivalentna je pronalasku matrice  $\mathbf{Q}$  za koju vrijedi:

$$\min_{\mathbf{Q}} \left[ -\text{tr}(\mathbf{Q}^T \log \mathbf{P}) - \frac{1}{\lambda} \text{H}(\mathbf{Q}) \right] \tag{7.13}$$

Uočimo da ovo odgovara problemu optimalnog transporta s entropijskom regularizacijom uz matricu cijena  $-\log \mathbf{P}$ . Pritom matrica  $\mathbf{Q}$  mora zadovoljavati ograničenja:

$$\begin{aligned}
\mathbf{Q} \mathbf{1}_K &= \frac{1}{N} \mathbf{1}_N \\
\mathbf{Q}^T \mathbf{1}_N &= \boldsymbol{\pi}
\end{aligned} \tag{7.14}$$

Rješenje ovog problema možemo pronaći algoritmom Sinkhorn-Knopp uz iterativno ažuriranje vektora  $\mathbf{u}$  i  $\mathbf{v}$  koristeći pravila:

$$\begin{aligned}\mathbf{u}^{(t+1)} &= \frac{\mathbf{1}_N}{N \cdot \mathbf{P}^{-\lambda} \mathbf{v}^{(t)}} \\ \mathbf{v}^{(t+1)} &= \frac{\boldsymbol{\pi}}{(\mathbf{P}^{-\lambda})^T \mathbf{u}^{(t)}}\end{aligned}\tag{7.15}$$

Konačnu matricu vjerojatnosti  $\mathbf{Q}$  tada dobivamo kao:

$$\mathbf{Q} = \text{diag}(\mathbf{u}) \mathbf{P}^{-\lambda} \text{diag}(\mathbf{v})\tag{7.16}$$

Važno je napomenuti da algoritmom Sinkhorn-Knopp dobivamo matricu vjerojatnosti  $\mathbf{Q}$  koja odgovara skupu podataka  $\mathcal{D}$ , a ne rješenje u zatvorenoj formi za distribuciju  $q(l|\mathbf{x}, y)$ . Ipak, ovo nam ne predstavlja problem jer je matrica  $\mathbf{Q}$  dovoljna za provođenje M koraka.

### 7.2.2. M korak

Cilj M koraka algoritma maksimizacije očekivanja je pronaći parametre  $\boldsymbol{\Omega}$  koji maksimiziraju donju varijacijsku granicu  $\mathcal{L}_{VD}(\boldsymbol{\Omega}, q|\mathcal{D})$  uz fiksiranu distribuciju  $q(l|\mathbf{x}, y)$  odnosno matricu vjerojatnosti  $\mathbf{Q}$ . Maksimizacija donje varijacijske granice ekvivalentna je minimizaciji cilja:

$$\begin{aligned}-\mathcal{L}_{VD}(\boldsymbol{\Omega}|\mathcal{D}) &= -\sum_{i=1}^N \mathbb{E}_{l^i \sim q(\cdot|\mathbf{x}^i, y^i)} [\log p_{\phi, \psi}(y^i|l^i, \mathbf{x}^i) + \log p_{\theta, \phi, \pi}(l^i|\mathbf{x}^i) - \log q(l^i|\mathbf{x}^i, y^i)] \\ &= \sum_{i=1}^N \sum_{l=1}^K q(l|\mathbf{x}^i, y^i) [-\log p_{\phi, \psi}(y^i|l, \mathbf{x}^i) - \log p_{\theta, \phi, \pi}(l|\mathbf{x}^i) + \log q(l|\mathbf{x}^i, y^i)] \\ &= \sum_{i=1}^N \left[ \sum_{l=1}^K -q(l|\mathbf{x}^i, y^i) \log p_{\theta, \phi, \pi}(l|\mathbf{x}^i) - \sum_{l=1}^K q(l|\mathbf{x}^i, y^i) \log p_{\phi, \psi}(y^i|l, \mathbf{x}^i) - H(q) \right] \\ &= \sum_{i=1}^N [\mathcal{L}_{CE}(p_{\theta, \phi, \pi}(l|\mathbf{x}^i), q(l|\mathbf{x}^i, y^i)) - \mathbb{E}_{l^i \sim q(\cdot|\mathbf{x}^i, y^i)} [\log p_{\phi, \psi}(y^i|l^i, \mathbf{x}^i)] - H(q)]\end{aligned}\tag{7.17}$$

Pritom  $\mathcal{L}_{CE}(p_{\theta,\phi,\pi}(l|\mathbf{x}^i), q(l|\mathbf{x}^i, y^i))$  označava funkciju gubitka unakrsne entropije između izlaza modela  $p_{\theta,\phi,\pi}(l|\mathbf{x}^i)$  i cilja  $q(l|\mathbf{x}^i, y^i)$ . Član  $H(q)$  ne ovisi o parametrima  $\mathbf{\Omega}$ , tako da ga možemo izostaviti te dobivamo konačan cilj koji želimo minimizirati:

$$\mathcal{L}_{VIBE}(\mathbf{\Omega}|\mathcal{D}) = \sum_{i=1}^N [\mathcal{L}_{CE}(p_{\theta,\phi,\pi}(l|\mathbf{x}^i), q(l|\mathbf{x}^i, y^i)) - \mathbb{E}_{l^i \sim q(\cdot|\mathbf{x}^i, y^i)} [\log p_{\phi,\psi}(y^i|l^i, \mathbf{x}^i)]] \quad (7.18)$$

Izraženi gubitak možemo minimizirati koristeći gradijentni spust, a sastoji se od dvije komponente. Prva komponenta pritom odgovara standardnom nadziranom gubitku između izlaza modela  $p_{\theta,\phi,\pi}(l|\mathbf{x}^i)$  i pseudooznaka dobivenih na temelju distribucije  $q(l|\mathbf{x}^i, y^i)$  procijenjene u E koraku. S druge strane, druga komponenta gubitka odgovara rekonstrukciji zatrovanih oznaka  $\mathbf{y}$  na temelju procijenjenih pseudooznaka  $\mathbf{l}$ .

### 7.3. Konzistencijski gubitak

Osnovna ideja konzistencijskog gubitka (engl. *consistency loss*) [26] je osigurati da model za slične ulaze daje slične izlaze. Dodavanjem ove komponente, modelu možemo povećati invarijantnost na perturbacije ulaza, kao i potencijalno spriječiti prenaučenosť. Drugim riječima, konzistencijski gubitak može služiti kao regularizacijska tehnika.

Kako bismo definirali sami gubitak, prvo je potrebno uvesti pojam slabih i jakih augmentacija. Kod uobičajenog učenja dubokih modela, većinom imamo definiran jedan skup augmentacija za učenje koji primjenjujemo na ulaze prije nego što ih damo modelu. S druge strane, kod implementacije konzistencijskog gubitka definiramo dva pogleda (engl. *view*) na ulazne podatke koristeći zasebne skupove augmentacija. Pritom skup slabih augmentacija u manjoj mjeri perturbira ulaz, a skup jakih augmentacija u većoj mjeri mijenja isti taj ulaz.

Skup jakih augmentacija lako možemo dobiti dodavanjem augmentacije AutoAugment [63] u postojeći skup slabih augmentacija. Augmentacija AutoAugment zapravo je strategija primjena niza pojedinih augmentacija specijalizirana za neki skup podataka (na primjer, za skup CIFAR-10), a određena podržanim učenjem (engl. *reinforcement learning*) [64].



Nakon što smo odredili oba pogleda ulaznih podataka, iste dajemo kao ulaz modelu. Konzistencijski gubitak tada možemo definirati kao udaljenost između izlaza modela za slabo odnosno jako augmentiran ulaz. Pritom uobičajeno koristimo mjeru poput unakrsne entropije ili KL divergencije:

$$\mathcal{L}_{con} = KL(p(y|\mathcal{A}_w(\mathbf{x}))||p(y|\mathcal{A}_s(\mathbf{x}))) \quad (7.19)$$

Pri čemu  $p(y|\mathcal{A}_w(\mathbf{x}))$  označava izlaz modela za slabu augmentaciju ulaza  $\mathcal{A}_w(\mathbf{x})$ , a  $p(y|\mathcal{A}_s(\mathbf{x}))$  označava izlaz modela za jaku augmentaciju  $\mathcal{A}_s(\mathbf{x})$ . Važno je napomenuti da kod konzistencijskog gubitka uobičajeno kao cilj tj. učitelja (engl. *teacher*) koristimo slabu augmentaciju, a kao učenika (engl. *student*) koristimo jaku augmentaciju. Sveukupni gubitak za zadani primjer  $\mathbf{x}$  tada definiramo kao:

$$\mathcal{L}_{total}(\mathbf{x}) = \mathcal{L}_{supervised}(\mathcal{A}_s(\mathbf{x})) + \sigma \mathcal{L}_{con}(\mathbf{x}) \quad (7.20)$$

Pritom hiperparametar  $\sigma$  zovemo stopom konzistencije (engl. *consistency rate*). Dodatno, uočimo da se nadzirani gubitak sada računa koristeći jaku augmentaciju ulaza  $\mathcal{A}_s(\mathbf{x})$ . Dok algoritmi SOP+ te ILL među ostalom koriste i konzistencijski gubitak, osnovna inačica okvira VIBE ga ne koristi. U našem radu, istražujemo učinak dodavanja konzistencijskog gubitka u formulaciju gubitka okvira VIBE.

Konkretno, glavna izmjena okvira VIBE je u M koraku. Dok E korak za zadani skup podataka  $\mathcal{D}$  aproksimira distribuciju  $q(l|\mathbf{x}, y)$ , M korak na temelju procijenjene distribucije optimira parametre  $\mathbf{\Omega}$  koristeći gradijentni spust. Pritom smo gubitak u M koraku definirali kao:


$$\mathcal{L}_{VIBE}(\mathbf{\Omega}|\mathcal{D}) = \sum_{i=1}^N [\mathcal{L}_{CE}(p_{\theta, \phi, \pi}(l|\mathbf{x}^i), q(l|\mathbf{x}^i, y^i)) - \mathbb{E}_{l^i \sim q(\cdot|\mathbf{x}^i, y^i)} [\log p_{\phi, \psi}(y^i|l^i, \mathbf{x}^i)]] \quad (7.21)$$

Uz korištenje jake augmentacije ulaza za izračun standardnog gubitka te dodavanje komponente konzistencijskog gubitka, konačni gubitak koji minimiziramo u M koraku proširene inačice okvira VIBE možemo definirati kao:

$$\begin{aligned} \mathcal{L}_{VIBE+CL}(\mathbf{\Omega}|\mathcal{D}) = & \sum_{i=1}^N [\mathcal{L}_{CE}(p_{\theta,\phi,\pi}(l|\mathcal{A}_S(\mathbf{x}^i)), q(l|\mathbf{x}^i, y^i)) - \mathbb{E}_{l^i \sim q(\cdot|\mathbf{x}^i, y^i)} [\log p_{\phi,\psi}(y^i|l^i, \mathbf{x}^i)]] \\ & + \sigma \sum_{i=1}^N KL(p_{\theta,\phi,\pi}(l|\mathcal{A}_W(\mathbf{x}^i)) || p_{\theta,\phi,\pi}(l|\mathcal{A}_S(\mathbf{x}^i))) \end{aligned} \quad (7.22)$$

## 7.4. Pretprocesiranje

Okvir VIBE algoritmom maksimizacije očekivanja implicitno prepravlja oznake zatrovanih primjera te ih potom koristi za učenje. Pritom učenje uspijeva jer većina napada nastoji što manje izmijeniti ulazne primjere. Ipak, napadi s čistim oznakama (engl. *clean-label attacks*) uobičajeno moraju više izmijeniti ulazne primjere kako bi uspjeli ugraditi stražnja vrata u model. Ova značajna perturbacija ulaza vidljiva je i u prostoru samonadziranih značajki: primjeri zatrovani napadom s čistim oznakama prilično su udaljeni od mnogostrukosti (engl. *manifold*) na kojoj leže čisti podatci. Kako bi iskoristili ovu činjenicu, okvir VIBE uključuje korak pretprocesiranja čiji je cilj ukloniti primjere zatrovane napadom s čistim oznakama.



**Slika 7.2.** Prikaz koraka pretprocesiranja okvira VIBE. Primjeri zatrovani napadom s čistim oznakama (lijevo, crvena boja) podudaraju se s primjerima detektiranim tijekom koraka pretprocesiranja (desno, zelena boja). Visokodimenzionalne značajke ulaznih primjera projicirane su u 2-dimenzionalni prostor koristeći algoritam UMAP [65]. Preuzeto iz [10].

Konkretno, korak pretprocesiranja promatra mnogostrukost podataka u prostoru samonadziranih značajki te zatrovane primjere identificira kao najudaljeniju zajednicu. Kako bi ovo postigli, prvo konstruiramo graf  $k$  najbližih susjeda predstavljen matricom susjedstva  $\mathbf{A}_k$ . Potom koristimo Leidenov algoritam [66] kako bismo podijelili graf najbližih susjeda  $\mathbf{A}_k$  na  $K + 1$  zajednicu. Za svaku detektiranu zajednicu zatim računamo prosječnu udaljenost do preostalih  $K$  zajednica te izdvajamo zajednicu s najvećom prosječnom udaljenosti. Ako je prosječna udaljenost te zajednice veća od zadanog praga  $\delta$ , iz skupa podataka  $\mathcal{D}$  uklanjamo primjere koji joj pripadaju.

U slučaju da je skup podataka  $\mathcal{D}$  zatrovan napadom s čistim oznakama, najudaljenija zajednica odgovarat će zatrovanim primjerima. S druge strane, ako skup  $\mathcal{D}$  nije zatrovan, najudaljenija zajednica će obuhvaćati nekolicinu čistih primjera koji odstupaju od mnogostrukosti podataka. Ipak, prosječna udaljenost najudaljenije zajednice u ovom slučaju bit će manja od praga  $\delta$  pa stoga ti primjeri neće biti odbačeni. Štoviše, čak i ako je prag  $\delta$  loše odabran pa zbog toga odbacimo nekolicinu čistih primjera, naučeni model će podjednako dobro generalizirati [10].

## 8. Duboki konvolucijski modeli

Arhitektura LeNet-5 [67] predstavlja jedan od prvih dubokih konvolucijskih modela [68], a dizajnirana je s ciljem klasifikacije ručno pisanih znamenki iz skupa podataka MNIST [25]. Ipak, duboki konvolucijski modeli postali su popularni tek razvojem duboke arhitekture AlexNet [69] koja je 2012. godine pobijedila na natjecanju ImageNet ILSVRC [70] te time pokazala potencijal konvolucijskih mreža.

Pod duboki konvolucijski model općenito mislimo na model koji sadrži barem jedan konvolucijski sloj. Osim konvolucijskih slojeva (engl. *convolutional layer*), duboki modeli uobičajeno sadrže i slojeve sažimanja (engl. *pooling layer*) [71], aktivacijske funkcije poput funkcije zglobnice (engl. *rectified linear unit* - ReLU), slojeve normalizacije nad grupom (engl. *batch normalization layer*) [72] te potpuno-povezane slojeve (engl. *fully-connected layer*).

### 8.1. Konvolucijski sloj

Konvolucijski sloj dubokih modela zasniva se na operaciji konvolucije. Konvoluciju možemo definirati kao integral umnoška dviju funkcija, pri čemu je jedna reflektirana i posmaknuta:

$$(f * g)(t) = \int_{-\infty}^{\infty} f(\tau)g(t - \tau)d\tau \quad (8.1)$$


U dubokom učenju, pod konvolucijom najčešće mislimo na operaciju unakrsne korelacije (engl. *cross-correlation*) kod koje izostavljamo reflektiranje jedne od funkcija:

$$(f \star g)(t) = \int_{-\infty}^{\infty} f(\tau)g(t + \tau)d\tau \quad (8.2)$$

Operacija konvolucije izvrsna je za primjenu na podacima rešetkaste strukture. Kako bismo ju mogli primijeniti na slike, izlaz operacije 2-dimenzionalne konvolucije definiramo kao:

$$Y_{i,j} = (X * W)_{i,j} = \sum_{m=0}^{M-1} \sum_{n=0}^{N-1} X_{i+m,j+n} W_{m,n} \quad (8.3)$$

Pritom  $X$  predstavlja ulaznu sliku, a  $Y$  rezultat primjene 2-dimenzionalne konvolucije s jezgrom  $W$  dimenzija  $M \times N$ . Uočimo da ovdje zapravo primjenjujemo operaciju unakrsne korelacije. Jezgra  $W$  predstavlja parametre koje možemo učiti gradijentnim spustom, a uobičajeno je kvadratnog oblika (na primjer, dimenzija  $3 \times 3$ ).



**Slika 8.1.** Prikaz primjene konvolucije uz jezgru veličine  $3 \times 3$ , korak iznosa 2 te nadopunjavanje iznosa 1. Nakon operacije konvolucije, na izlaz se dodatno primjenjuje operacija sažimanja maksimumom uz jezgru veličine  $2 \times 2$ . Preuzeto iz [68].

Osim veličine jezgre  $K$ , neki od hiperparametara konvolucijskih slojeva su korak (engl. *stride*)  $s$  te nadopunjavanje (engl. *padding*)  $p$ . Pritom korak određuje za koliko se elemenata horizontalno odnosno vertikalno jezgra  $W$  pomiče dok klizi po ulazu  $X$ . S druge strane, nadopunjavanjem možemo izbjeći smanjenje dimenzija izlaza naspram ulaza. Konkretno, primjenom jezgre veličine  $K \times K$  uz korak iznosa  $s$  na sliku dimenzija  $H_{in} \times W_{in}$  s nadopunjavanjem iznosa  $p$  dobivamo izlaz dimenzija:

$$\begin{aligned} H_{out} &= \lfloor \frac{H_{in} + 2p - K}{s} \rfloor + 1 \\ W_{out} &= \lfloor \frac{W_{in} + 2p - K}{s} \rfloor + 1 \end{aligned} \quad (8.4)$$

Ulaz i izlaz konvolucijskog sloja obično su dimenzija  $C_{in} \times H_{in} \times W_{in}$  odnosno  $C_{out} \times H_{out} \times W_{out}$ . Pritom  $C_{in}$  i  $C_{out}$  označavaju broj kanala ulaza odnosno izlaza. Parametri zadanog sloja tada su dimenzija  $C_{out} \times C_{in} \times K \times K$ . Ovo možemo zamisliti kao  $C_{out}$  zasebnih jezgara (po jedna za svaki kanal izlaza) pri čemu je svaka jezgra dimenzija  $C_{in} \times K \times K$ . Jedan kanal izlaza tada dobivamo kao:

$$\mathbf{Y}^{(d)} = \sum_{c=1}^{C_{in}} \mathbf{X}^{(c)} * \mathbf{W}^{(d,c)} \quad (8.5)$$

Pritom  $\mathbf{X}^{(c)}$  označava  $c$ -ti kanal ulaza  $\mathbf{X}$ , a  $\mathbf{W}^{(d,c)}$   $c$ -ti kanal  $d$ -te jezgre koja odgovara  $d$ -tom kanalu izlaza  $\mathbf{Y}^{(d)}$ .

Sloj sažimanja funkcionira slično konvolucijskom sloju. Kao i kod konvolucije, i ovdje klizimo po ulazu te dobivamo okna dimenzija  $K \times K$ . Pritom je korak najčešće jednak dimenzijama okna. Za razliku od konvolucijskog sloja, kod sloja sažimanja općenito ne postoji parametrizirana jezgra  $\mathbf{W}$ , već na svako okno primjenjujemo zadanu operaciju (na primjer, operaciju traženja maksimalne vrijednosti). Dodatno, sloj sažimanja se na svaki kanal ulaza primjenjuje zasebno tj. nema interakcije između različitih kanala.

## 8.2. Sloj normalizacije nad grupom

Osnovna ideja normalizacije nad grupom je da normalizacijom svake značajke zasebno možemo osigurati konzistentnu distribuciju ulaza u daljnji sloj modela. Idealno, normalizacija bi se provodila koristeći cijeli skup podataka  $\mathcal{D}$ , no ovo zbog memorijskih zahtjeva najčešće nije moguće. Umjesto toga, ideja je normalizaciju provoditi na razini mini-grupe  $\mathcal{B}$ . Dodavanje slojeva normalizacije nad grupom u proizvoljni model može ubrzati konvergenciju, stabilizirati učenje te dopustiti učenje s višom stopom učenja (engl. *learning rate*) [72].

Neka je  $\mathbf{x}_i$  i-ti vektor značajki iz minigrupe  $\mathcal{B}$  koja sadrži  $N$  vektora. Kako bismo mogli normalizirati značajke, prvo moramo izračunati procjene vektora srednjih vrijednosti  $\boldsymbol{\mu}_{\mathcal{B}}$  i varijanci  $\sigma_{\mathcal{B}}^2$  na temelju trenutne minigrupe:

$$\begin{aligned}\boldsymbol{\mu}_{\mathcal{B}} &= \frac{1}{N} \sum_{i=1}^N \mathbf{x}_i \\ \sigma_{\mathcal{B}}^2 &= \frac{1}{N} \sum_{i=1}^N (\mathbf{x}_i - \boldsymbol{\mu}_{\mathcal{B}})^2\end{aligned}\tag{8.6}$$

Normaliziranu k-tu značajku  $\hat{x}_i^{(k)}$  i-tog vektora značajki  $\mathbf{x}_i$  definiramo jednadžbom:

$$\hat{x}_i^{(k)} = \frac{x_i^{(k)} - \mu_{\mathcal{B}}^{(k)}}{\sqrt{(\sigma_{\mathcal{B}}^{(k)})^2 + \epsilon}}\tag{8.7}$$

Pritom je  $\epsilon$  konstanta malog iznosa koju dodajemo zbog numeričke stabilnosti. Kako bismo povećali ekspresivnost, normalizirane značajke dodatno transformiramo:

$$y_i^{(k)} = \gamma^{(k)} \hat{x}_i^{(k)} + \beta^{(k)}\tag{8.8}$$

Pri čemu je  $y_i^{(k)}$  k-ta značajka i-tog izlaza  $\mathbf{y}_i$  iz sloja normalizacije nad grupom, a  $\boldsymbol{\gamma}$  i  $\boldsymbol{\beta}$  su vektori parametara linearne transformacije koje učimo. Kako bi sloj normalizacije nad grupom radio ispravno, potrebno je koristiti dovoljno velike minigrupe.

Opisani postupak koristi se tijekom učenja modela. Nakon što smo naučili i upogonili model, primjeri mu najčešće dolaze jedan po jedan (engl. *online*). Kako bi se nosili s ovom situacijom, sloj normalizacije nad grupom definira još jedan režim rada. Konkretno, kada model koristimo za evaluaciju, više ne računamo statistike  $\boldsymbol{\mu}_{\mathcal{B}}$  i  $\sigma_{\mathcal{B}}^2$ . Umjesto toga, za normalizaciju koristimo pomične prosjeke izračunatih statistika  $\hat{\boldsymbol{\mu}}$  i  $\hat{\sigma}^2$ . Alternativno, možemo koristiti i statistike izračunate za cijeli skup za učenje  $\mathcal{D}$ .

### 8.3. Rezidualni modeli

Prije uvođenja rezidualnih blokova [73], duboki konvolucijski modeli bili su ograničeni dubinom. Konkretno, korištenje više od otprilike 20 slojeva vodilo je do pogoršanja performansi modela [73]. Jedan od razloga ovome je činjenica da kod modela s velikim brojem slojeva gradijent teško propagira do početnih slojeva. Pritom može doći do problema nestajućih ili eksplodirajućih gradijenata (engl. *vanishing/exploding gradients*).


Neka je  $\mathbf{x}$  ulaz u sloj  $l$ . Kod modela bez rezidualnih blokova, sloj  $l$  treba modelirati preslikavanje  $H(\mathbf{x})$ . Osnovna ideja uvođenja rezidualnih blokova je reformulacija danog problema. Umjesto direktnog modeliranja funkcije  $H(\mathbf{x})$ , cilj postaje modelirati razliku između očekivanog izlaza  $H(\mathbf{x})$  i danog ulaza  $\mathbf{x}$ . Ovu razliku zovemo rezidual i označavamo s  $F(\mathbf{x})$ . Izlaz rezidualnog bloka tada postaje:

$$H(\mathbf{x}) = F(\mathbf{x}) + P(\mathbf{x}) \quad (8.9)$$

Pritom  $P(\mathbf{x})$  označava projekciju ulaza  $\mathbf{x}$  kako bi se isti mogao zbrojiti s rezidualom  $F(\mathbf{x})$ , a  $H(\mathbf{x})$  označava izlaz rezidualnog bloka. Dakle, rezidualni blok sastoji se od reziduala  $F(\mathbf{x})$  te preskočne veze  $P(\mathbf{x})$  (engl. *skip connection*). Rezidual  $F(\mathbf{x})$  uobičajeno je modeliran nizom od nekoliko konvolucijskih slojeva u kombinaciji s nelinearnim aktivacijama i slojevima normalizacije nad grupom.

Kada govorimo o rezidualnim blokovima, važno je istaknuti razliku između osnovne inačice i predaktivacijske (engl. *pre-act*) inačice [74]. Konkretno, dok osnovna inačica koristi slijed slojeva Conv  $\rightarrow$  BatchNorm  $\rightarrow$  ReLU, predaktivacijska inačica koristi slijed slojeva BatchNorm  $\rightarrow$  ReLU  $\rightarrow$  Conv. Osim ovoga, osnovna inačica na zbroj reziduala  $F(\mathbf{x})$  i projekcije ulaza  $P(\mathbf{x})$  dodatno primjenjuje nelinearnu aktivaciju. Predaktivacijska inačica uklanja konačnu primjenu nelinearne aktivacije kako bi se dodatno pospješio tok gradijenata [74].





**Slika 8.2.** Prikaz osnovne inačice (lijevo) i predaktivacijske inačice (desno) rezidualnog bloka. Rezidual  $F(x)$  označen je iscrtkanom linijom.

Kod jednostavnih problema, već prvih nekoliko slojeva dubokog modela ima dovoljan kapacitet za modelirati potrebno rješenje. Ako naša arhitektura ne koristi rezidualne blokove, svi daljnji slojevi bi trebali modelirati funkciju identiteta. S druge strane, ako koristimo rezidualne blokove, težine svih daljnjih slojeva trebale bi konvergirati u vrijednost 0. Pokazuje se da je učenje "ugašenih" blokova značajno lakši problem od učenja funkcije identiteta [73]. Zbog ovoga, korištenje rezidualnih blokova nam omogućava dizajn arhitektura s velikim brojem slojeva.

Obitelj arhitektura ResNet [73] jedna je od najpoznatijih obitelji arhitektura baziranih na korištenju rezidualnih blokova. Pritom su najčešće korištene arhitekture s 18, 34, 50, 101 ili 152 sloja, ali postoje i još dublje inačice poput arhitekture ResNet-200. U okviru našeg rada, fokusiramo se na arhitekturu ResNet-18 koja se sastoji od 17 konvolucijskih slojeva i 1 potpuno-povezanog sloja.


## 9. Skupovi podataka

U okviru našeg rada, koristili smo nekoliko zatrovanih odnosno zašumljenih inačica skupa podataka CIFAR-10 [24].

### 9.1. CIFAR-10

Skup podataka CIFAR-10 jedan je od najčešće korištenih skupova za učenje i evaluaciju različitih algoritama i modela dubokog učenja, a nastao je označavanjem podskupa skupa slika Tiny Images [24]. Podijeljen je na 50000 primjera u skupu za učenje i 10000 primjera u skupu za ispitivanje.

Svaka slika je u boji, a dimenzije svih slika su  $32 \times 32$ . Pojedine slike mogu pripadati jednom od 10 razreda. Pritom su razredi isključivi tj. ne postoje preklapanja. Skup za učenje sadrži po 5000 slika iz svakog razreda, a skup za ispitivanje sadrži po 1000 slika iz svakog razreda. Drugim riječima, oba podskupa su balansirana.



**Slika 9.1.** Prikaz po jedne slike za svaki razred iz skupa podataka CIFAR-10.

## 10. Eksperimenti

Eksperimente koje smo provodili u okviru našeg rada možemo podijeliti na dvije cjeline: eksperimenti sa zašumljenim oznakama te eksperimenti s napadima umetanjem stražnjih vrata.

### 10.1. Zašumljene oznake

Eksperimente sa zašumljenim oznakama provodili smo na zašumljenim inačicama skupa CIFAR-10. Pritom smo koristili inkluzivno simetrično zašumljivanje uz stopu šuma iznosa 20%, 50% te 80%, kao i asimetrično zašumljivanje uz stopu šuma iznosa 40%. Za svaku kombinaciju metode zašumljivanja i stope šuma, stvorili smo jednu inačicu zašumljenog skupa CIFAR-10. Dodatno, različite pristupe smo evaluirali i pri učenju na čistom skupu CIFAR-10. U svim eksperimentima, učili smo model arhitekture ResNet-18. Ključna mjera dobrote za eksperimente sa zašumljenim oznakama je točnost na čistom skupu za ispitivanje.

Općenito uspoređujemo pet pristupa: nadzirano učenje (engl. *cross-entropy* - CE), nadzirano učenje s konzistencijskim gubitkom (engl. *cross-entropy with consistency loss* - CE + CL), nadogradnju algoritma *Sparse over-parameterization* (SOP+), algoritam *Imprecise label learning* (ILL) te okvir *Variational inference for backdoor elimination* s dodanim konzistencijskim gubitkom (VIBE).

Kod nadziranog učenja odnosno nadziranog učenja s konzistencijskim gubitkom, nasumično inicijalizirani model smo učili 300 epoha uz optimizator SGD s početnom stopom učenja iznosa 0.05. Pritom smo koristili moment (engl. *momentum*) [75] iznosa 0.9, kao i propadanje težina (engl. *weight decay*) [76] iznosa  $5 \cdot 10^{-4}$ . Kako bi se stopa učenja kroz vrijeme smanjivala, koristili smo višekoračnu strategiju (engl. *multistep scheduler*)

uz hiperparametar  $\gamma$  iznosa 0.1 te smanjivanje stope učenja pri dostizanju 150. odnosno 180. epohe. Skup podataka bio je podijeljen na minigrupe veličine 128. U slučaju nadziranog učenja s konzistencijskim gubitkom, koristili smo konstantnu stopu konzistencije iznosa 1. Jake augmentacije uključuju slabe augmentacije, augmentaciju AutoAugment te augmentaciju nasumičnog brisanja (engl. *random erasing*) [77]. Dodatno, kod nadziranog učenja s konzistencijskim gubitkom model učimo 300 epoha na čistom skupu odnosno 200 epoha na zašumljenim skupovima. Ovo je ujedno i jedini hiperparametar čiji iznos ne fiksiramo na jednu vrijednost za sve eksperimente.

U slučaju algoritma SOP+, hiperparametri odgovaraju onima iz originalnog rada [8], ali uz korištenje arhitekture ResNet-18 umjesto arhitekture predaktivacijskog ResNet-18. Nasumično inicijalizirani model učili smo 300 epoha uz optimizator SGD s početnom stopom učenja iznosa 0.02. Koristili smo moment iznosa 0.9 te propadanje težina iznosa  $5 \cdot 10^{-4}$ . Umjesto višekoračne strategije, ovdje smo koristili strategiju kosinusnog kaljenja (engl. *cosine annealing scheduler*) bez restarta te uz minimalnu stopu učenja iznosa  $2 \cdot 10^{-4}$ . Skup podataka ponovno je podijeljen na minigrupe veličine 128. Vektore parametara  $\{\mathbf{u}_i, \mathbf{v}_i\}_{i=1}^N$  inicijalizirali smo nasumično iz normalne distribucije sa srednjom vrijednošću iznosa 0 te standardnom devijacijom iznosa  $1 \cdot 10^{-8}$ , a učili smo ih uz optimizator SGD sa stopom učenja iznosa 1 te faktorom skaliranja stope učenja iznosa 10. Pritom za optimizator vektora  $\{\mathbf{u}_i, \mathbf{v}_i\}_{i=1}^N$  nismo koristili moment ni propadanje težina. Koristili smo konstantnu stopu konzistencije iznosa 0.9, kao i konstantnu stopu ravnoteže razreda iznosa 0.1. Jake augmentacije kod algoritma SOP+ uključuju slabe augmentacije, augmentaciju AutoAugment te augmentaciju izrezivanja (engl. *cutout*) [78].

Kod algoritma ILL, hiperparametri ponovno odgovaraju onima iz originalnog rada [9], ali uz korištenje arhitekture ResNet-18 umjesto arhitekture predaktivacijskog ResNet-18. Kao i kod algoritma SOP+, nasumično inicijalizirani model smo učili 300 epoha uz optimizator SGD s početnom stopom učenja iznosa 0.02. Pritom smo koristili moment iznosa 0.9, ali i propadanje težina iznosa  $1 \cdot 10^{-3}$  te propadanje slojeva (engl. *layer decay*) [79] iznosa 1. Za smanjivanje stope učenja, koristili smo strategiju kosinusnog kaljenja bez restarta te uz minimalnu stopu učenja iznosa  $2 \cdot 10^{-4}$ . Skup podataka ponovno je bio podijeljen na minigrupe veličine 128. Koristili smo konstantnu stopu konzistencije iznosa 1. Jake augmentacije kod algoritma ILL uključuju slabe augmentacije, augmentaciju Auto-

Augment te augmentaciju nasumičnog brisanja.

Konačno, kod okvira VIBE s dodanim konzistencijskim gubitkom, model inicijaliziran okvirom All4One smo učili 30000 iteracija (približno 77 epoha) uz optimizator SGD s početnom stopom učenja iznosa 0.01. Koristili smo moment iznosa 0.9, kao i propadanje težina iznosa  $5 \cdot 10^{-4}$ . Kao i kod algoritama SOP+ te ILL, koristili smo strategiju kosinusnog kaljenja bez restarta, ali uz minimalnu stopu učenja iznosa 0. Skup podataka bio je podijeljen na minigrupe veličine 256. Hiperparametar raspršenosti von Mises-Fisherove distribucije  $\kappa$  postavili smo na iznos 10, jednako kao i hiperparametar temperature  $\nu$  korišten pri izračunu distribucije  $p(y|l)$ . Pojedine vektore iz skupa čistih prototipova  $\phi$  odnosno skupa zašumljenih prototipova  $\psi$  inicijalizirali smo kao centroide pripadnih razreda. Parametre  $\hat{\pi}$  inicijalizirali smo nasumično iz jedinične normalne distribucije. Hiperparametar temperature  $c$  korišten za izračun koeficijenata miješanja  $\pi$  postavili smo na iznos 0.02. E korak učenja provodili smo svakih 1000 iteracija, pritom koristeći Sinkhorn-Knopp algoritam uz regularizacijski hiperparametar  $\lambda$  iznosa 25 te maksimalan broj iteracija iznosa 10000. Koristili smo konstantnu stopu konzistencije iznosa 5. Kao i kod nadziranog učenja s konzistencijskim gubitkom te algoritma ILL, jake augmentacije uključuju slabe augmentacije, augmentaciju AutoAugment te augmentaciju nasumičnog brisanja.

Ako za pojedini eksperiment nisu eksplicitno navedene vrijednosti određenih hiperparametara, u pitanju su upravo opisane vrijednosti. Na primjer, ako za određeni eksperiment učenja okvirom VIBE ne istaknemo korištenu veličinu minigrupe, podrazumijevamo već navedenu veličinu 256.

### 10.1.1. Usporedba sa stanjem tehnike

Prije svega, pogledajmo kako se različiti opisani algoritmi ponašaju pri učenju na čistim podacima. U tablici 10.1., stupac *Algoritam* predstavlja algoritam korišten za učenje modela na čistom skupu CIFAR-10. Stupac *Točnost [%]* predstavlja točnost naučenog modela na čistom skupu za ispitivanje skupa CIFAR-10. Najbolji rezultat je podebljan.

Tablica 10.1. Točnost modela učenih na čistom skupu CIFAR-10.

| Algoritam | Točnost [%]  |
|-----------|--------------|
| CE        | 95.30        |
| CE + CL   | 96.30        |
| SOP+      | 96.70        |
| ILL       | <b>96.75</b> |
| VIBE      | 96.10        |

Kao što možemo vidjeti, algoritam ILL postiže najvišu točnost pri učenju na čistom skupu CIFAR-10. Algoritam SOP+ postiže podjednaku točnost kao i algoritam ILL, dok okvir VIBE postiže za 0.65% nižu točnost. Usporedbom redaka CE i CE + CL, vidimo da dodavanje konzistencijskog gubitka povećava točnost nadziranog učenja za 1%. Zanimljivo je da algoritmi ILL te SOP+ postižu bolju točnost čak i od nadziranog učenja s konzistencijskim gubitkom. S druge strane, okvir VIBE postiže neznatno nižu točnost u usporedbi s nadziranim učenjem s konzistencijskim gubitkom.

Pogledajmo sada točnost različitih modela pri učenju na podacima sa simetrično zašumljenim oznakama. U tablici 10.2., stupac *Algoritam* predstavlja algoritam korišten za učenje modela na skupu CIFAR-10 sa simetrično zašumljenim oznakama. Znak \* prije imena algoritma označava rezultat preuzet iz originalnog rada pripadnog algoritma, dok manjak znaka označava reprodukciju rezultata na temelju originalnog repozitorija algoritma. Svaki stupac iz grupe stupaca *Stopa šuma [%]* odgovara jednoj zašumljenoj inačici skupa CIFAR-10 uz zadanu stopu šuma. Pojedine vrijednosti u tablici predstavljaju točnost odgovarajućeg modela na čistom skupu za ispitivanje skupa CIFAR-10. Najbolji rezultat za svaku zašumljenu inačicu skupa je podebljan. Vrijednosti preuzete iz originalnih radova nisu uzete u obzir pri označavanju najboljih rezultata.

Tablica 10.2. Točnost modela učenih na simetrično zašumljenim inačicama skupa CIFAR-10.

| Algoritam | Stopa šuma [%] |              |              |
|-----------|----------------|--------------|--------------|
|           | 20             | 50           | 80           |
| CE        | 83.80          | 57.20        | 27.30        |
| CE + CL   | 95.40          | 91.70        | 76.20        |
| SOP+      | <b>96.26</b>   | 95.58        | 93.11        |
| *SOP+     | 96.30          | 95.50        | 94.00        |
| ILL       | 96.22          | <b>95.67</b> | 93.75        |
| *ILL      | 96.78          | 96.60        | 94.31        |
| VIBE      | 95.70          | 94.80        | <b>94.40</b> |

Vidimo da za različite stope šuma različiti algoritmi postižu najvišu točnost. Konkretno, uz stopu šuma iznosa 20%, algoritam SOP+ postiže najvišu točnost. Algoritam ILL podjednake je točnosti, dok okvir VIBE postiže za 0.56% nižu točnost. Iako se nadzirano učenje pokazuje kao najlošije u ovom postavu, zanimljivo je da dodavanjem konzistencijskog gubitka možemo postići točnost za samo 0.86% nižu u usporedbi sa stanjem tehnike. Drugim riječima, iako standardno nadzirano učenje ne postiže visoku točnost pri učenju na skupu sa zašumljenim oznakama, jednostavnim dodavanjem konzistencijskog gubitka možemo drastično povećati točnost naučenog modela.

Uz stopu šuma iznosa 40%, algoritam ILL postiže najvišu točnost. Algoritam SOP+ u ovom slučaju je podjednake točnosti, dok okvir VIBE postiže za 0.87% nižu točnost. U usporedbi sa stanjem tehnike, ovaj postav predstavlja najgori slučaj za okvir VIBE. Dok standardno nadzirano učenje ovdje postiže nisku točnost iznosa 57.20%, dodavanjem konzistencijskog gubitka istu možemo povećati na 91.70%. Kada govorimo o postavu sa stopom šuma iznosa 80%, okvir VIBE postiže najvišu točnost. Pritom je točnost VIBE-a za 1.29% viša u odnosu na algoritam SOP+, odnosno za 0.65% viša u odnosu na algoritam ILL. Kod ovog postava, nadzirano učenje postiže veoma nisku točnost iznosa 27.30%. Iako dodavanjem konzistencijskog gubitka točnost možemo povećati za čak 48.90%, ovaj rezultat je i dalje značajno lošiji od rezultata okvira VIBE. Zanimljivo je da rezultati stanja tehnike za ovaj postav odudaraju od rezultata iz originalnih radova za 0.89% u slučaju algoritma SOP+, odnosno za 0.56% u slučaju algoritma ILL.

Uočimo da povećavanjem stope šuma s 20% na 80% kod okvira VIBE gubimo samo 1.3% točnosti, dok kod algoritama SOP+ te ILL gubimo 3.15% odnosno 2.47% točnosti. Robusnost okvira VIBE na povećanje stope šuma, kao i postizanje najboljih performansi u usporedbi sa stanjem tehnike pri visokoj stopi šuma, potencijalno su posljedica samonadzirane inicijalizacije parametara modela korištenjem okvira All4One. Konkretno, samonadzirana inicijalizacija parametara mogla bi povećati važnost semantike slika u usporedbi s važnošću pridijeljenih oznaka te time doprinijeti učenju modela robusnog na zašumljene oznake.

Pogledajmo još i točnost različitih modela pri učenju na podacima s asimetrično zašumljenim oznakama. U tablici 10.3., stupac *Algoritam* predstavlja algoritam korišten za učenje modela na skupu CIFAR-10 s asimetrično zašumljenim oznakama i stopom

šuma iznosa 40%. Kao i prije, stupac *Točnost [%]* predstavlja točnost naučenog modela na čistom skupu za ispitivanje skupa CIFAR-10, a najbolji rezultat je podebljan.

Tablica 10.3. Točnost modela učenih na asimetrično zašumljenom skupu CIFAR-10.

| Algoritam | Točnost [%]  |
|-----------|--------------|
| CE        | 76.80        |
| CE + CL   | 92.20        |
| SOP+      | 93.74        |
| *SOP+     | 93.80        |
| ILL       | 85.75        |
| *ILL      | 94.75        |
| VIBE      | <b>95.10</b> |

Vidimo da u ovom slučaju okvir VIBE postiže najvišu točnost. Pritom je točnost okvira VIBE za 1.36% viša u odnosu na algoritam SOP+, odnosno za 9.35% viša u odnosu na algoritam ILL. Točnost algoritma ILL ovdje drastično odstupa od točnosti navedene u originalnom radu. Kroz naše eksperimente, zaključili smo da je algoritam ILL nestabilan u teškim postavima - različita pokretanja učenja mogu rezultirati modelima s veoma različitim performansama. Dodatno, vidimo da i u ovom slučaju dodavanje konzistencijskog gubitka nadziranom učenju značajno povećava točnost. Konkretno, ovdje postićemo povećanje točnosti iznosa 15.4%. Dobiveni rezultati sugeriraju da bismo problem zašumljenih oznaka mogli riješiti fino podešenim nadziranim učenjem s konzistencijskim gubitkom.

Općenito, možemo vidjeti da je asimetrično zašumljivanje oznaka teži problem od simetričnog zašumljivanja. Nažalost, ovo je često i realističniji model. Na primjer, u slučaju označavanja skupa MNIST, anotatori mogu imati problema s razlikovanjem znamenki 1 i 7, ali ne i s razlikovanjem znamenki 1 i 0 ili znamenki 1 i 8. Drugim riječima, u stvarnosti do zašumljivanja najčešće dolazi zbog sistematskih pogrešaka anotatora, a ovo više odgovara modelu asimetričnog zašumljivanja oznaka.

Dok algoritmi SOP+ i ILL postižu najbolje performanse u postavima sa simetričnim zašumljivanjem i niskom stopom šuma, okvir VIBE postiže najbolje performanse u teškim postavima tj. pri simetričnom zašumljivanju uz stopu šuma iznosa 80%, kao i pri asimetričnom zašumljivanju uz stopu šuma iznosa 40%. Dodatno, dodavanjem konzistencijskog gubitka nadziranom učenju u većini slučajeva možemo postići rezultate veoma bliske onima algoritama za učenje na podacima sa zašumljenim oznakama.



### 10.1.2. Validacija hiperparametara

Pogledajmo kako smo od početne konfiguracije hiperparametara za okvir VIBE došli do konfiguracije koju smo koristili pri usporedbi sa stanjem tehnike. Za razliku od konačne konfiguracije koja koristi stopu učenja iznosa 0.01, početna konfiguracija koristi stopu učenja iznosa  $1 \cdot 10^{-3}$ . Dodatno, početna konfiguracija ne uključuje nijednu strategiju izmjene stope učenja, kao ni konzistencijski gubitak.

Izmjene hiperparametara prije svega smo validirali učenjem modela na skupu CIFAR-10 sa simetrično zašumljenim oznakama i stopom šuma iznosa 20%. Dodatno, kako bismo provjerili robusnost određenih izmjena, provodili smo i popratne eksperimente učenja na skupu CIFAR-10 s asimetrično zašumljenim oznakama i stopom šuma iznosa 40%. Ako u postavu za određeni eksperiment nije eksplicitno navedena metoda zašumljivanja, u pitanju je simetrično zašumljivanje uz stopu šuma iznosa 20%. U oba slučaja, ključna mjera dobrote je točnost na čistom skupu za ispitivanje skupa CIFAR-10.

Prije svega, pogledajmo kako se točnost modela učenih okvirom VIBE mijenja ovisno o broju iteracija učenja te iznosu stope učenja. U tablici 10.4., stupac *Broj iteracija* predstavlja broj iteracija učenja modela, dok stupci iz grupe *Stopa učenja* označavaju različite korištene stope učenja. Pojedine vrijednosti u tablici predstavljaju točnost odgovarajućeg modela na čistom skupu za ispitivanje skupa CIFAR-10, a najbolji rezultat je podebljan.

Tablica 10.4. Točnost modela učenih okvirom VIBE ovisno o broju iteracija te stopi učenja.

| Broj iteracija | Stopa učenja |       |      |
|----------------|--------------|-------|------|
|                | 0.001        | 0.005 | 0.01 |
| 15000          | <b>93.6</b>  | 93.3  | 93.1 |
| 30000          | 93.4         | 93.3  | 91.9 |
| 45000          | 91.6         | 93.2  | 91.6 |

Kao što možemo vidjeti, model učen 15000 iteracija uz stopu učenja iznosa  $1 \cdot 10^{-3}$  postiže najvišu točnost. Dok učenje 15000 odnosno 30000 iteracija vodi do približno podjednakih rezultata, učenje 45000 iteracija rezultira modelima s najnižom točnošću. Drugim riječima, dolazi do prenaučenosti modela. Zbog ovoga, u sljedećim eksperimentima više nećemo razmatrati učenje 45000 iteracija. Dodatno, možemo uočiti da povećanje stope učenja općenito smanjuje konačnu točnost naučenog modela.

Dodavanje komponente konzistencijskog gubitka trebalo bi povećati točnost modela. Za izračun konzistencijskog gubitka, koristili smo KL divergenciju između izlaza modela za slabo odnosno jako augmentirane ulaze. Pritom jake augmentacije uključuju slabe augmentacije te augmentaciju AutoAugment, a stopa konzistencije je postavljena na iznos 1. Pogledajmo kako se točnost modela učenih okvirom VIBE s konzistencijskim gubitkom mijenja ovisno o broju iteracija učenja te iznosu stope učenja.

Tablica 10.5. Točnost modela učenih okvirom VIBE s konzistencijskim gubitkom ovisno o broju iteracija te stopi učenja.

| Broj iteracija | Stopa učenja |             |      |
|----------------|--------------|-------------|------|
|                | 0.001        | 0.005       | 0.01 |
| 15000          | 93.4         | <b>94.8</b> | 94.4 |
| 30000          | 94.1         | 94.2        | 92.9 |

Vidimo da model učen 15000 iteracija uz stopu učenja iznosa  $5 \cdot 10^{-3}$  postiže najvišu točnost. Pritom dobiveni model postiže točnost za 1.2% višu od točnosti najboljeg modela učenog okvirom VIBE bez konzistencijskog gubitka. Općenito, pokazuje se da dodavanje komponente konzistencijskog gubitka povećava konačnu točnost naučenog modela za skoro sve konfiguracije broja iteracija te stope učenja. U sljedećim eksperimentima, podrazumijevamo učenje okvirom VIBE s konzistencijskim gubitkom i stopom konzistencije iznosa 1.

Osim KL divergencije, za izračun konzistencijskog gubitka možemo koristiti i unakrsnu entropiju. U tablici 10.6., stupac *Mjera udaljenosti* predstavlja mjeru udaljenosti korištenu za izračun konzistencijskog gubitka. Pritom vrijednost *KL* označava KL divergenciju, a vrijednost *CE* označava unakrsnu entropiju. Broj iteracija fiksirali smo na 30000, a stopu učenja variramo.

Tablica 10.6. Točnost modela učenih okvirom VIBE s konzistencijskim gubitkom izračunatim koristeći KL divergenciju odnosno unakrsnu entropiju.

| Mjera udaljenosti | Stopa učenja |             |      |
|-------------------|--------------|-------------|------|
|                   | 0.001        | 0.005       | 0.01 |
| KL                | 94.1         | <b>94.2</b> | 92.9 |
| CE                | 94.1         | <b>94.2</b> | 92.7 |

Kao što možemo vidjeti, korištenje obje mjere udaljenosti rezultira podjednako točnošću. Ovaj rezultat je i očekivan jer KL divergenciju možemo izraziti kao razliku između unakrsne entropije i entropije ciljne distribucije. Gledajući da ciljna distribucija ne ovisi o parametrima modela, minimizacija KL divergencije je jednaka minimizaciji unakrsne entropije. Zbog ovoga, u sljedećim eksperimentima ćemo koristiti KL divergenciju za izračun konzistencijskog gubitka.

Dakle, dodavanje komponente konzistencijskog gubitka izračunatog koristeći KL divergenciju povećava točnost naučenih modela. Fokusrirajmo se sada na standardne hiperparametre učenja dubokih modela. Jedan od osnovnih hiperparametara koji možemo varirati je veličina minigrupe. Gledajući da učenje provodimo zadani broj iteracija, a ne određeni broj epoha, uz izmjenu veličine minigrupe je potrebno promijeniti i broj iteracija ako želimo da model pojedine podatke vidi jednak broj puta. U tablici 10.7., stupac *Veličina minigrupe* predstavlja korištenu veličinu minigrupe. Kako bi učenje trajalo jednak broj epoha, učenje s veličinom minigrupe 128 provodimo 60000 iteracija, dok učenje s veličinom minigrupe 256 provodimo 30000 iteracija.

Tablica 10.7. Točnost modela učenih okvirom VIBE s konzistencijskim gubitkom ovisno o veličini minigrupe te stopi učenja.

| Veličina minigrupe | Stopa učenja |       |      |
|--------------------|--------------|-------|------|
|                    | 0.001        | 0.005 | 0.01 |
| 128                | <b>94.6</b>  | 93.8  | 92.8 |
| 256                | 94.1         | 94.2  | 92.9 |

Pokazuje se da model učen uz veličinu minigrupe 128 te stopu učenja iznosa  $1 \cdot 10^{-3}$  postiže najvišu točnost. Ipak, ako uspoređujemo učenje uz stopu učenja iznosa  $5 \cdot 10^{-3}$  odnosno iznosa 0.01, vidimo da učenje uz veličinu minigrupe 256 postiže bolju točnost. Kako bismo povećali robusnost na potencijalno lošiji odabir stope učenja, odlučili smo koristiti veličinu minigrupe 256 za sve sljedeće eksperimente.

Korištenjem strategije izmjene odnosno smanjenja stope učenja možemo pospješiti konvergenciju učenja, kao i poboljšati generalizacijsku moć naučenih modela. Dok algoritmi SOP+ te ILL koriste strategiju kosinusnog kaljenja, osnovna konfiguracija okvira VIBE ne uključuje nijednu strategiju izmjene stope učenja. Kako bismo potencijalno poboljšali točnost naučenih modela, odlučili smo koristiti strategiju kosinusnog kaljenja bez restarta. Pogledajmo kako se točnost modela učenih okvirom VIBE s konzistencij-

skim gubitkom i strategijom kosinusnog kaljenja mijenja ovisno o broju iteracija učenja te iznosu stope učenja.

Tablica 10.8. Točnost modela učenih okvirom VIBE s konzistencijskim gubitkom i strategijom kosinusnog kaljenja ovisno o broju iteracija te stopi učenja.

| Broj iteracija | Stopa učenja |       |             |
|----------------|--------------|-------|-------------|
|                | 0.001        | 0.005 | 0.01        |
| 15000          | 92.5         | 94.5  | 95.0        |
| 30000          | 93.4         | 94.7  | <b>95.1</b> |

Vidimo da model učen 30000 iteracija uz početnu stopu učenja iznosa 0.01 te strategiju kosinusnog kaljenja postiže najvišu točnost iznosa 95.1%. Dok se u prethodnim eksperimentima točnost smanjivala povećavanjem stope učenja, ovdje je situacija obrnuta: povećavanjem početne stope učenja, povećava se i točnost naučenih modela. U usporedbi s najboljim modelom iz tablice 10.5., novi najbolji model postiže za 0.3% višu točnost. Zbog ovoga, odlučujemo koristiti strategiju kosinusnog kaljenja u daljnjim eksperimentima. Dodatno, fiksiramo broj iteracija na 30000, a stopu učenja na iznos 0.01.

U prethodnim eksperimentima, stopu konzistencije smo fiksirali na iznos 1. Pogledajmo sada kako se točnost modela učenih okvirom VIBE s konzistencijskim gubitkom mijenja ovisno o iznosu stope konzistencije. U tablici 10.9., stupac *Stopa konzistencije* predstavlja korištenu (konstantnu) stopu konzistencije, dok stupac *Točnost [%]* ponovno predstavlja točnost naučenog modela na čistom skupu za ispitivanje skupa CIFAR-10.

Tablica 10.9. Točnost modela učenih okvirom VIBE s konzistencijskim gubitkom ovisno o stopi konzistencije.

| Stopa konzistencije | Točnost [%] |
|---------------------|-------------|
| 0.1                 | 94.8        |
| 0.25                | 94.8        |
| 0.5                 | 94.8        |
| 0.75                | 94.9        |
| 1                   | 95.1        |
| 2.5                 | 95.2        |
| 5                   | 95.6        |
| 7.5                 | <b>95.7</b> |
| 10                  | 95.5        |

Kao što možemo vidjeti, model učen uz stopu konzistencije iznosa 7.5 postiže najvišu točnost jednaku 95.7%. Naučeni model postiže za 0.6% višu točnost u usporedbi s prethodno najboljim modelom iz tablice 10.8.

Kao i za stopu učenja, i za stopu konzistencije možemo definirati strategiju izmjene iznosa stope. Gledajući da ciljne oznake dobivamo kao izlaz modela za slabo augmentirane ulaze, na početku učenja će dobivene oznake potencijalno biti neprecizne. Kako bismo doskočili ovom problemu, kroz iteracije bismo mogli povećavati značaj komponente konzistencijskog gubitka. Ovim pristupom, konzistencijski gubitak neće imati velik utjecaj kada model još nije dovoljno naučen. Konkretno, možemo definirati strategiju linearnog rasta stope konzistencije. Naravno, pritom moramo definirati i početni te konačni iznos stope. Usporedimo sada korištenje konstantne stope konzistencije s korištenjem strategije linearnog rasta stope uz različite početne odnosno konačne iznose. U tablici 10.10., stupac *Strategija izmjene* predstavlja korištenu strategiju izmjene stope konzistencije. Pritom vrijednost *Konstantna*, 7.5 označava strategiju konstantne stope iznosa 7.5, a vrijednost *Linearna*, [0.1, 10] označava strategiju linearnog rasta stope od početnog iznosa 0.1 do konačnog iznosa 10.

Tablica 10.10. Točnost modela učenih okvirom VIBE s konzistencijskim gubitkom ovisno o strategiji izmjene stope konzistencije.

| Strategija izmjene  | Točnost [%] |
|---------------------|-------------|
| Konstantna, 7.5     | <b>95.7</b> |
| Linearna, [0.1, 1]  | 95.0        |
| Linearna, [0.1, 5]  | 95.1        |
| Linearna, [0.1, 10] | 95.3        |
| Linearna, [1, 5]    | 95.2        |
| Linearna, [1, 7.5]  | 95.2        |
| Linearna, [1, 10]   | 95.4        |

Vidimo da model učen uz konstantnu stopu konzistencije iznosa 7.5 postiže najvišu točnost. Dakle, korištenje strategije linearnog rasta stope konzistencije vodi do smanjenja točnosti naučenih modela. Na temelju dobivenih rezultata, možemo zaključiti da je za postizanje visokih performansa pri učenju na podacima sa zašumljenim oznakama važno da komponenta konzistencijskog gubitka od početka učenja značajno utječe na ukupan gubitak.

Doprinos komponente konzistencijskog gubitka uvelike ovisi o korištenim augmentacijama. Do sada, jake augmentacije smo definirali kao slabe augmentacije uz dodanu augmentaciju AutoAugment. Ipak, algoritmi SOP+ te ILL u skupu jakih augmentacija dodatno imaju i augmentaciju izrezivanja odnosno augmentaciju nasumičnog brisanja. Potaknuti tom činjenicom, u skup jakih augmentacija smo dodali augmentaciju nasu-

mičnog brisanja. Pogledajmo sada kako se točnost modela učenih okvirom VIBE s augmentacijom nasumičnog brisanja mijenja ovisno o iznosu stope konzistencije.

Tablica 10.11. Točnost modela učenih okvirom VIBE s augmentacijom nasumičnog brisanja ovisno o stopi konzistencije.

| Stopa konzistencije | Točnost [%] |
|---------------------|-------------|
| 0.1                 | 95.1        |
| 0.25                | 95.3        |
| 0.5                 | 95.2        |
| 0.75                | 95.0        |
| 1                   | 95.3        |
| 2.5                 | <b>95.7</b> |
| 5                   | <b>95.7</b> |
| 7.5                 | 95.4        |
| 10                  | 95.0        |

Možemo vidjeti da modeli učeni uz stopu konzistencije iznosa 2.5 odnosno iznosa 5 postižu najvišu točnost jednaku 95.7%. Iako je točnost ovih modela jednaka točnosti prethodno najboljeg modela iz tablice 10.9., konačna točnost uz većinu drugih iznosa stope konzistencije je sada viša. Zbog toga, odlučujemo se za uključivanje augmentacije nasumičnog brisanja u skup jakih augmentacija. Dodatno, stopu konzistencije fiksiramo na iznos 5.

Dodavanjem novih augmentacija u postojeći skup augmentacija povećavamo sveukupnu jačinu skupa. Kako bi utjecaj konzistencijskog gubitka bio otprilike jednak kao i prije, potrebno je smanjiti iznos stope konzistencije. Ovo možemo vidjeti i u prethodnim eksperimentima: dodavanjem augmentacije nasumičnog brisanja, iznos optimalne stope konzistencije se smanjuje sa 7.5 na 5.

Konačno, pogledajmo ovisi li optimalan iznos stope konzistencije o konkretnoj inačici skupa podataka. U tablici 10.12., svaki stupac iz grupe stupaca *Inačica skupa podataka* predstavlja jednu inačicu skupa CIFAR-10. Konkretno, stupac *Čisto* označava čisti skup CIFAR-10, stupac *Simetrično, 20%* označava simetrično zašumljenu inačicu skupa uz stopu šuma iznosa 20%, a stupac *Asimetrično, 40%* označava asimetrično zašumljenu inačicu skupa uz stopu šuma iznosa 40%. Najbolji rezultat za svaku inačicu skupa je podebljan.

Tablica 10.12. Točnost modela učenih okvirom VIBE s konzistencijskim gubitkom na različitim inačicama skupa CIFAR-10 ovisno o stopi konzistencije.

| Stopa konzistencije | Inačica skupa podataka |                 |                  |
|---------------------|------------------------|-----------------|------------------|
|                     | Čisto                  | Simetrično, 20% | Asimetrično, 40% |
| 1                   | 96.0                   | 95.3            | 94.6             |
| 5                   | <b>96.1</b>            | <b>95.7</b>     | <b>95.1</b>      |
| 7.5                 | 95.9                   | 95.4            | 94.9             |

Za sve tri inačice skupa podataka CIFAR-10, modeli učeni uz stopu konzistencije iznosa 5 postižu najvišu točnost. Dakle, izgleda da odabir iznosa stope konzistencije ne ovisi nužno o konkretnoj inačici skupa podataka. Na temelju ovih rezultata, potvrđujemo fiksiranje stope konzistencije na iznos 5 te time dolazimo do konačne konfiguracije hiperparametara koju smo koristili pri usporedbi sa stanjem tehnike.

### 10.1.3. Validacija gubitka stanja tehnike

Algoritmi SOP+ te ILL koriste formulacije gubitka s nekoliko zasebnih komponenti. Potaknuti validacijom hiperparametara za okvir VIBE, odlučili smo istražiti utjecaj prisutnosti pojedinih komponenti gubitka na performanse algoritma SOP+ odnosno algoritma ILL.

Konkretno, algoritam SOP+ osim osnovnog gubitka dodatno koristi konzistencijski gubitak i gubitak ravnoteže razreda. Pritom oba gubitka imaju zasebne hiperparametre: stopu konzistencije odnosno stopu ravnoteže razreda. U osnovnoj konfiguraciji algoritma SOP+, stopa konzistencije je postavljena na iznos 0.9, dok je stopa ravnoteže razreda postavljena na iznos 0.1. Za provođenje eksperimenata, koristimo simetrično zašumljen skup CIFAR-10 uz stopu šuma iznosa 20% te prethodno opisanu konfiguraciju algoritma. U tablici 10.13., stupac *Stopa konzistencije* predstavlja korištenu stopu konzistencije, stupac *Stopa ravnoteže razreda* predstavlja korištenu stopu ravnoteže razreda, a stupac *Točnost [%]* ponovno predstavlja točnost modela na čistom skupu za ispitivanje skupa CIFAR-10.

Tablica 10.13. Točnost modela učenih algoritmom SOP+ ovisno o stopi konzistencije te stopi ravnoteže razreda.

| Stopa konzistencije | Stopa ravnoteže razreda | Točnost [%]  |
|---------------------|-------------------------|--------------|
| 0.9                 | 0                       | <b>96.39</b> |
| 1                   | 0                       | 96.28        |
| 0                   | 0.1                     | 93.93        |
| 0                   | 1                       | 93.91        |
| 0.9                 | 0.1                     | 96.26        |

Vidimo da model učen uz stopu konzistencije iznosa 0.9 te bez komponente gubitka ravnoteže razreda postiže najvišu točnost iznosa 96.39%. Model učen uz osnovnu konfiguraciju postiže neznatno nižu točnost, dok model učen uz stopu ravnoteže razreda iznosa 0.1 te bez komponente konzistencijskog gubitka postiže točnost za 2.46% nižu od točnosti najboljeg modela. Možemo zaključiti da je za uspješnost algoritma SOP+ veoma važan konzistencijski gubitak, dok gubitak ravnoteže razreda ne mijenja znatno performanse naučenih modela. Štoviše, uklanjanjem gubitka ravnoteže razreda bismo potencijalno mogli malo povećati uspješnost algoritma. Naravno, postoji mogućnost da je ova komponenta važna kod težih postava zašumljivanja ili kod težih skupova podataka.

Algoritam ILL osim osnovnog gubitka dodatno koristi i konzistencijski gubitak. Za razliku od algoritma SOP+, stopa konzistencije je kod algoritma ILL fiksirana na iznos 1. Kao i prije, učenje provodimo na simetrično zašumljenom skupu CIFAR-10 uz stopu šuma iznosa 20%. Pritom koristimo ranije opisanu konfiguraciju hiperparametara algoritma ILL.

Tablica 10.14. Točnost modela učenih algoritmom ILL ovisno o stopi konzistencije.

| Stopa konzistencije | Točnost [%]  |
|---------------------|--------------|
| 0                   | <b>96.28</b> |
| 1                   | 96.22        |

Vidimo da model učen bez komponente konzistencijskog gubitka postiže najvišu točnost. Ipak, razlika u točnosti je neznatna: samo 0.06%. Možemo zaključiti da konzistencijski gubitak nije značajan za algoritam ILL. Ipak, kao i kod algoritma SOP+, ne možemo isključiti mogućnost da je komponenta konzistencijskog gubitka značajna kod težih postava zašumljivanja ili kod težih skupova podataka.



#### 10.1.4. Validacija gubitka nadziranog učenja

Pokazali smo da dodavanje konzistencijskog gubitka nadziranom učenju značajno poboljšava performanse naučenih modela kada je u pitanju učenje na skupu sa zašumljenim oznakama. Ovu pojavu vrijedi detaljnije istražiti. Konkretno, zanima nas kako zadana formulacija gubitka utječe na performanse pri učenju na različitim inačicama skupa podataka CIFAR-10. Pritom stopu učenja fiksiramo na iznos 0.05, a broj epoha učenja variramo. Preostali hiperparametri odgovaraju prethodno opisanoj konfiguraciji.

Prije svega, pogledajmo kako se točnost modela učenih nadziranim učenjem bez konzistencijskog gubitka na različitim inačicama skupa CIFAR-10 mijenja ovisno o broju epoha učenja. U tablici 10.15., stupac *Broj epoha* predstavlja korišteni broj epoha učenja, dok svaki stupac iz grupe stupaca *Inačica skupa podataka* predstavlja jednu inačicu skupa CIFAR-10. Konkretno, stupac *Čisto* označava čisti skup CIFAR-10, stupac *Simetrično, 20%* označava simetrično zašumljenu inačicu skupa uz stopu šuma iznosa 20%, a stupac *Asimetrično, 40%* označava asimetrično zašumljenu inačicu skupa uz stopu šuma iznosa 40%. Kao i inače, rezultat za svaku inačicu skupa je podebljan.

Tablica 10.15. Točnost modela učenih nadziranim učenjem na različitim inačicama skupa CIFAR-10 ovisno o broju epoha.

| Broj epoha | Inačica skupa podataka |                 |                  |
|------------|------------------------|-----------------|------------------|
|            | Čisto                  | Simetrično, 20% | Asimetrično, 40% |
| 200        | 95.1                   | 83.6            | 75.8             |
| 300        | <b>95.3</b>            | <b>83.8</b>     | <b>76.8</b>      |

Možemo vidjeti da točnost modela učenih nadziranim učenjem bez konzistencijskog gubitka drastično pada kada su u skupu za učenje prisutni podatci sa zašumljenim oznakama. Konkretno, učenje na asimetrično zašumljenoj inačici skupa CIFAR-10 uz stopu šuma iznosa 40% rezultira modelom čija je točnost za 18.5% niža od točnosti modela učenog na čistom skupu. Dodatno, vidimo da učenje veći broj epoha rezultira boljim modelom neovisno o konkretnoj inačici skupa podataka.

Dodajmo sada komponentu konzistencijskog gubitka. Pritom stopu konzistencije fiksiramo na iznos 1, a jake augmentacije definiramo kao slabe augmentacije uz dodanu augmentaciju AutoAugment. Pogledajmo sada kako se točnost modela učenih nadziranim učenjem s konzistencijskim gubitkom na različitim inačicama skupa CIFAR-10

mijenja ovisno o broju epoha učenja.

Tablica 10.16. Točnost modela učenih nadziranim učenjem s konzistencijskim gubitkom na različitim inačicama skupa CIFAR-10 ovisno o broju epoha.

| Broj epoha | Inačica skupa podataka |                 |                  |
|------------|------------------------|-----------------|------------------|
|            | Čisto                  | Simetrično, 20% | Asimetrično, 40% |
| 200        | 95.7                   | <b>93.5</b>     | <b>89.9</b>      |
| 300        | <b>96.2</b>            | 89.6            | 83.0             |

Vidimo da dodavanje konzistencijskog gubitka povećava točnost modela na svim inačicama skupa CIFAR-10. Pri učenju na čistom skupu, učenje veći broj epoha rezultira višom točnošću. S druge strane, učenje na zašumljenim inačicama skupa rezultira višom točnošću kada odaberemo manji broj epoha. Dakle, ako želimo osigurati veću robusnost na prisutnost zašumljenih oznaka, bolje je model učiti manji broj epoha. Iako ćemo ovim pristupom imati malo nižu točnost pri učenju na čistom skupu, točnost modela pri učenju na zašumljenim inačicama skupa bit će značajno viša. Konkretno, kraćim učenjem možemo smanjiti razliku u točnosti modela učenog na čistom skupu te modela učenog na asimetrično zašumljenoj inačici skupa s 18.5% na 5.8%, ali ćemo ovo platiti 0.5% nižom točnošću pri učenju na čistom skupu.

Gledajući da je dodavanje augmentacije nasumičnog brisanja povećalo performanse okvira VIBE, odlučili smo primijeniti ovu promjenu i na nadzirano učenje. Konačno, pogledajmo kako se točnost modela učenih nadziranim učenjem s augmentacijom nasumičnog brisanja na različitim inačicama skupa CIFAR-10 mijenja ovisno o broju epoha učenja.

Tablica 10.17. Točnost modela učenih nadziranim učenjem s augmentacijom nasumičnog brisanja na različitim inačicama skupa CIFAR-10 ovisno o broju epoha.

| Broj epoha | Inačica skupa podataka |                 |                  |
|------------|------------------------|-----------------|------------------|
|            | Čisto                  | Simetrično, 20% | Asimetrično, 40% |
| 200        | 95.9                   | <b>95.4</b>     | <b>92.2</b>      |
| 300        | <b>96.3</b>            | 93.3            | 89.8             |

Možemo vidjeti da dodavanje augmentacije nasumičnog brisanja u skup jakih augmentacija također povećava točnost modela na svim inačicama skupa CIFAR-10. Kao i kod prethodnog eksperimenta, učenje na čistom skupu rezultira višom točnošću uz veći broj epoha, dok je pri učenju na zašumljenim inačicama skupa situacija obrnuta. Oda- birom učenja 200 epoha, razliku u točnosti modela učenog na čistom skupu te modela

učenog na asimetrično zašumljenoj inačici skupa dodatno smanjujemo s 5.8% na 3.7%, ali uz cijenu 0.4% niže točnosti pri učenju na čistom skupu. Drugim riječima, korištenjem nadziranog učenja s konzistencijskim gubitkom te augmentacijom nasumičnog brisanja u skupu jakih augmentacija možemo postići prihvatljivu robusnost na prisutnost zašumljenih oznaka, ali i povećati točnost naučenog modela u slučaju učenja na čistom skupu CIFAR-10.

## 10.2. Napadi umetanjem stražnjih vrata

Eksperimente s napadima umetanjem stražnjih vrata provodili smo na zatrovanim inačicama skupa CIFAR-10. Pritom smo koristili napade BadNets, Blend i WaNet uz stopu trovanja iznosa 10% te *all-to-one* izmjenu oznaka uz ciljni razred airplane. Kod napada BadNets, kao okidač smo koristili kvadratni uzorak dimenzija  $2 \times 2$  smješten u gornjem lijevom kutu slike. S druge strane, kod napada Blend smo kao okidač koristili sliku *Hello Kitty* vidljivu na prethodnom primjeru 2.2. uz jačinu miješanja iznosa 0.1. Konačno, kod napada WaNet smo koristili hiperparametar  $k$  iznosa 4 te hiperparametar  $s$  iznosa 1. Za svaki napad, stvorili smo jednu inačicu zatrovanog skupa CIFAR-10. U svim eksperimentima, učili smo model arhitekture ResNet-18. Ključne mjere dobrote za eksperimente s napadima umetanjem stražnjih vrata su točnost na čistom skupu za ispitivanje te stopa uspješnosti napada (ASR) izračunata na potpuno zatrovanoj inačici skupa za ispitivanje. Pritom želimo maksimizirati točnost, ali i minimizirati stopu uspješnosti napada.

Općenito uspoređujemo pet pristupa: algoritam *Anti-backdoor learning* (ABL), algoritam *Decoupling based defense* (DBD), algoritam *Adaptively splitting dataset-based defense* (ASD), osnovnu inačicu okvira VIBE te okvir VIBE s konzistencijskim gubitkom (VIBE + CL). Za algoritme ABL, DBD i ASD smo zbog jednostavnosti preuzeli rezultate iz originalnog rada okvira VIBE [10]. Pritom konfiguracije hiperparametara pojedinih algoritama odgovaraju konfiguracijama iz originalnih radova [5, 6, 7].

Kod osnovne inačice okvira VIBE, model inicijaliziran okvirom All4One smo učili 30000 iteracija uz optimizator SGD s početnom stopom učenja iznosa  $1 \cdot 10^{-3}$ . Koristili smo moment iznosa 0.9, kao i propadanje težina iznosa  $5 \cdot 10^{-4}$ . Pritom nismo koristili nijednu strategiju izmjene stope učenja. Skup podataka bio je podijeljen na minigrupe veličine 256. Hiperparametar raspršenosti von Mises-Fisherove distribucije  $\kappa$  fiksirali smo

na iznos 10, jednako kao i hiperparametar temperature  $\nu$  korišten pri izračunu distribucije  $p(y|l)$ . Pojedine vektore iz skupa čistih prototipova  $\phi$  odnosno skupa zatrovanih prototipova  $\psi$  inicijalizirali smo kao centroide pripadnih razreda. Parametre  $\hat{\pi}$  inicijalizirali smo nasumično iz jedinične normalne distribucije. Hiperparametar temperature  $c$  korišten za izračun koeficijenata miješanja  $\pi$  postavili smo na iznos 0.02. E korak učenja provodili smo svakih 1000 iteracija, pritom koristeći Sinkhorn-Knopp algoritam uz regularizacijski hiperparametar  $\lambda$  iznosa 25 te maksimalan broj iteracija iznosa 10000.

Konfiguracija hiperparametara okvira VIBE s konzistencijskim gubitkom jednaka je konfiguraciji osnovne inačice okvira, ali uz nekoliko dodanih hiperparametara. Konkretno, koristili smo konstantnu stopu konzistencije iznosa 1, a jake augmentacije uključuju slabe augmentacije, augmentaciju AutoAugment te augmentaciju nasumičnog brisanja.

Kao i prije, ako za pojedini eksperiment nisu eksplicitno navedene vrijednosti određenih hiperparametara, u pitanju su upravo opisane vrijednosti.

### 10.2.1. Usporedba sa stanjem tehnike

Prije svega, pogledajmo uspješnost opisanih algoritama obrane pri učenju na inačici skupa CIFAR-10 zatrovanoj napadom BadNets. U tablici 10.18., stupac *Algoritam* predstavlja korišteni algoritam obrane od napada umetanjem stražnjih vrata. Stupac *Točnost [%]* predstavlja točnost modela na čistom skupu za ispitivanje skupa CIFAR-10, a stupac *ASR [%]* predstavlja stopu uspješnosti napada izračunatu na potpuno zatrovanoj inačici skupa za ispitivanje. Najbolji rezultati za oba stupca su podebljani.

Tablica 10.18. Točnost modela učenih na inačici skupa CIFAR-10 zatrovanoj napadom BadNets.

| Algoritam | Točnost [%] | ASR [%]    |
|-----------|-------------|------------|
| ABL       | 93.8        | 1.1        |
| DBD       | 92.4        | 1.0        |
| ASD       | 92.1        | 3.0        |
| VIBE      | 94.4        | 0.6        |
| VIBE + CL | <b>94.8</b> | <b>0.5</b> |

Možemo vidjeti da osnovna inačica okvira VIBE postiže višu točnost, ali i nižu stopu uspješnosti napada u usporedbi s preostalim algoritmima obrane. Pritom vrijedi napomenuti da algoritam ABL postiže višu točnost te podjednaku ili nižu stopu uspješnosti napada od algoritama DBD i ASD. Dodavanjem komponente konzistencijskog gubitka, dodatno poboljšavamo performanse okvira VIBE. Konkretno, postižemo povećanje točnosti iznosa 0.4%, kao i smanjenje stope uspješnosti napada iznosa 0.1%. Pogledajmo sada uspješnost opisanih algoritama obrane pri učenju na inačici skupa CIFAR-10 zatrovanoj napadom Blend.

Tablica 10.19. Točnost modela učenih na inačici skupa CIFAR-10 zatrovanoj napadom Blend.

| Algoritam | Točnost [%] | ASR [%]    |
|-----------|-------------|------------|
| ABL       | 91.9        | 1.6        |
| DBD       | 92.2        | 1.7        |
| ASD       | 93.4        | 1.0        |
| VIBE      | 94.4        | 3.1        |
| VIBE + CL | <b>94.5</b> | <b>0.7</b> |

U ovom slučaju, osnovna inačica okvira VIBE postiže višu točnost, ali ne i nižu stopu uspješnosti napada u usporedbi s preostalim algoritmima obrane. Konkretno, algoritam ASD postiže za 2.1% nižu stopu uspješnosti napada u usporedbi s osnovnom inačicom okvira VIBE. Kao i u prethodnom eksperimentu, dodavanjem konzistencijskog gubitka poboljšavamo performanse okvira VIBE. Pritom postižemo povećanje točnosti iznosa 0.1%, ali i smanjenje stope uspješnosti napada iznosa čak 2.4%. Uz ovo poboljšanje, okvir VIBE s konzistencijskim gubitkom postiže najbolje performanse u usporedbi s preostalim algoritmima. Pogledajmo još i uspješnost navedenih algoritama obrane pri učenju na inačici skupa CIFAR-10 zatrovanoj napadom WaNet.

Tablica 10.20. Točnost modela učenih na inačici skupa CIFAR-10 zatrovanoj napadom WaNet.

| Algoritam | Točnost [%] | ASR [%]    |
|-----------|-------------|------------|
| ABL       | 84.1        | 2.2        |
| DBD       | 91.2        | <b>0.4</b> |
| ASD       | 93.3        | 1.2        |
| VIBE      | 94.5        | 1.0        |
| VIBE + CL | <b>94.8</b> | 0.6        |

Kao i u prethodnom eksperimentu, osnovna inačica okvira VIBE postiže višu točnost, ali ne i nižu stopu uspješnosti napada u usporedbi s preostalim algoritmima obrane. U ovom slučaju, algoritam DBD postiže za 0.6% nižu stopu uspješnosti napada u usporedbi s osnovnom inačicom okvira VIBE. Dodavanjem komponente konzistencijskog gubitka, ponovno poboljšavamo performanse okvira VIBE. Konkretno, postizemo povećanje točnosti iznosa 0.4%, kao i smanjenje stope uspješnosti napada iznosa 0.4%. Iako okvir VIBE s konzistencijskim gubitkom u ovom eksperimentu ima najvišu točnost, algoritam DBD i dalje postiže najnižu stopu uspješnosti napada.

Dakle, zaključujemo da dodavanje konzistencijskog gubitka okviru VIBE vodi do povećanja točnosti, kao i do smanjenja stope uspješnosti napada. Pritom je smanjenje najveće kod napada Blend za koji osnovni okvir VIBE ima relativno visoku stopu uspješnosti napada. Kada govorimo o napadima BadNets te WaNet, poboljšanja performansi su prisutna, ali ne i toliko značajna kao kod napada Blend. Općenito, okvir VIBE s konzistencijskim gubitkom postiže performanse podjednake ili bolje u usporedbi s algoritmima ABL, DBD te ASD.

### 10.2.2. Primjena algoritma ILL

Algoritam *Imprecise label learning* (ILL) pokazao se izvrsnim za problem zašumljenih oznaka. Potaknuti tim rezultatom, odlučili smo ga pokušati primijeniti na problem napada umetanjem stražnjih vrata. Konkretno, algoritmom ILL učimo modele arhitekture ResNet-18 na inačicama skupa CIFAR-10 zatrovanim napadom BadNets uz varijabilnu stopu trovanja. Pritom na slike dodajemo ranije opisani okidač, a ponovno koristimo i *all-to-one* izmjenu oznaka uz ciljni razred *airplane*. U tablici 10.21., stupac *Stopa trovanja [%]* predstavlja korištenu stopu trovanja, stupac *Točnost [%]* ponovno predstavlja točnost modela na čistom skupu za ispitivanje skupa CIFAR-10, a stupac *ASR [%]* predstavlja stopu uspješnosti napada izračunatu na potpuno zatrovanoj inačici skupa za ispitivanje.

Tablica 10.21. Točnost modela učenih algoritmom ILL na inačicama skupa CIFAR-10 zatrovanim napadom BadNets uz varijabilnu stopu trovanja.

| Stopa trovanja [%] | Točnost [%]  | ASR [%]     |
|--------------------|--------------|-------------|
| 0                  | <b>96.75</b> | -           |
| 1                  | 96.62        | <b>0.28</b> |
| 10                 | 10.00        | 100.00      |

Možemo vidjeti da model učen na inačici skupa CIFAR-10 zatrovanoj napadom BadNets uz stopu trovanja iznosa 1% postiže točnost neznatno nižu od točnosti modela učenog na čistom skupu. Prema iznosu stope uspješnosti napada, vidimo da napad uz stopu trovanja iznosa 1% nije uspio. Drugim riječima, ovdje algoritam ILL služi kao uspješna obrana od napada umetanjem stražnjih vrata. Ipak, važno je razmotriti i model učen na inačici skupa CIFAR-10 zatrovanoj napadom BadNets uz stopu trovanja iznosa 10%. Vidimo da u ovom slučaju učenje nije uspješno. Konkretno, došlo je do kolapsa učenja: model za sve ulaze predviđa zatrovani razred `airplane`. Ovaj rezultat pokazuje nam da učenje algoritmom ILL može biti nestabilno u teškim postavima napada. Dakle, iako je učenje uz nisku stopu trovanja uspješno, povećanje stope trovanja može voditi do nestabilnosti te kolapsa učenja. Zbog ovoga, algoritam ILL nije prikladan kao obrana od napada umetanjem stražnjih vrata.

### 10.2.3. Hibrid okvira VIBE i algoritma ILL

Okvir VIBE postiže izvrsne performanse pri učenju na zatrovanim podacima, kao i pri učenju na podacima sa zašumljenim oznakama. S druge strane, algoritam ILL je izvrstan za problem zašumljenih oznaka, ali ne i za problem napada umetanjem stražnjih vrata. Konkretno, vidjeli smo da učenje može biti nestabilno u teškim postavima napada. Ipak, algoritam ILL postiže višu točnost u usporedbi s okvirom VIBE u lakšim postavima zašumljivanja.

Zanimljivo je uočiti brojne sličnosti između okvira VIBE i algoritma ILL. U oba slučaja, glavni cilj je maksimizirati log-izglednost skupa podataka  $\mathcal{D} = \{(\mathbf{x}^i, y^i)\}_{i=1}^N$ . Pri tom su u skupu prisutne zatrovane odnosno zašumljene oznake  $\mathbf{y}$ , dok su čiste oznake  $\mathbf{l}$  skrivene. Zbog ovoga, distribuciju  $p(y|\mathbf{x})$  dobivamo marginalizacijom zajedničke distribucije  $p(y, l|\mathbf{x})$ . Kako bismo uspješno maksimizirali ovako definiranu log-izglednost, u oba slučaja koristimo algoritam maksimizacije očekivanja. Glavne razlike između okvira VIBE i algoritma ILL su u parametrizaciji pojedinih distribucija, kao i provođenju E koraka učenja.

Zbog navedenih sličnosti, možemo osmisliti hibridni okvir zasnovan na okviru VIBE uz određene dijelove algoritma ILL. Idealno, predloženi okvir bi imao izvrsne performanse neovisno o težini postava te bez obzira radi li se o problemu napada umetanjem stražnjih vrata ili o problemu zašumljenih oznaka. Konkretno, predlažemo dvije različite inačice hibridnog okvira.

Kod prve inačice, umjesto E koraka okvira VIBE koristimo E korak algoritma ILL. U E koraku okvira VIBE, matricu  $\mathbf{Q}$  procjenjujemo na temelju izračunate matrice  $\mathbf{P}$  koristeći algoritam Sinkhorn-Knopp za rješavanje problema optimalnog transporta s entropijskom regularizacijom. Pritom su matrice  $\mathbf{Q}$  i  $\mathbf{P}$  definirane jednadžbama 7.10, a matrica  $\mathbf{P}$  je izračunata na temelju modela iz prethodne iteracije. S druge strane, u E koraku algoritma ILL, matricu  $\mathbf{Q}$  jednostavno postavljamo na matricu  $\mathbf{P}$  izračunatu u prethodnoj iteraciji. Čiste oznake  $\mathbf{l}$  potom procjenjujemo na temelju dobivene matrice  $\mathbf{Q}$ . Pritom uobičajeno radimo s čvrstim oznakama (engl. *hard labels*), ali možemo koristiti i meke oznake (engl. *soft labels*). Dodatno, E korak kod okvira VIBE provodimo svakih  $T$  iteracija, dok ga kod algoritma ILL provodimo svaku iteraciju.

Model arhitekture ResNet-18 učimo prvom inačicom hibridnog okvira na skupu podataka CIFAR-10 zatrovanom napadom BadNets uz stopu trovanja iznosa 10% i prethodno opisani okidač. Konfiguracija hibridnog okvira pritom odgovara konfiguraciji osnovne inačice okvira VIBE, ali uz varijabilnu vrstu oznaka te varijabilan iznos hiperparametra  $T$ . U tablici 10.22., stupac *Vrsta oznaka* predstavlja korištenu vrstu oznaka, a stupac  $T$  predstavlja period provođenja E koraka. Kao i inače, stupac *Točnost [%]* predstavlja točnost modela na čistom skupu za ispitivanje skupa CIFAR-10, a stupac *ASR [%]* predstavlja stopu uspješnosti napada izračunatu na potpuno zatrovanoj inačici skupa za ispitivanje.

Tablica 10.22. Točnost modela učenih prvom inačicom hibridnog okvira na skupu CIFAR-10 zatrovanom napadom BadNets ovisno o vrsti oznaka te periodu provođenja E koraka.

| Vrsta oznaka | $T$  | Točnost [%] | ASR [%] |
|--------------|------|-------------|---------|
| Čvrste       | 1    | 94.7        | 100     |
| Čvrste       | 1000 | 94.5        | 100     |
| Meke         | 1    | <b>94.8</b> | 100     |
| Meke         | 1000 | 94.5        | 100     |



Kao što možemo vidjeti, model učen uz meke oznake te provođenje E koraka svaku iteraciju postiže najvišu točnost. Općenito, izgleda da provođenje E koraka svaku iteraciju rezultira višom točnošću u usporedbi s provođenjem E koraka svakih 1000 iteracija. Nažalost, na temelju iznosa stope uspješnosti napada, vidimo da prva inačica hibridnog okvira nije uspješna kao obrana od napada umetanjem stražnjih vrata.

U drugoj inačici hibridnog okvira, mijenjamo način izračuna distribucije  $p(y|l)$ . Kod okvira VIBE, ovu distribuciju definiramo kao normaliziranu kosinusnu sličnost između čistih i zatrovanih prototipova. S druge strane, kod algoritma ILL, ovu distribuciju računamo na temelju parametrizirane matrice šuma neovisne o uzorku. Ovu matricu možemo smatrati otprilike kao logite distribucije  $p(y|l)$ . Kako bismo pospješili učenje, matricu šuma možemo normalizirati po recima i stupcima, kao i skalirati hiperparametrom temperature  $c$ . Dodatno, važno je i pitanje inicijalizacije zadane matrice. Kod algoritma ILL, matricu šuma uobičajeno inicijaliziramo na jediničnu matricu. U našim eksperimentima, dodatno ćemo isprobati i nasumičnu inicijalizaciju.

Model arhitekture ResNet-18 učimo drugom inačicom hibridnog okvira na skupu podataka CIFAR-10 zatrovanom napadom BadNets uz stopu trovanja iznosa 10% i prethodno opisani okidač. Matricu šuma pritom inicijaliziramo nasumično iz jedinične normalne distribucije. Konfiguracija hibridnog okvira ponovno odgovara konfiguraciji osnovne inačice okvira VIBE, ali uz varijabilno korištenje normalizacije matrice te varijabilan iznos temperature. U tablici 10.23., stupac *Normalizacija* nam govori je li korištena normalizacija matrice šuma po recima i stupcima, a stupac *Temperatura* predstavlja korišteni iznos hiperparametra temperature  $c$ .

Tablica 10.23. Točnost modela učenih drugom inačicom hibridnog okvira uz nasumičnu inicijalizaciju matrice šuma na skupu CIFAR-10 zatrovanom napadom BadNets ovisno o korištenju normalizacije matrice te temperaturi.

| Normalizacija | Temperatura | Točnost [%] | ASR [%]    |
|---------------|-------------|-------------|------------|
| Ne            | 1           | 86.7        | 0.5        |
| Ne            | 10          | 14.3        | 1.2        |
| Da            | 1           | <b>89.9</b> | 0.8        |
| Da            | 10          | 29.3        | <b>0.1</b> |

Vidimo da normalizacija matrice šuma po recima i stupcima povećava točnost neovisno o iznosu hiperparametra temperature. Pritom najvišu točnost postiže model učen uz normalizaciju matrice šuma te uz temperaturu iznosa 1 tj. bez skaliranja matrice. Štoviše, učenje uz temperaturu iznosa 10 značajno smanjuje točnost u usporedbi s učenjem bez skaliranja. Pogledajmo sada još i performanse modela učenih uz inicijalizaciju matrice šuma na jediničnu matricu.

Tablica 10.24. Točnost modela učenih drugom inačicom hibridnog okvira uz jediničnu inicijalizaciju matrice šuma na skupu CIFAR-10 zatrovanom napadom BadNets ovisno o korištenju normalizacije matrice te temperaturi.

| Normalizacija | Temperatura | Točnost [%] | ASR [%]    |
|---------------|-------------|-------------|------------|
| Ne            | 1           | 92.4        | 0.8        |
| Ne            | 10          | 94.2        | <b>0.6</b> |
| Da            | 1           | 92.6        | <b>0.6</b> |
| Da            | 10          | <b>94.5</b> | 0.7        |

Možemo vidjeti da model učen uz normalizaciju matrice šuma po recima i stupcima te hiperparametar temperature iznosa 10 sada postiže najvišu točnost. Stopa uspješnosti napada pritom je podjednaka za sve konfiguracije hiperparametara. Za razliku od prethodnog eksperimenta, učenje uz temperaturu iznosa 10 sada povećava točnost u usporedbi s učenjem bez skaliranja matrice. Štoviše, vidimo da iznos temperature sada ima veći značaj nego korištenje normalizacije matrice šuma. Na temelju ovih rezultata, možemo zaključiti da je prikladna inicijalizacija matrice šuma veoma važna za uspješnost rada algoritma ILL.

Općenito, najbolji naučeni model po performansama je podjednak modelu učenim osnovnom inačicom okvira VIBE iz tablice 10.18. Dakle, zaključujemo da druga inačica hibridnog okvira uz jediničnu inicijalizaciju matrice šuma, normalizaciju matrice po recima i stupcima te hiperparametar temperature iznosa 10 može služiti kao zamjena za osnovnu inačicu okvira VIBE te općenito kao robusna obrana od napada umetanjem stražnjih vrata.

## 11. Zaključak

Kada prikupljamo i označavamo vlastite skupove podataka, možemo se susresti s brojnim problemima. Neki od najčešćih problema su napadi umetanjem stražnjih vrata (Bad-Nets, Blend, WaNet) i prisutnost zašumljenih oznaka (simetrično, asimetrično). Kroz vrijeme, razvili su se brojni algoritmi za obranu od napada (ABL, DBD, ASD), kao i za učenje na zašumljenim oznakama (SOP+, ILL). Okvir VIBE razvijen je s ciljem obrane od napada umetanjem stražnjih vrata. Provođenjem niza eksperimenata, pokazali smo da osnovna inačica okvira VIBE postiže podjednake ili bolje rezultate u usporedbi sa stanjem tehnike za obranu od napada. S druge strane, vidjeli smo i da osnovna inačica okvira VIBE postiže lošije rezultate od stanja tehnike za učenje na zašumljenim oznakama.

Pažljivom validacijom hiperparametara, korištenjem strategije kosinusnog kaljenja za izmjenu stope učenja te dodavanjem komponente konzistencijskog gubitka, poboljšali smo performanse okvira VIBE. Konkretno, zaključili smo da okvir VIBE s konzistencijskim gubitkom i prikladno odabranim skupom jakih augmentacija postiže najbolje rezultate u teškim postavima zašumljivanja (simetrično zašumljivanje uz visoku stopu šuma, asimetrično zašumljivanje). Iako algoritmi SOP+ te ILL i dalje postižu najbolje rezultate u lakšim postavima zašumljivanja, dodavanjem konzistencijskog gubitka okviru VIBE značajno smo smanjili razliku u performansama u usporedbi sa stanjem tehnike. Dodatno, eksperimentalno smo potvrdili da okvir VIBE s konzistencijskim gubitkom ima poboljšane performanse i na problemu napada umetanjem stražnjih vrata.

Potaknuti uspjehom poboljšanog okvira VIBE, odlučili smo dodati komponentu konzistencijskog gubitka standardnom nadziranom učenju te ga evaluirati na problemu zašumljenih oznaka. Dok standardno nadzirano učenje na podacima sa zašumljenim oznakama rezultira modelima s niskom točnošću, dodavanjem konzistencijskog gubitka možemo drastično povećati točnost naučenih modela na čistim podacima. Konkretno,

u lakšim postavima zašumljivanja, nadzirano učenje s konzistencijskim gubitkom postiže točnost usporedivu s točnošću algoritama SOP+ te ILL. Iako povećanje stope šuma vodi do pada točnosti nadziranog učenja s konzistencijskim gubitkom, uočeni pad je značajno manji u usporedbi sa standardnim nadziranim učenjem.

Konačno, eksperimentalno smo pokazali da učenje algoritmom ILL može biti nestabilno u teškim postavima napada. Zbog ovoga, algoritam ILL ne možemo koristiti kao obranu od napada umetanjem stražnjih vrata. Kako bismo pokušali riješiti ovaj problem, predlažemo dvije inačice hibridnog okvira zasnovane na okviru VIBE uz određene dijelove algoritma ILL. Dok se prva inačica (E korak preuzet iz algoritma ILL) nije pokazala uspješnom, druga inačica (definicija distribucije  $p(y|l)$  preuzeta iz algoritma ILL) postiže podjednake performanse kao i osnovna inačica okvira VIBE. Zaključujemo da druga inačica hibridnog okvira može služiti kao zamjena za osnovnu inačicu okvira VIBE, ali i općenito kao obrana od napada umetanjem stražnjih vrata.

Kao smjer za budući rad, prirodno se nalaže primjena okvira VIBE s konzistencijskim gubitkom na problem učenja na djelomičnim oznakama. Kako bismo ovo ostvarili, potrebno je reformulirati optimizacijski cilj te prilagoditi korake algoritma maksimizacije očekivanja. Kada je u pitanju nadzirano učenje, vrijedilo bi provesti još eksperimenata u vezi dodavanja konzistencijskog gubitka (izmjena stope konzistencije, validacija odabira skupa jakih augmentacija) kako bismo potvrdili da ovim pristupom možemo dobiti prihvatljivu točnost pri učenju na podacima sa zašumljenim oznakama. Konačno, bilo bi zanimljivo evaluirati uspješnu inačicu hibridnog okvira na problemu zašumljenih oznaka, kao i nadograditi ju konzistencijskim gubitkom.

## Literatura

- [1] C. Zhang, S. Bengio, M. Hardt, B. Recht, i O. Vinyals, “Understanding deep learning requires rethinking generalization”, *arXiv preprint arXiv:1611.03530*, 2016.
- [2] A. Voulodimos, N. Doulamis, A. Doulamis, i E. Protopapadakis, “Deep learning for computer vision: A brief review”, *Computational intelligence and neuroscience*, sv. 2018, br. 1, str. 7068349, 2018.
- [3] Y. Gao, B. G. Doan, Z. Zhang, S. Ma, J. Zhang, A. Fu, S. Nepal, i H. Kim, “Backdoor attacks and countermeasures on deep learning: A comprehensive review”, *arXiv preprint arXiv:2007.10760*, 2020.
- [4] S. Gupta i A. Gupta, “Dealing with noise problem in machine learning data-sets: A systematic review”, *Procedia Computer Science*, sv. 161, str. 466–474, 2019.
- [5] Y. Li, X. Lyu, N. Koren, L. Lyu, B. Li, i X. Ma, “Anti-backdoor learning: Training clean models on poisoned data”, *Advances in Neural Information Processing Systems*, sv. 34, str. 14 900–14 912, 2021.
- [6] K. Huang, Y. Li, B. Wu, Z. Qin, i K. Ren, “Backdoor defense via decoupling the training process”, *arXiv preprint arXiv:2202.03423*, 2022.
- [7] K. Gao, Y. Bai, J. Gu, Y. Yang, i S.-T. Xia, “Backdoor defense via adaptively splitting poisoned dataset”, u *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2023., str. 4005–4014.
- [8] S. Liu, Z. Zhu, Q. Qu, i C. You, “Robust training under label noise by over-parameterization”, u *International Conference on Machine Learning*. PMLR, 2022., str. 14 153–14 172.

- [9] H. Chen, A. Shah, J. Wang, R. Tao, Y. Wang, X. Li, X. Xie, M. Sugiyama, R. Singh, i B. Raj, “Imprecise label learning: A unified framework for learning with various imprecise label configurations”, *Advances in Neural Information Processing Systems*, sv. 37, str. 59 621–59 654, 2024.
- [10] I. Sabolić, M. Grcić, i S. Šegvić, “Seal your backdoor with variational defense”, *arXiv preprint arXiv:2503.08829*, 2025.
- [11] T. Gu, K. Liu, B. Dolan-Gavitt, i S. Garg, “Badnets: Evaluating backdooring attacks on deep neural networks”, *IEEE Access*, sv. 7, str. 47 230–47 244, 2019.
- [12] Y. Chen, X. Gong, Q. Wang, X. Di, i H. Huang, “Backdoor attacks and defenses for deep neural networks in outsourced cloud environments”, *IEEE Network*, sv. 34, br. 5, str. 141–147, 2020.
- [13] A. Nguyen i A. Tran, “Wanet-imperceptible warping-based backdoor attack”, *arXiv preprint arXiv:2102.10369*, 2021.
- [14] Y. Li, Y. Li, B. Wu, L. Li, R. He, i S. Lyu, “Invisible backdoor attack with sample-specific triggers”, u *Proceedings of the IEEE/CVF international conference on computer vision*, 2021., str. 16 463–16 472.
- [15] K. D. Doan, Y. Lao, i P. Li, “Marksman backdoor: Backdoor attacks with arbitrary target class”, *Advances in Neural Information Processing Systems*, sv. 35, str. 38 260–38 273, 2022.
- [16] M. Barni, K. Kallas, i B. Tondi, “A new backdoor attack in cnns by training set corruption without label poisoning”, u *2019 IEEE International Conference on Image Processing (ICIP)*. IEEE, 2019., str. 101–105.
- [17] S. M. Basha, D. S. Rajput, i V. Vandhan, “Impact of gradient ascent and boosting algorithm in classification.” *International Journal of Intelligent Engineering & Systems*, sv. 11, br. 1, 2018.
- [18] S. Ruder, “An overview of gradient descent optimization algorithms”, *arXiv preprint arXiv:1609.04747*, 2016.

- [19] A. Jaiswal, A. R. Babu, M. Z. Zadeh, D. Banerjee, i F. Makedon, “A survey on contrastive self-supervised learning”, *Technologies*, sv. 9, br. 1, str. 2, 2020.
- [20] Y. Wang, X. Ma, Z. Chen, Y. Luo, J. Yi, i J. Bailey, “Symmetric cross entropy for robust learning with noisy labels”, u *Proceedings of the IEEE/CVF international conference on computer vision*, 2019., str. 322–330.
- [21] J. E. Van Engelen i H. H. Hoos, “A survey on semi-supervised learning”, *Machine learning*, sv. 109, br. 2, str. 373–440, 2020.
- [22] R. Vilalta i Y. Drissi, “A perspective view and survey of meta-learning”, *Artificial intelligence review*, sv. 18, str. 77–95, 2002.
- [23] F. R. Cordeiro i G. Carneiro, “A survey on deep learning with noisy labels: How to train your model when you cannot trust on the annotations?” u *2020 33rd SIBGRAPI conference on graphics, patterns and images (SIBGRAPI)*. IEEE, 2020., str. 9–16.
- [24] A. Krizhevsky, G. Hinton *et al.*, “Learning multiple layers of features from tiny images”, 2009.
- [25] L. Deng, “The mnist database of handwritten digit images for machine learning research [best of the web]”, *IEEE signal processing magazine*, sv. 29, br. 6, str. 141–142, 2012.
- [26] D. Berthelot, N. Carlini, I. Goodfellow, N. Papernot, A. Oliver, i C. A. Raffel, “Mixmatch: A holistic approach to semi-supervised learning”, *Advances in neural information processing systems*, sv. 32, 2019.
- [27] D. Tanaka, D. Ikami, T. Yamasaki, i K. Aizawa, “Joint optimization framework for learning with noisy labels”, u *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2018., str. 5552–5560.
- [28] Y. Tian, X. Yu, i S. Fu, “Partial label learning: Taxonomy, analysis and outlook”, *Neural Networks*, sv. 161, str. 708–734, 2023.

- [29] T. K. Moon, “The expectation-maximization algorithm”, *IEEE Signal processing magazine*, sv. 13, br. 6, str. 47–60, 1996.
- [30] V. Hondru, F. A. Croitoru, S. Minaee, R. T. Ionescu, i N. Sebe, “Masked image modeling: A survey”, *arXiv preprint arXiv:2408.06687*, 2024.
- [31] M. A. Kramer, “Nonlinear principal component analysis using autoassociative neural networks”, *AIChE journal*, sv. 37, br. 2, str. 233–243, 1991.
- [32] E. Chávez, G. Navarro, R. Baeza-Yates, i J. L. Marroquín, “Searching in metric spaces”, *ACM computing surveys (CSUR)*, sv. 33, br. 3, str. 273–321, 2001.
- [33] P. Khosla, P. Teterwak, C. Wang, A. Sarna, Y. Tian, P. Isola, A. Maschinot, C. Liu, i D. Krishnan, “Supervised contrastive learning”, *Advances in neural information processing systems*, sv. 33, str. 18 661–18 673, 2020.
- [34] F. Schroff, D. Kalenichenko, i J. Philbin, “Facenet: A unified embedding for face recognition and clustering”, u *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2015., str. 815–823.
- [35] A. v. d. Oord, Y. Li, i O. Vinyals, “Representation learning with contrastive predictive coding”, *arXiv preprint arXiv:1807.03748*, 2018.
- [36] I. G. Estepa, I. Sarasúa, B. Nagarajan, i P. Radeva, “All4one: Symbiotic neighbour contrastive learning via self-attention and redundancy reduction”, u *Proceedings of the IEEE/CVF international conference on computer vision*, 2023., str. 16 243–16 253.
- [37] D. Dwibedi, Y. Aytar, J. Tompson, P. Sermanet, i A. Zisserman, “With a little help from my friends: Nearest-neighbor contrastive learning of visual representations”, u *Proceedings of the IEEE/CVF international conference on computer vision*, 2021., str. 9588–9597.
- [38] J. Zbontar, L. Jing, I. Misra, Y. LeCun, i S. Deny, “Barlow twins: Self-supervised learning via redundancy reduction”, u *International conference on machine learning*. PMLR, 2021., str. 12 310–12 320.



- [39] T. Pham, C. Zhang, A. Niu, K. Zhang, i C. D. Yoo, “On the pros and cons of momentum encoder in self-supervised visual representation learning”, *arXiv preprint arXiv:2208.05744*, 2022.
- [40] S. A. Koohpayegani, A. Tejankar, i H. Pirsiavash, “Mean shift for self-supervised learning”, u *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2021., str. 10 326–10 335.
- [41] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, i I. Polosukhin, “Attention is all you need”, *Advances in neural information processing systems*, sv. 30, 2017.
- [42] I. J. Myung, “Tutorial on maximum likelihood estimation”, *Journal of mathematical Psychology*, sv. 47, br. 1, str. 90–100, 2003.
- [43] S.-i. Amari, “Backpropagation and stochastic gradient descent method”, *Neurocomputing*, sv. 5, br. 4-5, str. 185–196, 1993.
- [44] C. J. Wu, “On the convergence properties of the em algorithm”, *The Annals of statistics*, str. 95–103, 1983.
- [45] F. Pérez-Cruz, “Kullback-leibler divergence estimation of continuous distributions”, u *2008 IEEE international symposium on information theory*. IEEE, 2008., str. 1666–1670.
- [46] R. M. Neal i G. E. Hinton, “A view of the em algorithm that justifies incremental, sparse, and other variants”, u *Learning in graphical models*. Springer, 1998., str. 355–368.
- [47] M. N. Bernstein, “Expectation-maximization (em) and coordinate ascent”, <https://mbernste.github.io/posts/em/>, 2021., accessed: 2025-06-02.
- [48] A. Rényi, “On measures of entropy and information”, u *Proceedings of the fourth Berkeley symposium on mathematical statistics and probability, volume 1: contributions to the theory of statistics*, sv. 4. University of California Press, 1961., str. 547–562.

- [49] G. Peyré, M. Cuturi *et al.*, “Computational optimal transport: With applications to data science”, *Foundations and Trends® in Machine Learning*, sv. 11, br. 5-6, str. 355–607, 2019.
- [50] N. Papadakis, “Optimal transport for image processing”, doktorska disertacija, Université de Bordeaux; Habilitation thesis, 2015.
- [51] V. I. Bogachev i A. V. Kolesnikov, “The monge-kantorovich problem: achievements, connections, and perspectives”, *Russian Mathematical Surveys*, sv. 67, br. 5, str. 785, 2012.
- [52] R. M. Karp, U. V. Vazirani, i V. V. Vazirani, “An optimal algorithm for on-line bipartite matching”, u *Proceedings of the twenty-second annual ACM symposium on Theory of computing*, 1990., str. 352–358.
- [53] G. M. Ziegler, “Lectures on polytopes.” 1993.
- [54] G. B. Dantzig, “Linear programming”, *Operations research*, sv. 50, br. 1, str. 42–47, 2002.
- [55] A. Genevay, “Entropy-regularized optimal transport for machine learning”, doktorska disertacija, Université Paris sciences et lettres, 2019.
- [56] P. A. Knight, “The sinkhorn–knopp algorithm: convergence and applications”, *SIAM Journal on Matrix Analysis and Applications*, sv. 30, br. 1, str. 261–275, 2008.
- [57] R. Sinkhorn, “A relationship between arbitrary positive matrices and doubly stochastic matrices”, *The annals of mathematical statistics*, sv. 35, br. 2, str. 876–879, 1964.
- [58] M. Cuturi, “Sinkhorn distances: Lightspeed computation of optimal transport”, *Advances in neural information processing systems*, sv. 26, 2013.
- [59] M. Slater, “Lagrange multipliers revisited”, u *Traces and emergence of nonlinear programming*. Springer, 2013., str. 293–306.

- [60] A. Banerjee, I. S. Dhillon, J. Ghosh, S. Sra, i G. Ridgeway, “Clustering on the unit hypersphere using von mises-fisher distributions.” *Journal of Machine Learning Research*, sv. 6, br. 9, 2005.
- [61] G. J. McLachlan i T. Krishnan, *The EM algorithm and extensions*. John Wiley & Sons, 2008.
- [62] E. J. McShane, “Jensen’s inequality”, 1937.
- [63] E. D. Cubuk, B. Zoph, D. Mane, V. Vasudevan, i Q. V. Le, “Autoaugment: Learning augmentation strategies from data”, u *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2019., str. 113–123.
- [64] L. P. Kaelbling, M. L. Littman, i A. W. Moore, “Reinforcement learning: A survey”, *Journal of artificial intelligence research*, sv. 4, str. 237–285, 1996.
- [65] L. McInnes, J. Healy, i J. Melville, “Umap: Uniform manifold approximation and projection for dimension reduction”, *arXiv preprint arXiv:1802.03426*, 2018.
- [66] V. A. Traag, L. Waltman, i N. J. Van Eck, “From louvain to leiden: guaranteeing well-connected communities”, *Scientific reports*, sv. 9, br. 1, str. 1–12, 2019.
- [67] Y. LeCun *et al.*, “Generalization and network design strategies”, *Connectionism in perspective*, sv. 19, br. 143-155, str. 18, 1989.
- [68] Z. Li, F. Liu, W. Yang, S. Peng, i J. Zhou, “A survey of convolutional neural networks: analysis, applications, and prospects”, *IEEE transactions on neural networks and learning systems*, sv. 33, br. 12, str. 6999–7019, 2021.
- [69] A. Krizhevsky, I. Sutskever, i G. E. Hinton, “Imagenet classification with deep convolutional neural networks”, *Advances in neural information processing systems*, sv. 25, 2012.
- [70] O. Russakovsky, J. Deng, H. Su, J. Krause, S. Satheesh, S. Ma, Z. Huang, A. Karpathy, A. Khosla, M. Bernstein *et al.*, “Imagenet large scale visual recognition challenge”, *International journal of computer vision*, sv. 115, str. 211–252, 2015.

- [71] Y.-L. Boureau, J. Ponce, i Y. LeCun, “A theoretical analysis of feature pooling in visual recognition”, u *Proceedings of the 27th international conference on machine learning (ICML-10)*, 2010., str. 111–118.
- [72] S. Ioffe i C. Szegedy, “Batch normalization: Accelerating deep network training by reducing internal covariate shift”, u *International conference on machine learning*. pmlr, 2015., str. 448–456.
- [73] K. He, X. Zhang, S. Ren, i J. Sun, “Deep residual learning for image recognition”, u *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016., str. 770–778.
- [74] —, “Identity mappings in deep residual networks”, u *Computer Vision–ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11–14, 2016, Proceedings, Part IV 14*. Springer, 2016., str. 630–645.
- [75] I. Sutskever, J. Martens, G. Dahl, i G. Hinton, “On the importance of initialization and momentum in deep learning”, u *International conference on machine learning*. PMLR, 2013., str. 1139–1147.
- [76] A. Krogh i J. Hertz, “A simple weight decay can improve generalization”, *Advances in neural information processing systems*, sv. 4, 1991.
- [77] Z. Zhong, L. Zheng, G. Kang, S. Li, i Y. Yang, “Random erasing data augmentation”, u *Proceedings of the AAAI conference on artificial intelligence*, sv. 34, br. 07, 2020., str. 13 001–13 008.
- [78] T. DeVries i G. W. Taylor, “Improved regularization of convolutional neural networks with cutout”, *arXiv preprint arXiv:1708.04552*, 2017.
- [79] M. Ishii i A. Sato, “Layer-wise weight decay for deep neural networks”, u *Pacific-Rim Symposium on Image and Video Technology*. Springer, 2017., str. 276–289.

# Sažetak

## Varijacijsko učenje na zašumljenim oznakama

Dominik Jambrović

Napadi umetanjem stražnjih vrata i prisutnost zašumljenih oznaka neki su od potencijalnih problema tijekom prikupljanja i označavanja skupova podataka. Iako je okvir VIBE dizajniran kao obrana od napada, pokazujemo da se može uspješno koristiti i za učenje na zašumljenim podacima. Poboljšavamo performanse okvira VIBE na problemu napada umetanjem stražnjih vrata dodavanjem komponente konzistencijskog gubitka. Učenjem te evaluacijom na zašumljenom skupu podataka CIFAR-10, potvrđujemo da okvir VIBE s konzistencijskim gubitkom nadmašuje performanse stanja tehnike u teškim postavima zašumljivanja. Eksperimentalno pokazujemo da dodavanje konzistencijskog gubitka značajno povećava točnost standardnog nadziranog učenja na problemu zašumljenih oznaka. Zaključujemo da je konzistencijski gubitak ključan za uspješno učenje na zašumljenim podacima.

**Ključne riječi:** napadi umetanjem stražnjih vrata; zašumljene oznake; algoritam maksimizacije očekivanja; konzistencijski gubitak; VIBE

# Abstract

## Variational learning on noisy labels

Dominik Jambrović

Backdoor attacks and the presence of noisy labels are some of the potential problems during data collection and labeling. Although the VIBE framework is designed as a defense against backdoor attacks, we show that it can also be successfully used for learning on noisy data. We improve the performance of the VIBE framework on the backdoor attacks problem by adding a consistency loss component. By training and evaluating it on the noisy CIFAR-10 dataset, we confirm that the VIBE framework with consistency loss outperforms the state-of-the-art in hard noisiness setups. Experiments show that adding consistency loss significantly increases the accuracy of standard supervised learning on the noisy labels problem. We conclude that consistency loss is crucial for successful learning on noisy data.

**Keywords:** backdoor attacks; noisy labels; expectation-maximization algorithm; consistency loss; VIBE