

# **Varijacijsko učenje na zašumljenim oznakama**

Autor: Dominik Jambrović

Voditelji: Ivan Sabolić, Siniša Šegvić

# Sadržaj

1. Uvod
2. Napadi umetanjem stražnjih vrata
3. Zašumljene oznake
4. Okvir VIBE
5. Konzistencijski gubitak
6. Eksperimenti
7. Zaključak i budući rad
8. Diskusija

# Uvod

Odluke pri nadziranom učenju **dubokih modela**

- arhitektura
- algoritam učenja
- hiperparametri
- **skup podataka**

Opasnosti pri **stvaranju** skupa podataka

- napadi umetanjem stražnjih vrata
- pogreške označivača ➡ zašumljene oznake



20 km/h



100 km/h

# Napadi umetanjem stražnjih vrata

- **zatrovani podatci** – izmijenjeni podatci za učenje koji navode optimizaciju da u model ugradi **stražnja vrata**
- stražnja vrata omogućavaju manipuliranje naučenim modelom
- trovanje uvijek uključuje **dodavanje okidača u podatke**
- većina metoda **mijenja i oznake**
- neke metode ne mijenjaju oznake, već dodatno perturbiraju podatke
- tijekom zaključivanja, model daje **krivo predviđanje** ako je na ulazu ispitna slika s okidačem

# Neke vrste okidača



**Original**



**BadNets**

vidljiv



**Blend**

teže primjenjivi u  
stvarnom svijetu



**WaNet**

# Zašumljene oznake

- posljedica **netočnog označavanja** podataka
- razlikujemo **simetrično** (gore) i **asimetrično** (dolje) zašumljivanje

$$y' = (1 - b) \cdot y + b \cdot \tilde{y}$$

$$y' = (1 - b) \cdot y + b \cdot f(y)$$

$$b \sim \mathcal{B}(p)$$

$$\tilde{y} \sim \mathcal{U}(\{y_0, \dots, y_{K-1}\})$$

$$f : Y \rightarrow Y$$

# Zašumljene oznake

- posljedica **netočnog označavanja** podataka
- razlikujemo **simetrično** (gore) i **asimetrično** (dolje) zašumljivanje

|             |   |                           |   |               |
|-------------|---|---------------------------|---|---------------|
| 1. airplane | → | {airplane, automobile,    | → | 1. automobile |
| 2. bird     |   | bird, cat, deer, dog,     |   | 2. deer       |
| 3. airplane |   | frog, horse, ship, truck} |   | 3. airplane   |

---

|          |   |               |
|----------|---|---------------|
| 1. truck | → | 1. automobile |
| 2. bird  |   | 2. airplane   |
| 3. cat   |   | 3. dog        |
| 4. dog   |   | 4. cat        |
| 5. deer  |   | 5. horse      |

# Okvir VIBE

- cilj: učenje modela **bez stražnjih vrata** na zatrovanim podatcima

$$\ell_{VD}(\cdot|\mathcal{D}) = \log \prod_{i=1}^N p(y^i|\mathbf{x}^i) = \sum_{i=1}^N \log \sum_{l=1}^K p(y^i|l, \mathbf{x}^i) p(l|\mathbf{x}^i)$$

- optimizacija varijacijskog cilja koristeći **algoritam maksimizacije očekivanja**



# Okvir VIBE, algoritam EM

- iterativan algoritam za učenje uz **prisutnost skrivenih varijabli**
- naizmjenično provođenje **E koraka** i **M koraka**
- M korak se može provoditi više puta zaredom

$$\theta^{(t+1)} = \arg \max_{\theta} \mathbb{E}_{Z \sim p(\cdot | X, \theta^{(t)})} [\log p(X, Z | \theta)]$$

- E korak: **aproksimacija čistih pseudooznaka** (algoritam SK)  
alternativno, korištenje modela iz prethodne iteracije
- M korak: **ažuriranje parametara modela** (gradijentni spust)


# Okvir VIBE

- model: **ekstraktor značajki**  $g_\theta$ , skup  $\phi$  čistih prototipova  $\mu_l$ , skup  $\psi$  zatrovanih prototipova  $\eta_y$

$$p_{\theta, \phi, \pi}(l^i | \mathbf{x}^i) = \frac{\exp(\kappa \mu_{l^i}^T \mathbf{v}^i + \log \pi_{l^i})}{\sum_{l'} \exp(\kappa \mu_{l'}^T \mathbf{v}^i + \log \pi_{l'})}$$

$$p_{\theta, \phi, \psi}(y^i | l^i, \mathbf{x}^i) = \frac{\exp(v \eta_{y^i}^T h(\mu_{l^i}, \mathbf{v}^i))}{\sum_{y'} \exp(v \eta_{y'}^T h(\mu_{l^i}, \mathbf{v}^i))}$$

# Okvir VIBE



Preuzeto iz [\[sabolic25iccv\]](#)

# Konzistencijski gubitak

- motivacija: samonadzirano učenje može **poboljšati performanse** modela **bez korištenja oznaka**
- cilj: osigurati da model za **različite perturbacije istog ulaza** daje **isti izlaz**
- **dva pogleda** na podatke: **slabe** i **jake** augmentacije

$$\mathcal{L}_{con} = KL(p(y|\mathcal{A}_W(\mathbf{x}))||p(y|\mathcal{A}_S(\mathbf{x})))$$

- povećavanje **invarijantnosti** na perturbacije ulaza, sprječavanje **prenaučenosti**

# Eksperimenti

# Skup podataka CIFAR-10

- slike dimenzija 32 x 32
- 10 razreda
- 50 000 primjera u skupu za učenje, 10 000 u skupu za ispitivanje

airplane



automobile



bird



cat



deer



# Postavke eksperimenata

- 3 ponavljanja pojedinih eksperimenata

## Zašumljene oznake

- **simetrično** zašumljivanje uz stopu šuma **20%, 50% i 80%**
- **asimetrično** zašumljivanje uz stopu šuma **40%**
- vrednovanje: **točnost** na čistom skupu

## Napadi umetanjem stražnjih vrata

- napadi **BadNets**, **Blend** i **WaNet** uz stopu trovanja **10%**
- ***all-to-one*** izmjena oznaka uz ciljni razred ***airplane***
- vrednovanje: **točnost** na čistom skupu, **udio uspješnih napada** (engl. *attack success rate* – ASR)

# Postavke eksperimenata

- arhitektura **ResNet18**
- **samonadzirana inicijalizacija** modela okvirom **All4One**
- inicijalizacija čistih i zatrovanih prototipova na **centroide pripadnih razreda**
- provođenje **E koraka** učenja **svakih 1000 iteracija**
- **faktor konzistencijskog gubitka** iznosa **5**
- učenje **30 000 iteracija** okvirom **VIBE** uz optimizator **SGD** sa **stopom učenja** iznosa **0.01** i strategijom **kosinusnog kaljenja** bez restarta
- skup podijeljen na **minigrupe** veličine **256**



# Čisti skup, usporedba sa SotA

Stanje tehnike

- *Sparse over-parameterization* (**SOP**)
- *Imprecise label learning* (**ILL**)
- SOP uz konzistencijski gubitak i gubitak ravnoteže razreda: **SOP+**

| Algoritam | Točnost [%]                      |
|-----------|----------------------------------|
| CE        | $95.2 \pm 0.2$                   |
| CE + CL   | $96.3 \pm 0.1$                   |
| SOP+      | $96.6 \pm 0.1$                   |
| ILL       | <b><math>96.7 \pm 0.1</math></b> |
| VIBE      | $96.1 \pm 0.1$                   |

CE – nadzirano učenje

CL – konzistencijski gubitak

# Zašumljene oznake, usporedba sa SotA

- oznaka \* prije imena algoritma – rezultat iz rada [\[chen24neurips\]](#)

## Simetrično zašumljivanje

| Algoritam | Stopa šuma [%]                   |                                  |                                  |
|-----------|----------------------------------|----------------------------------|----------------------------------|
|           | 20                               | 50                               | 80                               |
| CE        | $84.1 \pm 0.3$                   | $57.6 \pm 1.4$                   | $26.7 \pm 0.5$                   |
| CE + CL   | $95.2 \pm 0.2$                   | $91.6 \pm 0.2$                   | $76.5 \pm 1.1$                   |
| SOP+      | <b><math>96.3 \pm 0.1</math></b> | $95.5 \pm 0.1$                   | $93.2 \pm 0.2$                   |
| *SOP+     | 96.3                             | 95.5                             | 94.0                             |
| ILL       | $96.2 \pm 0.1$                   | <b><math>95.8 \pm 0.1</math></b> | $93.9 \pm 0.3$                   |
| *ILL      | $96.8 \pm 0.1$                   | $96.6 \pm 0.2$                   | $94.3 \pm 0.1$                   |
| VIBE      | $95.6 \pm 0.1$                   | $94.9 \pm 0.1$                   | <b><math>94.3 \pm 0.1</math></b> |

## Asimetrično zašumljivanje, stopa šuma 40%

| Algoritam | Točnost [%]                      |
|-----------|----------------------------------|
| CE        | $76.5 \pm 0.5$                   |
| CE + CL   | $92.3 \pm 0.2$                   |
| SOP+      | $94.1 \pm 0.3$                   |
| *SOP+     | 93.8                             |
| ILL       | $61.6 \pm 44.7$                  |
| *ILL      | $94.8 \pm 0.8$                   |
| VIBE      | <b><math>95.0 \pm 0.1</math></b> |

CE – nadzirano učenje

CL – konzistencijski gubitak

# Zašumljene oznake, validacija VIBE

| Postav                      | Točnost [%] |
|-----------------------------|-------------|
| VIBE                        | 93.6        |
| VIBE + CL                   | 94.8        |
| VIBE (CA) + CL              | 95.1        |
| VIBE (CA) + CL (CR = 7.5)   | 95.7        |
| VIBE (CA) + CL (RE, CR = 5) | <b>95.7</b> |

CA – kosinusno kaljenje

CL – konzistencijski gubitak

CR – faktor konzistencijskog gubitka

RE – augmentacija nasumičnog brisanja

# Zašumljene oznake, validacija SotA

## Algoritam SOP+

| Faktor konzistencijskog gubitka | Faktor gubitka ravnoteže razreda | Točnost [%] |
|---------------------------------|----------------------------------|-------------|
| 0.9                             | 0                                | <b>96.4</b> |
| 1                               | 0                                | 96.3        |
| 0                               | 0.1                              | 93.9        |
| 0                               | 1                                | 93.9        |
| 0.9                             | 0.1                              | 96.3        |

## Algoritam ILL

| Faktor konzistencijskog gubitka | Točnost [%] |
|---------------------------------|-------------|
| 0                               | <b>96.3</b> |
| 1                               | 96.2        |

# Zašumljene oznake, validacija CE

## Nadzirano učenje

| Broj epoha | Inačica skupa podataka |                 |                  |
|------------|------------------------|-----------------|------------------|
|            | Čisto                  | Simetrično, 20% | Asimetrično, 40% |
| 200        | 95.1                   | 83.6            | 75.8             |
| 300        | <b>95.3</b>            | <b>83.8</b>     | <b>76.8</b>      |

## Nadzirano učenje s konzistencijskim gubitkom

| Broj epoha | Inačica skupa podataka |                 |                  |
|------------|------------------------|-----------------|------------------|
|            | Čisto                  | Simetrično, 20% | Asimetrično, 40% |
| 200        | 95.9                   | <b>95.4</b>     | <b>92.2</b>      |
| 300        | <b>96.3</b>            | 93.3            | 89.8             |

# Napadi, usporedba sa SotA

- oznaka \* prije imena algoritma – rezultat iz rada [\[sabolic25iccv\]](#)

## BadNets

| Algoritam | Točnost [%]                      | ASR [%]                         |
|-----------|----------------------------------|---------------------------------|
| *ABL      | 93.8                             | 1.1                             |
| *DBD      | 92.4                             | 1.0                             |
| *ASD      | 92.1                             | 3.0                             |
| VIBE      | $94.4 \pm 0.1$                   | $0.6 \pm 0.1$                   |
| VIBE + CL | <b><math>94.8 \pm 0.1</math></b> | <b><math>0.5 \pm 0.1</math></b> |

## Blend

| Algoritam | Točnost [%]                      | ASR [%]                         |
|-----------|----------------------------------|---------------------------------|
| *ABL      | 91.9                             | 1.6                             |
| *DBD      | 92.2                             | 1.7                             |
| *ASD      | 93.4                             | 1.0                             |
| VIBE      | $94.3 \pm 0.1$                   | $3.5 \pm 0.4$                   |
| VIBE + CL | <b><math>94.5 \pm 0.1</math></b> | <b><math>0.7 \pm 0.1</math></b> |

## WaNet

| Algoritam | Točnost [%]                      | ASR [%]       |
|-----------|----------------------------------|---------------|
| *ABL      | 84.1                             | 2.2           |
| *DBD      | 91.2                             | <b>0.4</b>    |
| *ASD      | 93.3                             | 1.2           |
| VIBE      | $94.3 \pm 0.2$                   | $0.8 \pm 0.2$ |
| VIBE + CL | <b><math>94.7 \pm 0.1</math></b> | $0.6 \pm 0.1$ |

# Zaključak i budući rad

- osnovnu inačicu VIBE-a nadogradili smo korištenjem **kosinusnog kaljenja** te dodavanjem **konzistencijskog gubitka**

## Zašumljene oznake

- osnovna inačica VIBE-a postiže lošije rezultate od SotA
- nadograđena inačica VIBE-a postiže **najbolje rezultate u teškim postavima**, ali i bolje rezultate u lakšim postavima (+2.1pp ACC @ 20% sim. zaš.)
- dodavanje konzistencijskog gubitka nadziranom učenju može **značajno povećati točnost** naučenih modela (+11.6pp ACC @ 20% sim. zaš.)

# Zaključak i budući rad

## Napadi umetanjem stražnjih vrata

- osnovna inačica VIBE-a postiže **najvišu točnost**, ali ne i najniži ASR u usporedbi sa SotA na **3 različita napada**
- nadograđena inačica VIBE-a postiže **najvišu točnost**, kao i **najniži ASR** u usporedbi s osnovnom inačicom VIBE-a te SotA na **2/3 različita napada** (-2.8pp ASR @ 10% Blend)

## Budući rad

- primjena nadograđene inačice VIBE-a na **problem učenja na djelomičnim oznakama** (engl. *partial label learning*)
- dodatni eksperimenti u vezi dodavanja konzistencijskog gubitka nadziranom učenju



# Diskusija