

Varijacijsko učenje na zašumljenim oznakama

Autor: Dominik Jambrović

Voditelji: Ivan Sabolić, Siniša Šegvić

Sadržaj

1. Uvod
2. Napadi umetanjem stražnjih vrata
3. Zašumljene oznake
4. Okvir VIBE
5. Konzistencijski gubitak
6. Eksperimenti
7. Zaključak i budući rad
8. Diskusija

Uvod

Odluke pri nadziranom učenju **dubokih modela**

- arhitektura
- algoritam učenja
- hiperparametri
- **skup podataka**

Opasnosti pri **stvaranju** skupa podataka

- napadi umetanjem stražnjih vrata
- pogreške označivača → zašumljene oznake

Napadi umetanjem stražnjih vrata

- **zatrovani podatci** – izmijenjeni podatci za učenje koji navode optimizaciju da u model ugradi **stražnja vrata**
- stražnja vrata omogućavaju manipuliranje naučenim modelom
- trovanje uvijek uključuje **dodavanje okidača u podatke**
- većina metoda **mijenja i oznake**
- neke metode ne mijenjaju oznake, već dodatno perturbiraju podatke
- tijekom zaključivanja, model daje **krivo predviđanje** ako je na ulazu ispitna slika s okidačem

Neke vrste okidača



Original



BadNets

vidljiv



Blend

teže primjenjivi u
stvarnom svijetu



WaNet

Zašumljene oznake

- posljedica **netočnog označavanja** podataka
- razlikujemo **simetrično** (gore) i **asimetrično** (dolje) zašumljivanje

1. airplane		{airplane, automobile,		1. automobile
2. bird	→	bird, cat, deer, dog,	→	2. deer
3. airplane		frog, horse, ship, truck}		3. airplane

1. truck		1. automobile
2. bird		2. airplane
3. cat	→	3. dog
4. dog		4. cat
5. deer		5. horse

Okvir VIBE

- cilj: učenje modela **bez stražnjih vrata** na zatrovanim podatcima

$$\ell_{VD}(\cdot|\mathcal{D}) = \log \prod_{i=1}^N p(y^i|\mathbf{x}^i) = \sum_{i=1}^N \log \sum_{l=1}^K p(y^i|l, \mathbf{x}^i) p(l|\mathbf{x}^i)$$

- optimizacija varijacijskog cilja koristeći **algoritam maksimizacije očekivanja**

Okvir VIBE


- model: **ekstraktor značajki**, skup čistih prototipova μ_l , skup zatrovanih prototipova η_y

$$p_{\theta, \phi, \pi}(l^i | \mathbf{x}^i) = \frac{\exp(\kappa \mu_{l^i}^T \mathbf{v}^i + \log \pi_{l^i})}{\sum_{l'} \exp(\kappa \mu_{l'}^T \mathbf{v}^i + \log \pi_{l'})}$$

$$p_{\phi, \psi}(y^i | l^i, \mathbf{x}^i) = \frac{\exp(\nu \eta_{y^i}^T h(\mu_{l^i}, \mathbf{v}^i))}{\sum_{y'} \exp(\nu \eta_{y'}^T h(\mu_{l^i}, \mathbf{v}^i))}$$

- E korak: **aproksimacija čistih pseudooznaka** (algoritam SK)
- M korak: **ažuriranje parametara modela** (gradijentni spust)

Okvir VIBE



Preuzeto iz [\[sabolic25iccv\]](#)

Konzistencijski gubitak

- cilj: osigurati da model za **različite perturbacije istog ulaza** daje **isti izlaz**
- **dva pogleda** na podatke: **slabe** i **jake** augmentacije

$$\mathcal{L}_{con} = KL(p(y|\mathcal{A}_W(\mathbf{x}))||p(y|\mathcal{A}_S(\mathbf{x})))$$

- povećavanje **invarijantnosti** na perturbacije ulaza, sprječavanje **prenaučenosti**

Eksperimenti

Skup podataka CIFAR-10

- slike dimenzija 32 x 32
- 10 razreda
- 50 000 primjera u skupu za učenje, 10 000 u skupu za ispitivanje

airplane



automobile



bird



cat



deer



Postavke eksperimenata

Zašumljene oznake

- **simetrično** zašumljivanje uz stopu šuma **20%, 50% i 80%**
- **asimetrično** zašumljivanje uz stopu šuma **40%**
- vrednovanje: **točnost** na čistom skupu

Napadi umetanjem stražnjih vrata

- napadi **BadNets**, **Blend** i **WaNet** uz stopu trovanja **10%**
- ***all-to-one*** izmjena oznaka uz ciljni razred ***airplane***
- vrednovanje: **točnost** na čistom skupu, **udio uspješnih napada** (engl. *attack success rate* – ASR)

Postavke eksperimenata

- arhitektura **ResNet18**
- **samonadzirana inicijalizacija** modela okvirom **All4One**
- inicijalizacija čistih i zatrovanih prototipova na **centroide pripadnih razreda**
- učenje **30 000 iteracija** okvirom **VIBE** uz optimizator **SGD** sa **stopom učenja** iznosa **0.01** i strategijom **kosinusnog kaljenja** bez restarta
- skup podijeljen na **minigrupe** veličine **256**
- provođenje **E koraka** učenja **svakih 1000 iteracija**
- **faktor konzistencijskog gubitka** iznosa **5**

Čisti skup, usporedba sa SotA

Stanje tehnike

- *Sparse over-parameterization* (**SOP**)
- *Imprecise label learning* (**ILL**)
- SOP uz konzistencijski gubitak i gubitak ravnoteže razreda:
SOP+

Algoritam	Točnost [%]
CE	95.30
CE + CL	96.30
SOP+	96.70
ILL	96.75
VIBE	96.10

Zašumljene oznake, usporedba sa SotA

- oznaka * prije imena algoritma – rezultat iz rada [\[chen24neurips\]](#)

Simetrično zašumljivanje

Algoritam	Stopa šuma [%]		
	20	50	80
CE	83.80	57.20	27.30
CE + CL	95.40	91.70	76.20
SOP+	96.26	95.58	93.11
*SOP+	96.30	95.50	94.00
ILL	96.22	95.67	93.75
*ILL	96.78	96.60	94.31
VIBE	95.70	94.80	94.40

Asimetrično zašumljivanje, stopa šuma 40%

Algoritam	Točnost [%]
CE	76.80
CE + CL	92.20
SOP+	93.74
*SOP+	93.80
ILL	85.75
*ILL	94.75
VIBE	95.10

Zašumljene oznake, validacija VIBE

Postav	Točnost [%]
VIBE	93.6
VIBE + CL	94.8
VIBE (CA) + CL	95.1
VIBE (CA) + CL (CR = 7.5)	95.7
VIBE (CA) + CL (RE, CR = 5)	95.7

CA – kosinusno kaljenje

CL – konzistencijski gubitak

CR – faktor konzistencijskog gubitka

RE – augmentacija nasumičnog brisanja

Zašumljene oznake, validacija SotA

Algoritam SOP+

Faktor konzistencijskog gubitka	Faktor gubitka ravnoteže razreda	Točnost [%]
0.9	0	96.39
1	0	96.28
0	0.1	93.93
0	1	93.91
0.9	0.1	96.26

Algoritam ILL

Faktor konzistencijskog gubitka	Točnost [%]
0	96.28
1	96.22

Zašumljene oznake, validacija CE

Nadzirano učenje

Broj epoha	Inačica skupa podataka		
	Čisto	Simetrično, 20%	Asimetrično, 40%
200	95.1	83.6	75.8
300	95.3	83.8	76.8

Nadzirano učenje s konzistencijskim gubitkom

Broj epoha	Inačica skupa podataka		
	Čisto	Simetrično, 20%	Asimetrično, 40%
200	95.9	95.4	92.2
300	96.3	93.3	89.8

Napadi, usporedba sa SotA

- oznaka * prije imena algoritma – rezultat iz rada [\[sabolic25iccv\]](#)

BadNets

Algoritam	Točnost [%]	ASR [%]
*ABL	93.8	1.1
*DBD	92.4	1.0
*ASD	92.1	3.0
VIBE	94.4	0.6
VIBE + CL	94.8	0.5

Blend

Algoritam	Točnost [%]	ASR [%]
*ABL	91.9	1.6
*DBD	92.2	1.7
*ASD	93.4	1.0
VIBE	94.4	3.1
VIBE + CL	94.5	0.7

WaNet

Algoritam	Točnost [%]	ASR [%]
*ABL	84.1	2.2
*DBD	91.2	0.4
*ASD	93.3	1.2
VIBE	94.5	1.0
VIBE + CL	94.8	0.6

Zaključak i budući rad

- osnovnu inačicu VIBE-a nadogradili smo korištenjem **kosinusnog kaljenja** te dodavanjem **konzistencijskog gubitka**

Zašumljene oznake

- osnovna inačica VIBE-a postiže lošije rezultate od SotA
- nadograđena inačica VIBE-a postiže **najbolje rezultate u teškim postavima**
- dodavanje konzistencijskog gubitka nadziranom učenju može **značajno povećati točnost** naučenih modela

Zaključak i budući rad

Napadi umetanjem stražnjih vrata

- osnovna inačica VIBE-a postiže **najvišu točnost**, ali ne i najniži ASR u usporedbi sa SotA na **3 različita napada**
- nadograđena inačica VIBE-a postiže **najvišu točnost**, kao i **najniži ASR** u usporedbi s osnovnom inačicom VIBE-a te SotA na **2/3 različita napada**

Budući rad

- primjena nadograđene inačice VIBE-a na **problem učenja na djelomičnim oznakama** (engl. *partial label learning*)
- dodatni eksperimenti u vezi dodavanja konzistencijskog gubitka nadziranom učenju

Diskusija